



COLEGIO DE POSTGRADUADOS
INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS
AGRÍCOLAS
CAMPUS MONTECILLO
PROGRAMA DE POSTGRADO EN CIENCIAS FORESTALES

TAREA 1.

INTRODUCCIÓN A LAS SERIES DE TIEMPO

EST-624. Series de tiempo
Dra. Martha Elva Ramírez Guzmán

Zaira Rosario Pérez Vázquez
25 de enero de 2021

Introducción

Los datos obtenidos de observaciones recopiladas secuencialmente a lo largo del tiempo son extremadamente comunes en distintas áreas. Muchos conjuntos de datos aparecen como series de tiempo, por ejemplo, una secuencia mensual de cantidad de mercancías enviadas a una fábrica, una serie semanal de números de accidentes de tráfico, cantidades de lluvia y temperatura diaria, etc. Las series pueden tener periodicidad anual, semestral, trimestral, mensual, etc., según los periodos de tiempo en los que están recogidos los datos que la componen (Box *et al.*, 2016).

El propósito del análisis de series de tiempo es generalmente doble: 1) para comprender o modelar el mecanismo estocástico que da lugar a una serie observada y 2) para predecir o pronosticar los valores futuros de una serie con base en la historia de esa serie y, posiblemente, otras series relacionadas o factores. Una característica especial en las series de tiempo y sus modelos es que normalmente no podemos asumir que las observaciones surgen independientemente de una población común (o de poblaciones con diferentes medios, por ejemplo). Por lo cual, estudiar modelos que incorporan la dependencia es el concepto clave en el análisis de series de tiempo (Cryer y Chan, 2008).

De acuerdo con Box *et al.* (2016), el uso de las series de tiempo y los modelos dinámicos en cinco áreas importantes de aplicación: a) la previsión de valores futuros de una serie de tiempo a partir de valores actuales y pasados; b) la determinación de la función de transferencia de un sistema sujeto a inercia – la determinación de un modelo dinámico de entrada y salida de cualquier serie dada de entradas; c) el uso de variables indicadoras de entrada en modelos de función de transferencia para representar y evaluar los efectos de intervenciones inusuales sobre el comportamiento de una serie de tiempo; d) el examen de las interrelaciones entre diferentes variables de interés de series de tiempo relacionadas y la determinación de modelos dinámicos multivariados apropiados para representar esas relaciones conjuntas entre las variables a lo largo del tiempo; y e) el diseño de esquemas de control simples mediante los cuales las posibles desviaciones de la salida del sistema de un objetivo deseado pueden, en la medida de lo posible, compensarse mediante el ajuste de los valores de la serie de entrada.

Selección del conjunto de datos

La temperatura y la precipitación son variables climatológicas de vital importancia para el funcionamiento de los ecosistemas forestales, por ejemplo, para el crecimiento estacional de la vegetación, para el establecimiento del periodo vegetativo y reproductivo de las especies arbóreas, para la descomposición del material orgánico muerto, entre otros. Asimismo, las proyecciones de cambio climático del IPCC (2007) indican que entre 20 y 46% de las superficies de los bosques de coníferas experimentarán modificaciones de 2020 a 2050.

La reducción de la cobertura arbórea genera diversos efectos a distintas escalas sobre el funcionamiento del ecosistema y se manifiesta en la degradación de suelos, la pérdida de capacidad de los sistemas biológicos, el incremento de la vulnerabilidad en regiones sujetas a perturbaciones climáticas y la variación del albedo, que alteran el intercambio de energía entre la superficie y la atmósfera. Además, repercute en las tasas de evapotranspiración y el ciclo del carbono a nivel global, por la disminución en los reservorios y áreas de captura (Sala *et al.*, 2000; Lambin *et al.*, 2003). La disminución de la precipitación y el incremento de la temperatura también inciden en la vulnerabilidad de las especies forestales (Williams *et al.*, 2012). Es probable que las sequías aumenten en frecuencia e intensidad (IPCC, 2007) y posiblemente provocarán que dichos taxa modifiquen su distribución (Gómez y Arriaga, 2007) y tiendan a contraerse en sitios con climas propicios para su adaptación (Sáenz *et al.*, 2010; Rehfeldt *et al.*, 2012). Por lo cual, es importante conocer el comportamiento de esta variable bajo el contexto de cambio climático, así como identificar o pronosticar posibles cambios en estas variables a través del tiempo.

Por lo anterior, el conjunto de datos seleccionado proviene del Servicio Meteorológico Nacional en su base de datos climatológicos para la estación 01342 – Zacualtipán, Hidalgo (CONAGUA, 2019). Los datos constituyen una serie mensual de mediciones de las variables continuas de precipitación total y temperatura media, con registros anuales en el periodo 1945 - 2019. Se selecciono la estación de Zacualtipán debido a que en esa región se localiza uno de los macizos forestales más productivos del Estado de Hidalgo y se encuentra delimitado dentro de una superficie monitoreada intensivamente.

TAREA 1. Componentes de una serie de tiempo

Análisis descriptivo

El primer paso para analizar una serie de tiempo es graficarla y determinar algunos estadísticos clásicos para conocer el comportamiento y posibles tendencias en la variable. La creación de la serie de tiempo se realizó mediante la función “*ts*”. Mediante las funciones “*summary*”, “*var*” y “*sd*” se obtuvieron los valores de resumen para ambos conjuntos de datos. Los valores de asimetría y curtosis se obtuvieron mediante la librería “*moments*” y con las funciones “*skewness*” y “*kurtosis*”, respectivamente (Tabla 1).

Tabla 1. Estadística descriptiva de las variables continuas de precipitación y temperatura.

Variable	Mínimo	Media	Mediana	Máximo	Varianza	Desviación estándar	Curtosis	Asimetría
Precipitación (mm)	0.00	124.37	70.60	1501.50	23,970.89	154.8254	24.325	3.644
Temperatura (°C)	4.24	13.51	13.79	22.24	10.4854	3.2454	2.572	-0.277

En la variable de precipitación se observa una media mayor con respecto a la mediana, en conjunto con los valores de asimetría positivos, lo que sugiere una distribución asimétrica sesgada a la derecha. La simetría y la curtosis permiten conocer más sobre la forma que sigue su distribución de frecuencias, la cual se muestra mediante histogramas y su respectiva función de densidad (Figura 1 y Figura 2). Mientras que para la variable temperatura, el valor es bastante cercano a cero, aunque negativo, lo que sugiere que los datos son ligeramente sesgados hacia la izquierda.




Figura 1. Histograma de frecuencias para a) Precipitación y b) Temperatura.




Figura 2. Función de densidad para a) Precipitación y b) Temperatura.

##1. Conjunto de datos

```
rm(list=ls())
options(max.print = 10000)
setwd("C:/Users/zaira/Tarea 1-2")
```

#Precipitación

```
datos_pp<-read.csv("Precipitacion_Serie.csv",header=FALSE)
datos_pp
#Temperatura
datos_tma<-read.csv("Temperatura_Serie.csv",header=FALSE)
datos_tma
```

#Librerías

```
library(forecast)
library(tseries)
library(ggfortify)
library(TTR)
library(moments)
```

##2. Creación de la serie de tiempo

```
#Precipitación
pp_serie<-ts(datos_pp,frequency = 12,start = c(1945,1),names = "Precipitacion")
pp_serie
tma_serie<-ts(datos_tma,frequency = 12,start = c(1945,1),names = "Temperatura")
tma_serie
```

#3. Estadística descriptiva de la serie

```
par(mfrow=c(1,2),cex=0.9)
hist(pp_serie,main="a"),ylab="Frecuencia",xlab="Precipitación (mm)")
hist(tma_serie,main = "b"),ylab = "Frecuencia",xlab="Temperatura media anual (°C)")
```

```
dev.off() #650x340 px

summary(pp_serie)
summary(tma_serie)
var(pp_serie,na.rm = TRUE)
var(tma_serie,na.rm = TRUE)
sd(pp_serie,na.rm = TRUE)
sd(tma_serie,na.rm = TRUE)
kurtosis(pp_serie,na.rm = TRUE)
kurtosis(tma_serie,na.rm = TRUE)
skewness(pp_serie,na.rm = TRUE)
skewness(tma_serie,na.rm = TRUE)

#5. Gráfica de densidad de la serie
par(mfrow=c(1,2),cex=0.9)
plot(density(pp_serie,na.rm = TRUE), main = "a)")
plot(density(tma_serie,na.rm = TRUE), main = "b)")
dev.off()
```

Para obtener la gráfica de cada serie de tiempo se utilizó la función “*autoplot*” de la librería “*ggplot2*” (Figura 3 y Figura 4). Para la variable de precipitación, no se observan tendencias crecientes o decrecientes a lo largo del periodo evaluado (1945-2019) en la serie de tiempo; aparentemente el patrón que se repite cada año no es constante por lo que la serie de tiempo no es estacionaria, sin embargo, su valor promedio no parece cambiar el tiempo.




Figura 3. Serie de tiempo de la variable aleatoria de precipitación total.

Para la temperatura, esta si ha presentado fluctuaciones a través del tiempo o ciclicidad, además de estacionalidad, pues el patrón que se repite cada año es bastante similar. Posiblemente también exista un efecto estacional en ambas series de tiempo, pues el comportamiento de la serie es parecido en ciertos tiempos periódicos a través del periodo observado.




Figura 4. Serie de tiempo de la variable aleatoria de temperatura media mensual.

#4.Gráfica de series

```
plot.ts(pp_serie)
```

```
plot.ts(tma_serie)
```

```
autoplot(pp_serie, ts.colour = "dark green",xlab = "Año",ylab = "Precipitación  
(mm)")
```

```
autoplot(tma_serie, ts.colour = "brown",xlab = "Año",ylab = "Temperatura (°C)")
```

Para verificar la estacionalidad de las variables se observó la función de la autocorrelación de cada serie, mediante la función “*acf*” de la librería “*stats*”. En una serie estacionaria se espera un ACF que va a cero para cada *lag* o cambio en el tiempo. La Figura 5 y Figura 6 muestran que ambas series de tiempo no son estacionarias ya que los retrasos superan los intervalos de confianza del ACF (línea azul punteada).




Figura 5. Función de autocorrelación para la variable de precipitación.




Figura 6. Función de autocorrelación para la variable de temperatura.

#4. Gráfica de su función de autocorrelación

```
acf(pp_serie,na.action = na.pass)
acf(tma_serie,na.action = na.pass)
#Otra forma de ver la gráfica
autoplot(acf(pp_serie,na.action = na.pass))
autoplot(acf(tma_serie,na.action = na.pass))
```

Descomposición de las series de tiempo

Dado el comportamiento de la serie de tiempo, se requiere su análisis mediante la descomposición de la misma en sus componentes constituyentes: tendencia, componente aleatorio y estacionalidad. Al ser una serie no estacional, esta consta de un componente de

tendencia y un componente aleatorio, por lo cual se utilizó un método de suavizamiento por promedios móviles mediante la función “*SMA*” de la librería “*TTR*”. El valor de n indica el número de periodos para promediar.

Para la precipitación, en la Figura 7, Figura 8 y Figura 9 se muestran las series de tiempo suavizadas cuando $n = 5$, $n = 8$ y $n = 10$, respectivamente. Se observa una gran cantidad de fluctuación aleatoria y la tendencia no alcanza a apreciarse cuando $n = 5$. La tendencia es mucho más clara cuando $n = 10$. Se aprecia un aumento en las desviaciones de precipitación en los primeros veinte años.




Figura 7. Suavizamiento por promedios móviles ($n = 5$) para la variable de precipitación.




Figura 8. Suavizamiento por promedios móviles ($n = 8$) para la variable de precipitación.




Figura 9. Suavizamiento por promedios móviles ($n = 10$) para la variable de precipitación.

Para la temperatura, el suavizamiento fue considerando los mismos valores de n (Figura 10, Figura 11, Figura 12). En esta variable la tendencia y ciclicidad es mucho más notable, tanto con un valor de $n = 8$, como para $n = 10$. Por lo que se descompuso la variable con la función “*decompose*”




Figura 10. Suavizamiento por promedios móviles ($n = 5$) para la variable de temperatura.




Figura 11. Suavizamiento por promedios móviles ($n = 8$) para la variable de temperatura.




Figura 12. Suavizamiento por promedios móviles ($n = 10$) para la variable de temperatura.

La función “*decompose*” permite observar los componentes de la serie temporal: observaciones, tendencia, estacionalidad y aleatoriedad. Para la variable de temperatura (Figura 13), se aprecia una ligera tendencia ascendente en los últimos diez años de mediciones y el componente aleatorio presenta bastante ruido. De forma ilustrativa y en vista de que la variable de precipitación no es estacionaria, la gráfica de descomposición (Figura 14) muestra que esta variable presento una tendencia a incrementar en los primeros veinte años registrados, sin embargo, también se observa un patrón constante de aumentos y decrementos posiblemente en periodos de 5 años.




Figura 13. Descomposición aditiva de la serie de tiempo de temperatura.




Figura 14. Componentes para la serie de tiempo de la variable temperatura.

#6. Descomposición de la serie de tiempo

#Suavizamiento por promedios móviles

#Precipitación

```
pp_SMA5<-SMA(pp_serie,n=5)
```

```
autoplot(pp_SMA5, ts.colour = "dark green",xlab = "Año",ylab = "Precipitación (mm)")
```

```
pp_SMA8<-SMA(pp_serie,n=8)
```


```
autoplot(pp_SMA8, ts.colour = "dark green",xlab = "Año",ylab = "Precipitación (mm)")
pp_SMA10<-SMA(pp_serie,n=10)
autoplot(pp_SMA10, ts.colour = "dark green",xlab = "Año",ylab = "Precipitación (mm)")
pp_comp<-decompose(pp_serie)
plot(pp_comp)

#temperatura
tma_SMA5<-SMA(tma_serie,n=5)
autoplot(tma_SMA5, ts.colour = "brown",xlab = "Año",ylab = "Temperatura (°C)")
tma_SMA8<-SMA(tma_serie,n=8)
autoplot(tma_SMA8, ts.colour = "brown",xlab = "Año",ylab = "Temperatura (°C)")
tma_SMA10<-SMA(tma_serie,n=10)
autoplot(tma_SMA10, ts.colour = "brown",xlab = "Año",ylab = "Temperatura (°C)")

#7. Descomposición aditiva de una serie
#Temperatura
tma_comp<-decompose(tma_serie)
plot(tma_comp,cex=0.9)
#Precipitación (únicamente ilustrativa - serie no estacionaria)
#Temperatura
pp_comp<-decompose(pp_serie)
plot(pp_comp,cex=0.9)
```

Reconstrucción de una serie

La reconstrucción de una serie en función de sus componentes se realizó únicamente para la variable temperatura, aunque de forma ilustrativa dado el comportamiento de la variable (Ver código en R). Esta reconstrucción puede realizarse de forma aditiva o multiplicativa, al sumar o multiplicar la estacionariedad, la tendencia y el componente aleatorio. Debido a la naturaleza de la serie de tiempo, el gráfico de comparación entre la serie original y la serie reconstruida muestra un ajuste exacto. La remoción de componentes se muestra en el código de R.



##8. Reconstrucción de una serie en función de sus componentes

#Temperatura

```
x_tma<-tma_comp$x           # Datos originales
seasonal_tma<-tma_comp$seasonal # valores estimados de estacionalidad
trend_tma<-tma_comp$trend    # valores estimados de tendencia
random_tma<-tma_comp$random  # valores estimados de aleatoriedad

tma_est<-seasonal_tma+trend_tma+random_tma
tma_est_ts<-ts(tma_est,frequency = 12,start = c(1945,1),names = "Temperatura
Est")
autoplot(tma_est_ts, ts.colour = "brown",xlab = "Año",ylab = "Temperatura (°C)")

#Grafica de x: serie original v.s. y: estimación con modelo aditivo
plot.ts(tma_serie,tma_est_ts,xlab="TMA original",ylab="TMA estimación")
both<-cbind(tma_serie,tma_est_ts)
```

#Gráfica de ambas series

```
plot.ts(both,plot.type = c("multiple", "single"), col="green")
plot.ts(both)
```

9. Remoción de componentes

```
tma_adjust <- tma_serie - seasonal_tma
plot(tma_adjust)
tma_adjust <- tma_serie - trend_tma
plot(tma_adjust)
tma_adjust2 <- tma_serie - (trend_tma + random_tma)
plot(tma_adjust2)
```

#10. Descomposición con modelo multiplicativo

```
#  $Y[t] = T[t] * S[t] * e[t]$ 
tma_mult_components <- decompose(tma_serie,
                                type = c("multiplicative"))

x_tma_mult<-tma_mult_components$x
seasonal_tma_mult<-tma_mult_components$seasonal
trend_tma_mult<-tma_mult_components$trend
random_tma_mult<-tma_mult_components$random
figure_tma_mult<-tma_mult_components$figure
```

```

type_tma_mult<-tma_mult_components$type

tma_seasonal2<-x_tma_mult/seasonal_tma_mult
plot(tma_seasonal2)
tma_trend2<-x_tma_mult/trend_tma_mult
plot(tma_trend2)

tma_random2<-x_tma_mult/(seasonal_tma_mult*trend_tma_mult)
plot(tma_random2)

```

Comparación entre años

La comparación entre años permite identificar variaciones mensuales entre los diferentes años evaluados e identificar visualmente posibles tendencias por periodicidad. Las librerías utilizadas fueron “TSstudio” y “ggplot2”. Para la variable de precipitación (Figura 15), se observan mayores precipitaciones en los meses de agosto a noviembre, sin embargo, es notable que el primer periodo de lluvias entre mayo y julio ha disminuido notablemente en los años más recientes. Asimismo, es notable como la precipitación total máxima ha disminuido también. Por otra parte, la temperatura parece mantener el mismo patrón, aunque las temperaturas han incrementado aproximadamente 2°C en los últimos veinte años (Figura 16).




Figura 15. Comparación mensual de la precipitación en el periodo 1945 - 2019.




Figura 16. Comparación mensual de la temperatura en el periodo 1945 - 2019.

11. Comparación entre años (normal), Identificación de tendencias (cycle), box plots (box) y todos juntos # Visualize time series object by it periodicity,

```
library(TSstudio)
library(ggplot2)
```

#Temperatura

```
ts_seasonal(tma_serie,type="normal") # Comparacion entre años
ts_seasonal(tma_serie,type="cycle") # Para detectar ciclos o tendencias
ts_seasonal(tma_serie,type="box") # Box plots por mes
ts_seasonal(tma_serie,type="all") # Todos en una gráfica
```

#Precipitación

```
ts_seasonal(pp_serie,type="normal") # Comparacion entre años
ts_seasonal(pp_serie,type="cycle") # Para detectar ciclos o tendencias
ts_seasonal(pp_serie,type="box") # Box plots por mes
ts_seasonal(pp_serie,type="all") # Todos en una gráfica
```

TAREA 2: Cambios estructurales de una serie de tiempo

La detección de cambios estructurales en las relaciones de regresión lineal es de especial interés en el análisis de series de tiempo, pues permite analizar nuevas observaciones y detectar cambios en los parámetros de un modelo dinámico tan pronto sea posible posteriores a su ocurrencia y que no son estables a través del periodo evaluado (Kleiber y Zeileis, 2008). La construcción de modelos lineales puede permitir incorporar los cambios estructurales y verificar que los residuales representen ruido blanco o en su defecto, alguna estructura no identificada en la serie.

Identificación de cambios de nivel

El análisis de cambios estructurales se realizó únicamente para la variable de temperatura. Los breaks o puntos de corte minimizan la suma de cuadrados residuales asociadas a un modelo con $m + 1$ segmentos, dado un tamaño mínimo de segmento de $h \times n$ observaciones, por lo cual es necesario calcular el número de breaks óptimos, el ancho de banda y elegir el modelo que minimiza el criterio de información BIC. Este procedimiento se realiza con la librería *strucchange*.

El ancho de banda es una ventana que toma el porcentaje de los puntos para calcular los segmentos de ajuste de los modelos, generalmente es alrededor del 10 al 15% ($h = 0.1$). Se realizó el suavizamiento de la serie de tiempo, con un valor de $\text{span} = 0.1$. En la Figura 17 se aprecian cambios en la temperatura por periodos aproximados de diez o doce años.




Figura 17. Señal de la serie de tiempo de temperatura media.

Posteriormente se ajusto un modelo con intercepto a toda la serie (1). Se obtuvo el siguiente resumen:

```
> #Identificación de cambio de nivel #Modelo lineal  
  
> summary(lm(tma_serie ~ 1))  
  
Call:  
lm(formula = tma_serie ~ 1)  
  
Residuals:  
    Min       1Q   Median       3Q      Max   
-9.2693 -2.3145  0.2858  2.4158  8.7298  
  
Coefficients:  
            Estimate Std. Error t value Pr(>|t|)      
(Intercept) 13.5112     0.1079   125.2  <2e-16 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
  
Residual standard error: 3.238 on 899 degrees of freedom  
  
# 7. Gráfica de la serie y del intercepto  
  
plot(tma_serie,col="light gray")  
lines(fit, col = "purple")  
grid()
```

El valor promedio fue altamente significativo y con un valor estimado de 13.511 °C. La gráfica obtenida se muestra en la Figura 18.




Figura 18. Serie de tiempo de temperatura media (color gris claro) y línea de ajuste de modelo lineal (púrpura).

los cambios de nivel fueron identificados con la función “*breakpoints*” de la librería “*strucchange*”. Se utilizó un porcentaje de observaciones $h = 0.1$. La gráfica obtenida muestra los cambios de nivel en el modelo ajustado. Se espera que la suma de cuadrados para cada break sea lo menor posible. La suma de cuadrados RSS más pequeña es con un número de breaks entre 6 y 7, sin embargo, el criterio BIC sugiere que el valor óptimo de breaks igual a 6.




Figura 19. Suma de cuadrados de residuales y Criterio de Información Bayesiano (BIC) para cambios de nivel.

Una vez establecido el número de breaks óptimos, se obtuvo la gráfica con sus respectivos intervalos de confianza. Los intervalos de cambio en la temperatura media son obtenidos a partir de la función “*coef*”. El periodo de cambio más largo fue de 1977 a 1994.




Figura 20. Gráfica de segmentos (breaks = 6) para cambios de nivel en la serie de tiempo de temperatura.

8. Identificación de cambios estructurales de nivel

```
> temp_brk <-breakpoints(tma_serie ~ 1, h = 0.1)
> summary(temp_brk)
```

Optimal (m+1)-segment partition:

Call:

```
breakpoints.formula(formula = tma_serie ~ 1, h = 0.1)
```

Breakpoints at observation number:

```
m = 1          579
m = 2      225    386
m = 3      225    386    590
m = 4    90 225    386    590
m = 5    90 225    386    590    810
m = 6    90 225    386    590 718 808
m = 7    90 225    386 495 590 718 808
m = 8    90 201 296 386 495 590 718 808
```

Corresponding to breakdates:

```
m = 1          1993(3)
m = 2      1963(9)    1977(2)
m = 3      1963(9)    1977(2)    1994(2)
m = 4    1952(6) 1963(9)    1977(2)    1994(2)
m = 5    1952(6) 1963(9)    1977(2)    1994(2)
m = 6    1952(6) 1963(9)    1977(2)    1994(2) 2004(10)
m = 7    1952(6) 1963(9)    1977(2) 1986(3) 1994(2) 2004(10)
m = 8    1952(6) 1961(9) 1969(8) 1977(2) 1986(3) 1994(2) 2004(10)
```

```
m = 1
m = 2
m = 3
m = 4
m = 5    2012(6)
m = 6    2012(4)
m = 7    2012(4)
m = 8    2012(4)
```

Fit:

```
m    0    1    2    3    4    5    6    7    8
RSS 9426 7898 6852 6499 6334 6175 6011 6010 6170
BIC 4682 4536 4422 4388 4378 4369 4358 4372 4409
> plot(temp_brk)
```

```
> # Serie, cambios de nivel e intervalos de confianza de los cambios de nivel
```

```
> plot(tma_serie,col="light gray")
> lines(fitted(temp_brk, breaks = 6), col = "red")
```

```
> lines(confint(temp_brk, breaks = 6))
> coef(temp_brk, breaks = 6)
      (Intercept)
1945(1) - 1952(6)    14.46385
1952(7) - 1963(9)    12.71557
1963(10) - 1977(2)    10.05566
1977(3) - 1994(2)     13.61465
1994(3) - 2004(10)    15.57237
2004(11) - 2012(4)    13.80743
2012(5) - 2019(12)    16.40755
```

🚦 Identificación de cambios de tendencia

Para identificar cambios de tendencia nuevamente se ajusto el modelo, incorporando el tiempo en el ajuste lineal en lugar del intercepto. En términos generales, el intercepto es significativo, con una pendiente de 0.004095, lo que indica el cambio mensual de temperatura a lo largo de un año.

> #9. Identificación de cambios de tendencia.

```
> #Ajuste de un modelo de regresión lineal
> l <- length(tma_serie)
> tt <- 1:l
> trend_fit <- lm(tma_serie ~ tt)
> summary(trend_fit)

Call:
lm(formula = tma_serie ~ tt)

Residuals:
    Min       1Q   Median       3Q      Max
-8.489 -2.295  0.348  2.202  7.914

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.167e+01  2.042e-01  57.14  <2e-16 ***
tt           4.095e-03  3.926e-04  10.43  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.06 on 898 degrees of freedom
Multiple R-squared:  0.1081,    Adjusted R-squared:  0.1071
F-statistic: 108.8 on 1 and 898 DF,  p-value: < 2.2e-16

> plot(tma_serie,col="light gray")
> lines(ts(fitted(trend_fit), start=1945, frequency = 1), col = 4)
```

El número de breaks óptimos para la detección de cambios en la tendencia fue de 5 (Figura 21).




Figura 21. Suma de cuadrados de residuales y Criterio de Información Bayesiano (BIC) para cambios de tendencia.

En la se observa que los periodos más largos de cambios en la tendencia de la temperatura media fueron, a) en el periodo de 1977 a 1994, con un valor de intercepto y pendiente de 13.82586 y 0.0004323715, respectivamente; b) en el periodo 1994 – 2010, con un valor de 22.08238 en su intercepto y una pendiente igual a -0.0101693813.




Figura 22. Gráfica de segmentos (breaks =5) para cambios de tendencia en la serie de tiempo de temperatura.

> # Breaks óptimos. Cambios en tendencia

```
> temp_brk_trend <- breakpoints(tma_serie ~ tt, h = 0.1)
> summary(temp_brk_trend)
```

Optimal (m+1)-segment partition:

Call:

```
breakpoints.formula(formula = tma_serie ~ tt, h = 0.1)
```

Breakpoints at observation number:

m = 1		386			
m = 2		386		765	
m = 3		386	590	789	
m = 4	122 225	386		765	
m = 5	122 225	386	590	789	
m = 6	122 225	386	590 686 807		
m = 7	122 225	386 495 590 686 807			
m = 8	92 183 279 386 495 590 686 807				

Corresponding to breakdates:

m = 1			1977(2)		
m = 2			1977(2)		
m = 3			1977(2)	1994(2)	
m = 4	1955(2) 1963(9)		1977(2)		
m = 5	1955(2) 1963(9)		1977(2)	1994(2)	
m = 6	1955(2) 1963(9)		1977(2)	1994(2) 2002(2)	
m = 7	1955(2) 1963(9)		1977(2) 1986(3) 1994(2) 2002(2)		
m = 8	1952(8) 1960(3) 1968(3)	1977(2) 1986(3) 1994(2) 2002(2)			

m = 1	
m = 2	2008(9)
m = 3	2010(9)
m = 4	2008(9)
m = 5	2010(9)
m = 6	2012(3)
m = 7	2012(3)
m = 8	2012(3)

Fit:

m	0	1	2	3	4	5	6	7	8
RSS	8408	6510	6159	6009	5885	5736	5673	5666	5692
BIC	4586	4376	4346	4345	4346	4343	4354	4373	4398

Gráfica del modelo de regresión lineal. Es significativa la tendencia

```
plot(tma_serie,col="light gray")
lines(ts(fitted(trend_fit), start=1945, frequency = 1), col = 4)
```

Breaks óptimos.

```
temp_brk_trend <- breakpoints(tma_serie ~ tt, h = 0.1)
```



```
summary(temp_brk_trend)
plot(temp_brk_trend) #The BIC indica 5 breaks
```

> # Interceptos y pendientes de los cambios estructurales de tendencia

```
> breakdates(temp_brk_trend, breaks = 5)
[1] 1955.083 1963.667 1977.083 1994.083 2010.667
> coef(temp_brk_trend, breaks = 5)
              (Intercept)              tt
1945(1) - 1955(2)      16.30432 -0.0407716768
1955(3) - 1963(9)      12.27508  0.0039503196
1963(10) - 1977(2)     10.01753  0.0001246130
1977(3) - 1994(2)      13.82586 -0.0004323715
1994(3) - 2010(9)      22.08238 -0.0101693813
2010(10) - 2019(12)    -32.45945  0.0570434407
```

> # Gráfica de los cambios estructurales en tendencia

```
> plot(tma_serie,col="light gray")
> lines(fitted(temp_brk_trend, breaks = 5), col = "red")
> lines(confint(temp_brk_trend, breaks = 5))
```

Ajuste de un modelo cuadrático

Se ajustó un modelo cuadrático para analizar nuevamente los cambios de nivel. El modelo mostró que el tiempo es significativo. La gráfica de breaks óptimos sugiere un valor de BIC igual a 3 (Figura 23). La Figura 24 muestra un mejor ajuste a la serie de tiempo de temperatura. El periodo más largo fue de 1977 a 2004.




Figura 23. Suma de cuadrados de residuales y Criterio de Información Bayesiano (BIC) para cambios de nivel en el modelo cuadrático de temperatura.




Figura 24. Gráfica de segmentos (breaks =3) para cambios de nivel en la serie de tiempo de temperatura con modelo cuadrático.

> ##10. Ajuste de un modelo cuadrático

```
> cuadr_fit <- lm(tma_serie ~ tt + I(tt^2))
> summary(cuadr_fit)
```

Call:

```
lm(formula = tma_serie ~ tt + I(tt^2))
```

Residuals:

Min	1Q	Median	3Q	Max
-8.0720	-2.0883	0.2708	2.2772	7.8665

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.382e+01	2.913e-01	47.442	< 2e-16 ***
tt	-1.023e-02	1.493e-03	-6.853	1.35e-11 ***
I(tt^2)	1.590e-05	1.605e-06	9.909	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.907 on 897 degrees of freedom

Multiple R-squared: 0.1961, Adjusted R-squared: 0.1943

F-statistic: 109.4 on 2 and 897 DF, p-value: < 2.2e-16

> # En busca de cambios estructurales cuadráticos

```
> temp_brk_cuadratico <- breakpoints(tma_serie ~ tt + I(tt^2), data = datos_tma,
h = 0.1)
> summary(temp_brk_cuadratico)
```

Optimal (m+1)-segment partition:

Call:

```
breakpoints.formula(formula = tma_serie ~ tt + I(tt^2), h = 0.1,
data = datos_tma)
```

Breakpoints at observation number:

```

m = 1          386
m = 2          386          718
m = 3      225    386          718
m = 4      225    386      590      801
m = 5      225    386      590 706 801
m = 6   98 225    386      590 706 801
m = 7   98 225    386 490 590 706 801
m = 8   98 188 279 386 490 590 706 801

```

Corresponding to breakdates:

```

m = 1          1977(2)
m = 2          1977(2)          2004(10)
m = 3      1963(9)          1977(2)          2004(10)
m = 4      1963(9)          1977(2)          1994(2)          2011(9)
m = 5      1963(9)          1977(2)          1994(2) 2003(10) 2011(9)
m = 6  1953(2) 1963(9)          1977(2)          1994(2) 2003(10) 2011(9)
m = 7  1953(2) 1963(9)          1977(2) 1985(10) 1994(2) 2003(10) 2011(9)
m = 8  1953(2) 1960(8) 1968(3) 1977(2) 1985(10) 1994(2) 2003(10) 2011(9)

```

Fit:

```

m   0    1    2    3    4    5    6    7    8
RSS 7578 6467 6090 5878 5732 5659 5588 5573 5568
BIC 4499 4383 4356 4352 4356 4372 4388 4413 4439
> plot(temp_brk_cuadratico)

```

```

# El mínimo valor de BIC se alcanza en m=3
> plot(tma_serie, col="light gray")
> lines(fitted(temp_brk_cuadratico, breaks = 3), col = "red")
> lines(confint(temp_brk_cuadratico, breaks = 3))

```

Conclusión

Una serie temporal es una sucesión de observaciones de una variable de interés tomadas en varios instantes de tiempo. El análisis de las series de tiempo es importante para conocer el comportamiento de una variable a través del tiempo; además, permite modelar y predecir cambios a futuro. Las series de tiempo generalmente se representan con gráficos temporales y se clasifican en series estacionarias (donde la media y la variabilidad se mantienen constantes) y en no estacionarias (si cambian a lo largo del tiempo). Las series no estacionarias, como la temperatura, muestran cambios de varianza, pueden también mostrar tendencias o incluso, efectos estacionales.

 Referencias

- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., Ljung, G. M., 2016. *Time Series Analysis. Forecasting and Control*. Wiley Series in Probability and Statistics. Fifth Edition. Canada, 1-3 pp.
- Cryer, J. D., Chan, K.S., 2008. *Time Series Analysis. With Applications in R*. Springer Science and Business Media. Second Edition. New York, 1-3 pp.
- Comisión Nacional del Agua (CONAGUA), 2019. Proyecto de bases de datos climatológicos de la estación Zacualtipán, Hidalgo. Disponible en: <https://smn.conagua.gob.mx/tools/RESOURCES/Mensuales/hgo/00013042.TXT>
- Intergovernmental Panel on Climate Change (IPCC), 2007. *Climate Change 2007: The physical science basis. Contribution of the Working Group as part of the Intergovernmental Panel on Climate Change*. In: Solomon, S., D. Qin, M. Manning, Z. Chen, M. Marquis, K. B. Averyt, M. Tignor and H. L. Miller (eds). Cambridge University Press, Cambridge, UK and Cambridge University Press. New York, NY, USA. 996 p.
- Kleiber, C., Zeileis, A., 2008. *Applied Econometrics with R*. Springer. 174-185 pp.
- Lambin, E., Geist H., Lepers, E., 2003. Dynamics of land-use and land-cover change in tropical regions. *Annual Review of Environment and Resources* 28, 2005-241.
- Sala, O., Chapin, F., Armesto, J., Berlow, E., Bloomfield, J., Dirzo, R., Huber-Sanwald, E., Huenneke, L., Jackson, R., Kinzig, A., Leemans, R., Lodge, D., Mooney, H., Oesterheld, M., Poff, N., Sykes, M., Walker, B., Walker, M., Wall, D., 2000. Global biodiversity scenarios for the year 2100. *Science* 287, 1770-1774.