



COLEGIO DE POSTGRADUADOS

COLEGIO DE POSTGRADUADOS
INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS
AGRÍCOLAS
CAMPUS MONTECILLO
PROGRAMA DE POSTGRADO EN CIENCIAS FORESTALES

TAREA 3.

SIMULACIÓN DE PROCESOS ESTACIONARIOS

EST-624. Series de tiempo
Dra. Marta Elva Ramírez Guzmán

Zaira Rosario Perez Vazquez
01 de febrero de 2021

Introducción

El término ARIMA significa “media móvil integrada autoregresiva”. Un modelo ARIMA no estacional se clasifica como un modelo “ARIMA (d, p, q), donde “p” es el número de términos autorregresivos, “d” es el número de diferencias no estacionales necesarias para la estacionariedad, y “q” es el número de errores de pronóstico rezagados en la ecuación de predicción. Box, Jenkins y Reinsel (1994) desarrollaron una metodología sistemática que combina el promedio móvil y el enfoque autorregresivo para identificar y estimar modelos de series temporales.

Un modelo autorregresivo (AR) es una regresión lineal del valor actual de la serie contra uno o más valores anteriores de la misma. El valor de p se llama el orden del modelo AR. Estos modelos se pueden analizar con uno o varios métodos, como la de mínimos cuadrados lineales, además, tienen una interpretación directa.

Un modelo de promedio móvil (AM) es una regresión lineal del valor actual de la serie contra el ruido blanco de uno o más valores anteriores de la serie. Bajo el supuesto de que este ruido blanco proviene de la misma distribución (generalmente normal), con una esperanza en cero y varianza constante. Sin embargo, ajustar las estimaciones de MA es más complicado que con los modelos AR debido a que los términos de error no son observables.

El modelo ARMA de Box-Jenkins es una combinación de los modelos AR y MA. Para realizar un buen ajuste se requiere de una serie de tiempo con más de 50 datos. Para desarrollar estos modelos se requiere el cumplimiento de dos supuestos principalmente: a) los datos deben ser estacionarios, es decir, que las propiedades de la serie no dependen del momento en que se capturan), y b) los datos deben ser univariados (la regresión únicamente considera los valores pasados de la misma variable de interés).

Simulación de un proceso estacionario

Se simularon, mediante la función “*arima.sim*” de la librería “*stats*”, algunas observaciones aleatorias para dos procesos de series de tiempo AR, MA y ARIMA. Antes de generar la simulación se estableció un valor fijo de semilla con la función “*set.seed*”.

Simulación autorregresiva (AR)

Para el primer modelo autorregresivo AR de orden 1 (1, 0, 0) se utilizó un valor de $\Phi = 0.8$ con 1,000 observaciones. Para el segundo modelo, se definió un valor de $\Phi = 0.9$ con 100 observaciones. Para graficar la serie se utilizó la función “*autoplot*” de la librería “*ggfortify*” y “*ggarrange*” de la librería “*ggpubr*” (Figura 1).




Figura 1. Simulación autorregresiva AR (1) con parámetros: A) $\Phi = 0.8$ y $n = 1,000$ observaciones; B) $\Phi = 0.9$ y $n = 100$ observaciones.

R code:

```
###2. Simulación de un proceso estacionario
set.seed(98765)
?arima.sim

##Simulación AR(1)
Sim1_AR<-arima.sim(list(order=c(1,0,0),ar=0.8),n=1000)
Sim2_AR<-arima.sim(list(order=c(1,0,0),ar=0.9),n=100)
```

R code:

```
#Gráfica de las simulaciones AR(1)
Fig1_AR_S1<-autoplot(Sim1_AR, ts.colour = "dark blue",xlab = "Tiempo",ylab = "x")
Fig1_AR_S2<-autoplot(Sim2_AR, ts.colour = "brown",xlab = "Tiempo",ylab = "x")
ggarrange(Fig1_AR_S1, Fig1_AR_S2, ncol = 1, nrow = 2, labels = c("A", "B"))
```

Simulación de promedios móviles

Para el primer modelo de promedios móviles AM de orden 1 (0, 0, 1) se utilizó un valor de $\theta = 0.7$ con 1,000 observaciones. Para el segundo modelo, se definió un valor de $\theta = -0.5$ con 100 observaciones. Para graficar la serie se utilizó la función “*autoplot*” de la librería “*ggfortify*” y “*ggarrange*” de la librería “*ggpubr*” (Figura 2).




Figura 2. Simulación con promedios móviles MA (1) con parámetros: A) $\theta = 0.7$ y $n = 1,000$ observaciones; B) $\theta = -0.5$ y $n = 100$ observaciones.

R code:

```
##Simulación MA
Sim3_MA<-arima.sim(list(order=c(0,0,1),ma=0.7),n=1000)
Sim4_MA<-arima.sim(list(order=c(0,0,1),ma=-0.5),n=100)

#Gráfica de las simulaciones MA(1)
Fig2_MA_S1<-autoplot(Sim3_MA, ts.colour = "dark blue",xlab = "Tiempo",ylab = "x")

Fig2_MA_S2<-autoplot(Sim4_MA, ts.colour = "brown",xlab = "Tiempo",ylab = "x")
```

R code:

```
ggarrange(Fig2_MA_S1,Fig2_MA_S2,ncol = 1, nrow = 2,labels = c("A","B"))
```

Simulación autorregresiva y de promedios móviles

Para esta simulación, se utilizaron los valores de AR y MA anteriores (1, 0, 1), correspondientes con el número de observaciones definidas. Para el primer modelo, se definió un valor $\Phi = 0.8$ y $\theta = 0.7$ con 1,000 observaciones. Para el segundo modelo, los parámetros fueron $\Phi = 0.9$ y $\theta = -0.5$, con 100 observaciones. Para graficar la serie se utilizó la función “autoplot” y “ggarrange” (Figura 3).




Figura 3. Simulación ARMA (1, 0, 1) con parámetros: A) $\Phi = 0.8$, $\theta = 0.7$ y $n = 1,000$ observaciones; B) $\Phi = 0.9$, $\theta = -0.5$ y $n = 100$ observaciones.

R code:

```
##Simulación ARMA(1,0,1)
Sim5_ARMA<-arima.sim(list(order=c(1,0,1),ar=0.8,ma=0.7),n=1000)
Sim6_ARMA<-arima.sim(list(order=c(1,0,1),ar=0.9,ma=-0.5),n=100)
#Gráfica de las simulaciones ARMA(1,0,1)
Fig3_ARMA_S1<-autoplot(Sim5_ARMA, ts.colour = "dark blue",xlab = "Tiempo",ylab = "x")
Fig3_ARMA_S2<-autoplot(Sim6_ARMA, ts.colour = "brown",xlab = "Tiempo",ylab = "x")
ggarrange(Fig3_ARMA_S1,Fig3_ARMA_S2,ncol = 1, nrow = 2,labels = c("A","B"))
```

Identificación del modelo

En la identificación del modelo se evalúa si la serie cumple el supuesto de estacionariedad en media y varianza. De esta forma se observa si la serie de tiempo parece variar alrededor de un nivel fijo. La función de autocorrelación “*acf*” proporciona la autocorrelación en todos los retrasos posibles. La autocorrelación en el retraso 0 se incluye por defecto y siempre toma el valor 1, pues representa la correlación entre los datos y ellos mismos. La función de autocorrelación “*pacf*” en el rezago k es una función de autocorrelación que describe entre todos los puntos de datos que son exactamente k retrasos, después de tener en cuenta su correlación con los datos entre esos k retrasos. Esta función permite, a grandes rasgos, identificar el número de coeficientes de autorregresión (AR) (valor de p) en un modelo ARIMA.

Modelos autorregresivos.

Se observa en la Figura 4 que la autocorrelación continúa disminuyendo a medida que aumenta el retraso, lo que indica que no existe una asociación lineal entre las observaciones separadas por retrasos más grandes. La función de autocorrelación parcial presenta solo un pico significativo superior a los intervalos de confianza ($p = 1$).




Figura 4. Función ACF y PACF de las simulaciones autorregresivas AR (1) con parámetros: A) $\Phi = 0.8$ y $n = 1,000$ observaciones; B) $\Phi = 0.9$ y $n = 100$ observaciones.

```

###3. Identificación del modelo

##Autorregresivo AR(1)
#ACF y PACF
par(mfrow=c(2,2),cex=0.6)
#Sim1_AR
acf(Sim1_AR,main=(expression(ACF: AR(1)~~~phi==0.8)),ylim=c(-0.1,1.1))
pacf(Sim1_AR,main=(expression(PACF: AR(1)~~~phi==0.8)),ylim=c(-0.1,1.1))
#Sim2_AR
acf(Sim2_AR,main=(expression(ACF: AR(1)~~~phi==0.9)),ylim=c(-0.4,1.1))
pacf(Sim2_AR,main=(expression(PACF: AR(1)~~~phi==0.9)),ylim=c(-0.1,1.1))
dev.off()

```

Modelos de promedios móviles.

En la Figura 5 se observa en la que la autocorrelación presenta dos picos significativos, el primero es 1 derivado de su correlación entre los mismos valores, y el segundo pico indican el primer retardo. La función de autocorrelación parcial presenta varios picos por encima de los intervalos de confianza y tiende a infinito pues continúa disminuyendo a medida que aumenta el retraso ($q = 1$).




Figura 5. Función ACF y PACF de las simulaciones con promedios móviles MA (1) con parámetros: A) $\theta = 0.7$ y $n = 1,000$ observaciones; B) $\theta = -0.5$ y $n = 100$ observaciones.

```
##Promedios móviles AM(1)
par(mfrow=c(2,2),cex=0.6)
#Sim3_MA
acf(Sim3_MA,main=(expression(ACF: MA(1)~~~theta==0.7)))
pacf(Sim3_MA,main=(expression(PACF: MA(1)~~~theta==0.7)))
#Sim4_MA
acf(Sim4_MA,main=(expression(ACF: MA(1)~~~theta==0.5)))
pacf(Sim4_MA,main=(expression(PACF: MA(1)~~~theta==0.5)))
dev.off()
```

Modelos de autorregresión y promedios móviles

En este tipo de modelos, tanto la función de autocorrelación como la función de autocorrelación parcial presentan picos significativos que sobrepasan los intervalos de confianza (Figura 6). En la primera simulación, se observa que la función ACF tiende a disminuir a medida que el número de retrasos incrementa, mientras que la función PACF presenta cuatro picos significativos. En la segunda simulación, la función de autocorrelación comienza a disminuir a partir de un retraso cercano a 10, mientras que la función PAC solo presenta un pico significativo.




Figura 6. Función ACF y PACF de las simulaciones con ARMA (1, 0, 1) con parámetros: A) $\Phi = 0.8$, $\theta = 0.7$ y $n = 1,000$ observaciones; B) $\Phi = 0.9$, $\theta = -0.5$ y $n = 100$ observaciones.

R code:

```
##ARMA (1,0,1)
par(mfrow=c(2,2),cex=0.6)
#Sim5_ARMA
acf(Sim5_ARMA,main=(expression(ACF: ARMA(1,0,1)~~~phi==0.8~~~theta==0.7)))
pacf(Sim5_ARMA,main=(expression(PACF: ARMA(1,0,1)~~~phi==0.8~~~theta==0.7)))
#Sim6_ARMA
acf(Sim6_ARMA,main=(expression(ACF: ARMA(1,0,1)~~~phi==0.9~~~theta==-0.5)))
pacf(Sim6_ARMA,main=(expression(PACF: ARMA(1,0,1)~~~phi==0.9~~~theta==-0.5)))
dev.off()
```

Ajuste del modelo

El ajuste del modelo se obtuvo con la función “*arima*” de la librería “*stats*”, la cual ajusta un modelo ARIMA a una serie temporal univariante.

Modelos autorregresivos

En la primera simulación, el valor del coeficiente obtenido fue de 0.79, bastante cercano al valor establecido de $\Phi = 0.8$, con un intercepto igual a 0.1084. En la segunda simulación, el valor del coeficiente obtenido fue de 0.8441 y un intercepto igual a 1.2171. En este caso, el valor no es tan cercano al valor establecido de $\Phi = 0.9$, en comparación con la primera simulación, lo cual se ve reflejado con un error estándar ligeramente mayor. Esto puede ser un efecto de la menor cantidad de observaciones definidas en la simulación con respecto a la primera.

R code:

```
> ?arima

# Sim1_AR
> arima(Sim1_AR,order=c(1,0,0))

Call:
arima(x = Sim1_AR, order = c(1, 0, 0))

Coefficients:
      ar1  intercept 
 0.7991    0.1084 
s.e. 0.0192    0.1577 

sigma^2 estimated as 1.012:  log likelihood = -1425.27,  aic = 2856.55
```

R code:

```
# Sim2_AR
> arima(Sim2_AR,order=c(1,0,0))

Call:
arima(x = Sim2_AR, order = c(1, 0, 0))

Coefficients:
      ar1  intercept
    0.8441    1.2171
s.e.  0.0556    0.5814

sigma^2 estimated as 0.9055:  log likelihood = -137.55,  aic = 281.1
```

Modelos de promedios móviles

En la primera simulación, el coeficiente obtenido fue ligeramente superior al valor establecido de $\theta = 0.7$, con un valor de 0.7243 y un intercepto igual a 0.0155. Por el contrario, para la segunda simulación, el coeficiente obtenido fue ligeramente inferior al valor establecido de $\theta = -0.5$, con un valor de -0.4804 y un intercepto igual a -0.0295.

R code:

```
> #Sim3_MA
> arima(Sim3_MA,order=c(0,0,1))

Call:
arima(x = Sim3_MA, order = c(0, 0, 1))

Coefficients:
      ma1  intercept
    0.7243    0.0155
s.e.  0.0221    0.0548

sigma^2 estimated as 1.011:  log likelihood = -1424.71,  aic = 2855.42

> #Sim4_MA
> arima(Sim4_MA,order=c(0,0,1))

Call:
arima(x = Sim4_MA, order = c(0, 0, 1))

Coefficients:
      ma1  intercept
   -0.4804   -0.0295
s.e.  0.0807    0.0494

sigma^2 estimated as 0.8853:  log likelihood = -135.93,  aic = 277.87
```

Modelos de autorregresión y promedios móviles

En la primera simulación, se obtuvo un coeficiente para la parte regresiva de 0.7923, muy cercano al valor establecido de $\Phi = 0.8$; el coeficiente de promedios móviles fue de 0.7064, valor bastante cercano al establecido $\theta = 0.7$, con un valor de intercepto de 0.2231. En la segunda simulación, el error estándar fue mayor en comparación con la primera simulación. Se obtuvo un valor del intercepto de -0.2962, el coeficiente regresivo fue de 0.7664, inferior al establecido en $\Phi = 0.9$; el coeficiente de promedios móviles fue de -0.3673, nuevamente el valor se encuentra alejado del establecido en $\theta = -0.5$.

R code:

```
> #Sim5_ARMA
> arima(Sim5_ARMA,order=c(1,0,1))

Call:
arima(x = Sim5_ARMA, order = c(1, 0, 1))

Coefficients:
      ar1      ma1  intercept
    0.7923  0.7064     0.2231
s.e.  0.0203  0.0241     0.2589

sigma^2 estimated as 1.001:  log likelihood = -1420.95,  aic = 2849.91

> #Sim6_ARMA
> arima(Sim6_ARMA,order=c(1,0,1))

Call:
arima(x = Sim6_ARMA, order = c(1, 0, 1))

Coefficients:
      ar1      ma1  intercept
    0.7664 -0.3673    -0.2962
s.e.  0.1250  0.1915     0.2694

sigma^2 estimated as 1.039:  log likelihood = -143.98,  aic = 295.97
```

Diagnóstico del modelo

El diagnóstico del modelo se realizó mediante la comparación del criterio de información de akaike (AIC) y el criterio de información bayesiano (BIC). Los modelos fueron nuevamente ajustados eliminando el intercepto y guardando cada uno en un objeto para facilitar la obtención de AIC y BIC. En la Tabla 1 se muestran los valores de AIC y BIC obtenidos para

cada simulación. Se observa que los mejores modelos ajustados para cada simulación fueron aquellos que no consideraron el intercepto en el ajuste del modelo.

Tabla 1. Valores de AIC y BIC obtenidos para las simulaciones AR, MA y ARMA, derivados del ajuste del modelo con y sin intercepto.

	Autorregresivo (AR)		Promedios móviles (MA)		ARMA	
Simulación (S)	AIC	BIC	AIC	BIC	AIC	BIC
Simulación 1						
S1: Con intercepto	2856.547	2871.271	2855.42	2870.144	2849.909	2869.54
S1: Sin intercepto	2855.019	2864.834	2853.501	2863.317	2848.648	2863.371
Simulación 2						
S2: Con intercepto	281.1035	288.919	277.8658	285.6813	295.9691	306.3898
S2: Sin intercepto	282.237	287.4474	276.219	281.4294	295.0162	302.8317

Finalmente, para observar el comportamiento de los residuales, se obtuvieron a partir de la función “*ggtsdiag*” de la librería “*ggfortify*”, las gráficas de los modelos ARIMA con mejor ajuste, es decir, aquellos que fueron ajustados sin considerar al intercepto. Las Figura 7, Figura 8 y Figura 9 muestran los correlogramas obtenidos para cada uno de los modelos con 1,000 observaciones. Se observa que no existe ningún rezago significativo por lo que podemos decir que los residuales son ruido blanco.




Figura 7. Correlograma del primer modelo autorregresivo sin intercepto.




Figura 8. Correlograma del primer modelo de promedios móviles sin intercepto.




Figura 9. Correlograma del primer modelo ARMA sin intercepto.

```
##Autorregresivos
ggtsdiag(S2_AR)
ggtsdiag(S4_AR)
##Promedios móviles
ggtsdiag(S2_MA)
ggtsdiag(S4_MA)
##ARMA
ggtsdiag(S2_ARMA)
ggtsdiag(S4_ARMA)
```

R code:

Conclusiones

La simulación de procesos estacionarios permite una mejor identificación de las gráficas generadas por las funciones acf y pacf. Los resultados obtenidos mostraron un mayor ajuste del modelo cuando los datos consideraba un mayor número de observaciones y las gráficas de residuales muestran las características del ruido blanco, en las cuales, ya no existen picos significativos en la función de autocorrelación.

Referencias

Box, G.E.P., Jenkins, G.M. and Reinsel, G.C. (1994) Time Series Analysis; Forecasting and Control. 3rd Edition, Prentice Hall, Englewood Cliff, New Jersey.