



COLEGIO DE POSTGRADUADOS

COLEGIO DE POSTGRADUADOS
INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS
AGRÍCOLAS
CAMPUS MONTECILLO
PROGRAMA DE POSTGRADO EN CIENCIAS FORESTALES

TAREA 4.

METODOLOGÍA DE BOX-JENKINS

EST-624. Series de Tiempo

Zaira Rosario Perez Vazquez
08 de febrero de 2021

Tabla de contenido

TAREA 4-A	2
I. Introducción	2
II. Análisis de la temperatura media anual	3
a) Reconocimiento de la serie	3
b) Identificación de la señal y nivel de la serie.....	5
c) Identificación de cambios estructurales de nivel y tendencia.	7
d) Identificación de un modelo ARIMA	11
e) Ajuste de los modelos ARIMA	17
f) Diagnóstico de los modelos ARIMA.....	18
g) Predicción de la serie	23
III. Análisis de la precipitación total anual	27
a) Reconocimiento de la serie	27
b) Transformación de la serie de tiempo.....	29
c) Identificación de la señal y nivel de la serie.....	33
d) Identificación de cambios estructurales de nivel y tendencia.	36
e) Identificación de un modelo ARIMA	41
f) Ajuste de los modelos ARIMA	44
g) Diagnóstico de los modelos ARIMA.....	45
h) Predicción de la serie	49
III. Conclusiones	51
TAREA 4-B.	52
Pregunta 1.....	52
Pregunta 2.....	52
Pregunta 3.....	52
Pregunta 4.....	53
Pregunta 5.....	53
Referencias.....	53

TAREA 4-A

I. Introducción

En el presente trabajo, se utilizaron dos conjuntos de datos climatológicos que provienen del Servicio Meteorológico Nacional, en particular, de la estación 01342 – Zacualtipán, Hidalgo (CONAGUA, 2019). Los datos representan una serie de tiempo anual con mediciones de las variables continuas de temperatura media anual (°C) y de precipitación total anual (mm). Los registros de las variables pertenecen al periodo 1945 – 2019.

Un modelo ARIMA no estacional se clasifica como un modelo ARIMA (p, d, q), donde p es el número de términos autorregresivos, d es el número de diferencias no estacionales necesarias para la estacionariedad, y q es el número de errores de pronóstico rezagados en la ecuación de predicción. Un modelo autorregresivo es simplemente una regresión lineal del valor actual de la serie contra uno o más valores anteriores de la serie. El valor de p se llama el orden del modelo AR. Un modelo de promedio móvil (MA) es conceptualmente una regresión lineal del valor actual de la serie contra el ruido blanco o choques aleatorios de uno o más valores anteriores de la serie (q). Se supone que los choques aleatorios en cada punto provienen de la misma distribución, típicamente una distribución normal, con ubicación en cero y escala constante.

Los pasos para realizar el modelado ARIMA son los siguientes: a) Identificación del modelo, b) Ajuste del modelo, c) Diagnóstico del modelo y d) Pronóstico. Los supuestos del modelo son: i) los datos deben ser estacionarios, ii) los datos presentan una distribución normal, y iii) los datos deben ser univariados.

II. Análisis de la temperatura media anual

a) Reconocimiento de la serie

En primer lugar, se realizó el análisis descriptivo de la serie para conocer su comportamiento. Para convertir el conjunto de datos a serie de tiempo se utilizó la función “ts” del paquete *stats*. En la Figura 1 se observa que la serie probablemente no es estacionaria pues presenta una ligera tendencia ascendente a medida que avanza el tiempo, además, presenta aproximadamente seis cambios en su estructura. La temperatura media anual entre 1945 y 2019 varió entre 9.10°C a 18.10°C, con un valor medio igual a 13.51 ± 2.06 °C y una mediana de 13.50°C.




Figura 1. Serie de tiempo de la temperatura media anual (°C).

El histograma de frecuencias y la función de densidad siguen una distribución en forma de campana que sugieren una distribución normal, al igual que el gráfico QQ (Figura 2). Por lo cual, se utilizó la prueba de Jarque-Bera-Test y Shapiro Wilks para verificar que los datos siguen una distribución normal. La prueba de hipótesis fue la siguiente:

H_0 : La serie de tiempo tiene una distribución normal

H_1 : La serie de tiempo no tiene una distribución normal.

Se obtuvo un valor de significancia igual a 0.6785 en la prueba de Jarque-Bera, mientras que la de Shapiro Wilks mostró un valor de significancia de 0.1018. Por lo que se acepta la

hipótesis de normalidad en la serie de tiempo analizada. La verificación del supuesto de normalidad sugiere que la metodología de Box y Jenkins puede utilizarse.




Figura 2. Temperatura media anual: a) Histograma de frecuencias, b) Función de densidad y c) Gráfico QQ para normalidad.

R code:

```
rm(list=ls())
options(max.print = 10000)
setwd("C:/Users/.../Tarea 4")

#Librerias
library(ggfortify)
library(tseries)
library(car)
library(nortest)
library(forecast)
library(ggpubr)
library(strucchange)
library(fUnitRoots)
library(astsa)
library(lmtest)

### 1. Primer conjunto de datos - Temperatura media anual
datos_TMA<-read.csv("Temperatura_SerieAnual.csv",header = FALSE)
View(datos_TMA)
TMA_serie<-ts(datos_TMA,start = 1945,frequency = 1,names = "Temperatura")
TMA_serie

##1.1 Reconocimiento de la serie

#1.1.1. Estadística descriptiva de la serie
autoplot(TMA_serie,xlab = "Tiempo",ylab = "Temperatura (°C)")
```

R code:

```
summary(TMA_serie)
  Temperatura
Min.   : 9.10
1st Qu.:12.60
Median :13.50
Mean   :13.51
3rd Qu.:14.75
Max.   :18.10

var(TMA_serie)
sd(TMA_serie)
par(mfrow=c(1,3),cex=0.9)
hist(TMA_serie,main = "a",xlab = "Temperatura media anual (°C)",ylab =
"Frecuencia")
plot(density(TMA_serie), main = "b",ylab = "Densidad")
qqPlot(TMA_serie,dist="norm",ylab = "Temperatura",main = "c")
dev.off() #800x320px

#1.1.2 Prueba de normalidad
jarque.bera.test(TMA_serie) #La serie sigue una distribución normal

      Jarque Bera Test

data:  TMA_serie
X-squared = 0.7756, df = 2, p-value = 0.6785

shapiro.test(TMA_serie)

      Shapiro-Wilk normality test

data:  TMA_serie
W = 0.9725, p-value = 0.1018

#Nota: Se puede aplicar la metodología de Box-Jenkins
```

b) Identificación de la señal y nivel de la serie.

La señal de la serie fue graficada utilizando la función de regresión local polinomial “*loess*” del paquete *stats*; en este caso, se utilizó un nivel de suavizamiento de 0.2 (Figura 3). Se observan periodos de disminución de la temperatura en los primeros 20 años y posteriormente se observa una tendencia positiva. Para la estimación del nivel de la serie, se utilizó un modelo de regresión lineal. El nivel de la serie fue significativo ($\alpha < 0.001$) y se encuentra en un valor de temperatura igual a 13.508°C (Figura 4).




Figura 3. Señal de la serie de tiempo de temperatura media anual.




Figura 4. Nivel de la serie de tiempo de temperatura media anual.

R code:

##1.2. Identificación de la señal de la serie

```
tt_tma <- 1:length(TMA_serie)
fit_tma <- ts(loess(TMA_serie ~ tt_tma, span = .2)$fitted, start = 1945,
frequency = 1)
plot.ts(fit_tma, type='l')
grid()
lines(TMA_serie, col = "red")
```

##1.3. Estimación del nivel de la serie ($y=bo+e$)

```
fit_level_tma<-lm(TMA_serie~1)
summary(fit_level_tma)
Call:
lm(formula = TMA_serie ~ 1)
```

Residuals:

Min	1Q	Median	3Q	Max
-4.408	-0.908	-0.008	1.242	4.592

R code:

```

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  13.5080    0.2387    56.6  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.067 on 74 degrees of freedom

plot.ts(TMA_serie, main="Nivel de la serie")
lines(ts(fitted(fit_level_tma), start=1945, frequency = 1), col = "red")
#Nota: el nivel de la serie se encuentra en un
#valor de temperatura igual a 13.508°C (Valor muy cercano a la media y mediana
de la serie)

```

c) Identificación de cambios estructurales de nivel y tendencia.

- Cambios estructurales de nivel

El número de puntos de corte óptimos para detectar cambios de nivel y de tendencia se obtuvo mediante la función “*breakpoints*” del paquete *strucchange*. Se utilizó un porcentaje de observaciones $h = 0.1$. Se espera que la suma de cuadrados para cada break sea lo menor posible. Para la detección de cambios de nivel, en la Figura 5 se observa que el número óptimo de puntos de corte es 6, con los valores de RSS y BIC más pequeños. Los años de corte son en 1951, 1963, 1976, 1993, 2004 y 2012 (Figura 6). El periodo más largo fue de 1976 a 1992 en el que el aumento de la temperatura se mantuvo estable.




Figura 5. Suma de cuadrados residuales y criterio de información bayesiano (BIC) para cambios de nivel en la temperatura media anual.




Figura 6. Gráfica de segmentos ($breaks = 6$) para cambios de nivel en la serie de tiempo de temperatura media anual.

R code:

```
##1.4 Identificación de cambios estructurales de nivel
#1.4.1. Breakpoints
temp_brk <- breakpoints(TMA_serie ~ 1, h = 0.1)
summary(temp_brk)
plot(temp_brk)
#Nota: De acuerdo con AIC y BIC, aproximadamente existen 6 cambios de nivel

breakdates(temp_brk, breaks = 6)
[1] 1951 1963 1976 1993 2004 2012

plot(TMA_serie,col="dark gray")
lines(fitted(temp_brk, breaks = 6), col = 4)
lines(confint(temp_brk, breaks = 6))
coef(temp_brk, breaks = 6)
(Intercept)
1945 - 1951    14.62857
1952 - 1963    12.55000
1964 - 1976    10.12308
1977 - 1993    13.57059
1994 - 2004    15.50000
2005 - 2012    13.82500
2013 - 2019    16.67143
```

- *Cambios estructurales de tendencia*

Para la detección de cambios de tendencia se ajustó nuevamente un modelo de regresión lineal. La tendencia de la serie fue significativa ($\alpha < 0.001$). Se observó una tendencia ascendente en la variable evaluada, por lo cual la serie de tiempo no es estacionaria.

en media (Figura 7). La obtención del número de puntos de corte óptimos se determinó con la función “*breakpoints*” del paquete *strucchange*. De acuerdo con AIC y BIC, existen seis cambios estructurales de tendencia (Figura 8). Los primeros cuatro cortes coinciden con los cambios estructurales en nivel (1951, 1963, 1976, 1993) y los últimos dos cambios se registraron en el año 2000 y 2012 (Figura 9).




Figura 7. Tendencia de la serie de tiempo de temperatura media anual.




Figura 8. Suma de cuadrados residuales y criterio de información bayesiano (BIC) para cambios de tendencia en la temperatura media anual.




Figura 9. Gráfica de segmentos (breaks = 6) para cambios de tendencia en la serie de tiempo de temperatura media anual.

R code:

```
#1.5. Tendencias
#1.5.1. Ajuste del modelo de regresión lineal
tt_tma
trend_fit_tma <- lm(TMA_serie ~ tt_tma)
summary(trend_fit_tma)
Call:
lm(formula = TMA_serie ~ tt_tma)

Residuals:
    Min       1Q   Median       3Q      Max
-3.7134 -0.8511  0.0424  0.9397  4.2789

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 11.62260    0.41372  28.093  < 2e-16 ***
tt_tma       0.04962    0.00946   5.245 1.47e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.774 on 73 degrees of freedom
Multiple R-squared:  0.2737,    Adjusted R-squared:  0.2637
F-statistic: 27.51 on 1 and 73 DF,  p-value: 1.468e-06

#Nota: hay presencia de tendencia significativa
plot(TMA_serie)
lines(ts(fitted(trend_fit_tma), start=1945, frequency = 1), col = "red")
#La tendencia es ascendente - la serie no es estacionaria en media.

#1.5.2. Obtención de breakpoints
temp_brk_trend <- breakpoints(TMA_serie ~ tt_tma, h = 0.1)
summary(temp_brk_trend)
plot(temp_brk_trend)
#Nota: De acuerdo con AIC y BIC, existen seis cambios estructurales de tendencia
```

R code:

```
breakdates(temp_brk_trend, breaks = 6)
[1] 1951 1963 1976 1993 2000 2012

coef(temp_brk_trend, breaks = 6)
      (Intercept)      tt_tma
1945 - 1951      16.27143 -0.41071429
1952 - 1963      11.58706  0.07132867
1964 - 1976      10.39451 -0.01043956
1977 - 1993      13.06814  0.01225490
1994 - 2000      28.22857 -0.24285714
2001 - 2012      31.99289 -0.28041958
2013 - 2019     -19.32857  0.50000000

plot(TMA_serie,col="dark gray")
lines(fitted(temp_brk_trend, breaks = 6), col = 4)
lines(confint(temp_brk_trend, breaks = 6))
```

d) Identificación de un modelo ARIMA

- *Supuesto de estacionariedad*

La serie de tiempo cumple el supuesto de normalidad, por lo que ahora requiere evaluar si la serie cumple el supuesto de estacionariedad en media y varianza. Para ello, se utilizó la prueba de Dickey – Fuller aumentada con la función “*adf.test*” del paquete *tseries*. El contraste de hipótesis fue:

H_0 : La serie es no estacionaria: Tiene raíz unitaria

H_1 : La serie es estacionaria: No tiene raíz unitaria

El valor del estadístico fue de 0.484, con un valor de significancia *pvalue* mayor a 0.05. Por lo que la hipótesis nula no se rechaza, y por lo tanto, la serie original no es estacionaria. Otra forma de realizar la prueba es mediante la función “*adfTest*” del paquete *fUnitRoots*. Esta función permite especificar el número de lags en la serie e incluir el tipo de regresión de raíz unitaria. En este caso, se seleccionó el tipo “ct” debido a la tendencia existente en la serie. La prueba de hipótesis reafirmo la falta de estacionariedad en la serie de tiempo con un *pvalue* de 0.2758.

R code:

```
##1.6. Identificación de un modelo ARIMA

##1.6.1. Estacionariedad
adf.test(TMA_serie) #La serie no es estacionaria

      Augmented Dickey-Fuller Test

data:  TMA_serie
Dickey-Fuller = -2.2242, Lag order = 4, p-value = 0.484
alternative hypothesis: stationary

#Otra forma:
> adfTest(TMA_serie,lags=0,type=c("ct"))

Title:
Augmented Dickey-Fuller Test

Test Results:
PARAMETER:
  Lag Order: 0
STATISTIC:
  Dickey-Fuller: -2.7346
P VALUE:
  0.2758

#Nota: se selecciona el tipo ct debido a la tendencia existente
#Nota: La serie es no estacionaria.
```

- *Funciones de autocorrelación acf – pcf*

De forma gráfica, la función de autocorrelación “*acf*” del paquete *stats* proporciona la autocorrelación en todos los retrasos posibles. La autocorrelación en el retraso 0 es igual a 1, ya que representa la correlación entre los datos y ellos mismos. La función “*pacf*” es una función de autocorrelación que describe la correlación entre todos los puntos de datos que son exactamente k pasos separados, después de considerar su correlación con los datos entre esos k pasos. Estas dos funciones ayudan a identificar el número de coeficientes de auto regresión (AR) y promedios móviles (MA), valor p y q respectivamente, en un modelo ARIMA. La función “*acf2*” del paquete *astsa* permite obtener ambas gráficas de forma simultánea (Figura 10).

Se observa que la autocorrelación continúa disminuyendo a medida que aumentan los retrasos, lo que confirma que no existe una asociación lineal entre las observaciones separadas por retrasos más grandes, por lo que la serie no es estacionaria.




Figura 10. Función *acf* y *pacf* en la serie de tiempo de temperatura media anual.

R code:

```
##1.6.2. Función acf y pacf  
acf(TMA_serie)  
pacf(TMA_serie)  
acf2(TMA_serie)
```

- *Identificación de los valores (p, d, q)*

El análisis previo indica que se tiene que eliminar la tendencia y la posible estacionalidad de la serie para que cumpla el supuesto de estacionariedad. Por lo cual, se utiliza un modelo ARIMA. Si la serie se diferencia la serie mostrará un comportamiento estacionario. Para estimar el número de diferenciaciones (d) necesarias se utilizó la función “*ndiffs*” del paquete *forecast*. Esta función indica de forma automática cuántas diferenciaciones se requieren para lograr la estacionariedad. Existe otra función para

identificar si se requieren diferenciaciones por estacionalidad “*nsdiffs*”. Sin embargo, para esta serie en particular, no se requieren diferenciaciones por estacionalidad. El resultado obtenido sugiere que sólo se requiere una diferenciación para que la serie sea estacionaria en media y varianza ($d = 1$). En la Figura 11 se observan ambas series (original vs diferenciada en un lag) Se observa que la una mayor representación de la estacionariedad en la serie diferenciada.




Figura 11. Serie de tiempo original vs Serie de tiempo diferenciada en $d = 1$.

Para verificar la estacionariedad, nuevamente se graficaron las funciones de *acf* y *pacf*. En la Figura 12 se observa que en ninguna de las funciones se obtuvieron picos significativos. Por lo que se optó por realizar nuevamente la prueba de Dickey – Fuller aumentada. El contraste de hipótesis fue:

H_0 : La serie diferenciada es no estacionaria: Tiene raíz unitaria

H_1 : La serie diferenciada es estacionaria: No tiene raíz unitaria

El valor del estadístico fue de 0.03811, con un valor de significancia *pvalue* menor a 0.05. Por lo que la hipótesis nula se rechaza, y por lo tanto, la serie diferenciada es estacionaria (Figura 13).




Figura 12. Función *acf* y *pacf* en la serie de tiempo de temperatura media anual diferenciada ($d = 1$).




Figura 13. Comparación de funciones *acf* y *pacf* entre la serie de tiempo original ($d = 0$) y diferenciada ($d = 1$).

R code:

```
#1.6.3. Diferenciación de la serie
ndiffs(TMA_serie) #d = 1
[1] 1
nsdiffs(TMA_serie) #No existen datos estacionales
Error in nsdiffs(TMA_serie) : Non seasonal data

TMA_serie_diff1 <- diff(TMA_serie, lag = 1)

#Comparación entre serie original y diferenciada en lag=1
both<-cbind(TMA_serie, TMA_serie_diff1)
head(both)
Time Series:
Start = 1945
End = 1950
Frequency = 1
      TMA_serie TMA_serie_diff1
1945      15.8             NA
1946      15.1            -0.7
1947      14.7            -0.4
1948      16.1             1.4
1949      13.5            -2.6
1950      14.3             0.8

plot(both)

#Otra forma de ver la gráfica
autoplot(both,xlab = "Tiempo",ylab = "Temperatura (°C)")

#Verificar estacionariedad
plot(TMA_serie_diff1)
acf(TMA_serie_diff1)
pacf(TMA_serie_diff1)
acf2(TMA_serie_diff1)
adf.test(TMA_serie_diff1) #La serie es estacionaria

      Augmented Dickey-Fuller Test

data:  TMA_serie_diff1
Dickey-Fuller = -3.6153, Lag order = 4, p-value =
0.03811
alternative hypothesis: stationary

#Gráficas
par(mfrow=c(2,2))
acf(TMA_serie,main="ACF - Original")
pacf(TMA_serie,main="PACF - Original")
acf(TMA_serie,main="ACF - Diff (1)")
pacf(TMA_serie_diff1,main="PACF - Diff(1)")
dev.off()
```

De acuerdo con la Figura 13, se propusieron los siguientes modelos ARIMA (p, d, q):

- Arima1: ARIMA (0,1,0)
- Arima2: ARIMA (1,1,0)
- Arima3: ARIMA (0,1,14)
- Arima4: ARIMA (1,1,14)

e) Ajuste de los modelos ARIMA

El ajuste de los modelos ARIMA se realizó mediante la función “*arima*” del paquete *stats*. Posterior al ajuste, se obtuvieron los valores de AIC y BIC respectivos. El modelo con valores menores en ambos criterios (AIC: 202.4181; BIC: 204.7222) fue el modelo *Arima1*, con valores *p*, *d*, *q*, de 0, 1, 0 respectivamente. Adicionalmente, se utilizó la función “*autoarima*” del paquete *forecast* para obtener de forma automática los valores óptimos de estos parámetros, y de esta forma, comprobar la selección del mejor modelo ARIMA. El resultado obtenido coincide con los valores establecidos para el modelo *Arima1*.

R code:

```
##1.7. Ajuste de un modelo ARIMA
#Propuestas:
#Arima1: ARIMA (0,1,0)
#Arima2: ARIMA (1,1,0)
#Arima3: ARIMA (0,1,14)
#Arima4: ARIMA (1,1,14)

Arima1<-arima(TMA_serie, c(0, 1, 0))
Arima2<-arima(TMA_serie, c(1, 1, 0))
Arima3<-arima(TMA_serie, c(0, 1, 14)) #No cumplen el principio de parsimonia
(ilustrativo)
Arima4<-arima(TMA_serie, c(1, 1, 14))

AIC(Arima1,Arima2,Arima3,Arima4)
      df      AIC
Arima1  1 202.4181
Arima2  2 202.6083
Arima3 15 216.9941
Arima4 16 219.1855

BIC(Arima1,Arima2,Arima3,Arima4)
      df      BIC
Arima1  1 204.7222
Arima2  2 207.2164
Arima3 15 251.5551
Arima4 16 256.0506

> ?auto.arima
```

R code:

```
> auto.arima(TMA_serie, stepwise = FALSE, approximation = FALSE)
```

```
Series: TMA_serie  
ARIMA(0,1,0)
```

```
sigma^2 estimated as 0.8785: log likelihood=-100.21  
AIC=202.42 AICc=202.47 BIC=204.72
```

f) Diagnóstico de los modelos ARIMA

El modelo con mejor ajuste fue *Arima1*: (0, 1, 0), este modelo únicamente incluye la diferenciación y no tiene componentes de medias móviles ni autorregresivos. Por lo que se procedió a validarlo y a compararlo con los otros modelos con menor ajuste. Para ello, se utilizó la función “*ggtsdiag*” del paquete *ggfortify*. En la Figura 14 se muestra el comportamiento de los residuales del modelo seleccionado *Arima1* (0, 1, 0). Se aprecia que los residuales representan ruido blanco, con media en cero y sin picos significativos en la función de autocorrelación y con *pvalues* superiores al valor de significancia que indican que los residuales son independientes. Lo anterior valida el modelo *Arima1*.




Figura 14. Diagnóstico de residuales del modelo ARIMA: Arima1 (0,1,0).

El resto de los modelos propuestos: Arima2 (1, 1, 0) (Figura 15), Arima3 (0, 1, 14) (Figura 16) y Arima4 (1, 1, 14) (Figura 17) también mostraron residuales que son ruido blanco. Sin embargo, se optó por seleccionar el primer modelo en función de su menor complejidad.




Figura 15. Diagnóstico de residuales del modelo ARIMA: Arima2 (1,1,0).




Figura 16. Diagnóstico de residuales del modelo ARIMA: Arima3 (0,1,14).




Figura 17. Diagnóstico de residuales del modelo ARIMA: Arima3 (1,1,14).

Adicionalmente, se realizaron las pruebas de Box-Pierce y Ljung-Box para el modelo seleccionado *Arima1* para examinar la independencia de los residuales, el contraste de hipótesis fue:

$$H_0: \text{Los residuales son independientes}$$

$$H_1: \text{Los residuales no son independientes}$$

Se obtuvo un *pvalue* de 0.1785 y de 0.1699 para la prueba de Box-Pierce y Ljung-Box, respectivamente, con un valor de significancia $\alpha > 0.05$. Por lo cual no se rechaza la hipótesis nula y se confirma la independencia de los residuales. Respecto a la normalidad en residuales, se realizaron las pruebas de Jarque-Bera y Shapiro-Wilks. El contraste de hipótesis fue:

$$H_0: \text{Los residuales tienen una distribución normal}$$

$$H_1: \text{Los residuales no tiene una distribución normal.}$$

No obstante, los residuales presentaron *pvalues* menores a $\alpha = 0.05$, por lo cual, se rechaza H_0 y se concluye que los residuales no tienen una distribución normal, tal como se muestra en la Figura 18.




Figura 18. Histograma de residuales y gráfico QQ para normalidad para el modelo *Arima1*.

En vista de que el modelo *Arima1* no cumple con el supuesto de normalidad, se verifico este supuesto para el resto de los modelos. Aparentemente, el modelo *Arima3* cumple con todos los supuestos para ser considerado ruido blanco (Figura 16, Figura 19), por lo que este modelo de promedios móviles de orden 14 y con diferenciación igual a 1 representa mejor el comportamiento de la serie de tiempo de temperatura media anual.




Figura 19. Histograma de residuales y gráfico QQ para normalidad para el modelo *Arima3*.

R code:

##1.8. Diagnóstico de un modelo ARIMA

```
ggtsdiag(Arima1) #Modelo seleccionado
ggtsdiag(Arima2)
ggtsdiag(Arima3)
ggtsdiag(Arima4)
```

#Pruebas adicionales a los residuales

```
Box.test(Arima1$residuals) # Test de Box-Pierce #Independencia
```

Box-Pierce test

```
data: Arima1$residuals
X-squared = 1.8103, df = 1, p-value = 0.1785
```

```
Box.test(Arima1$residuals, type="Ljung-Box") #Independencia
```

Box-Ljung test

```
data: Arima1$residuals
X-squared = 1.8837, df = 1, p-value = 0.1699
```

```
jarque.bera.test(Arima1$residuals) #Normalidad
```

Jarque Bera Test

```
data: Arima1$residuals
X-squared = 21.101, df = 2, p-value = 2.618e-05
```

```
shapiro.test(Arima1$residuals) #Normalidad
```

Shapiro-Wilk normality test

```
data: Arima1$residuals
W = 0.95191, p-value = 0.006355
```

```
par(mfrow=c(1,2))
hist(Arima1$residuals, main="a"), xlab = "Residuales", ylab = "Frecuencia")
qqPlot(Arima1$residuals, distribution = "norm", main = "b"), ylab = "Residuales")
dev.off()
```

#Verificar normalidad en Arima2,3 y 4

```
#Arima2
```

```
jarque.bera.test(Arima2$residuals) #Sin Normalidad
```

```
shapiro.test(Arima2$residuals) #Sin Normalidad
```

```
#Arima3
```

```
jarque.bera.test(Arima3$residuals) #Sin Normalidad
```

```
shapiro.test(Arima3$residuals) #Normalidad
```

Shapiro-Wilk normality test

```
data: Arima3$residuals
W = 0.97313, p-value = 0.1111
```

R code:

```
#Arima4
jarque.bera.test(Arima4$residuals) #Sin Normalidad
shapiro.test(Arima4$residuals) #Normalidad

#Nota: al parecer el modelo Arima3 es el más cercano a una distribución normal

Box.test(Arima3$residuals) # Test de Box-Pierce #Independencia
Box-Pierce test

data: Arima3$residuals
X-squared = 0.0022047, df = 1, p-value = 0.9626

Box.test(Arima3$residuals, type="Ljung-Box") #Independencia
par(mfrow=c(1,2))
hist(Arima3$residuals, main="a",xlab = "Residuales",ylab = "Frecuencia")
qqPlot(Arima3$residuals,distribution = "norm",main = "b",ylab = "Residuales")
dev.off()
#Nota: Este modelo cumple con todos los supuestos de ruido blanco.
```

g) Predicción de la serie

Finalmente, la predicción de la serie se realizó con la función “*forecast*” del paquete *forecast* para los modelos *Arima1* y *Arima3*. Mediante esta función se especifica el modelo que se utiliza para las predicciones, el nivel de confianza para los intervalos de predicción y la cantidad de años a predecir (*h*). El periodo de la serie es de 1945 a 2019, por lo que las predicciones se realizarán para 2025 y para 2030, con el objetivo de comparar la capacidad predictiva de los modelos *Arima1* y *Arima3*. Se estableció un intervalo de confianza del 95%.

Para 2025, el modelo *Arima1* predice un comportamiento estable de la temperatura media anual en 18°C aproximadamente (Figura 20). Por su parte, el modelo *Arima3* muestra una disminución en la temperatura (Figura 21). Bajo el contexto de cambio climático, posiblemente esta tendencia sea errónea, por lo que se recomienda contrastar dichas predicciones con otras variables relacionadas.




Figura 20. Predicción del modelo *Arima1* (0, 1, 0) para el año 2025.






Figura 21. Predicción del modelo *Arima3* (0, 1, 14) para el año 2025.

Para 2030, el modelo *Arima1* continua con una predicción estable en el comportamiento de la temperatura (Figura 22). Por otra parte, el modelo *Arima3* muestra una predicción mucho más consistente con los cambios estructurales que presenta la serie de tiempo, por lo que podemos concluir que, aparentemente, este modelo predice mejor la serie de tiempo (Figura 23).

Figura 22. Predicción del modelo *Arima1* (0, 1, 0) para el año 2030.Figura 23. Predicción del modelo *Arima3* (0, 1, 14) para el año 2030.

R code:**##1.9. Predicción (con el mejor modelo: ARIMA6)****#2025**

```
tma_pred_arma1<-forecast(Arima1,level = c(95), h = 6)
autoplot(tma_pred_arma1)
tma_pred_arma3<-forecast(Arima3,level = c(95), h = 6)
autoplot(tma_pred_arma3)
```

#2030

```
tma_pred2_arma1<-forecast(Arima1,level = c(95), h = 11)
autoplot(tma_pred2_arma1)
tma_pred2_arma3<-forecast(Arima3,level = c(95), h = 11)
autoplot(tma_pred2_arma3)
```

III. Análisis de la precipitación total anual

a) Reconocimiento de la serie

En primer lugar, se realizó el análisis descriptivo de la serie para conocer el comportamiento de la serie de tiempo. En la Figura 24 se observa que la serie probablemente no es estacionaria en varianza, pues presenta algunos valores mucho más pronunciados en los primeros años de evaluación. La precipitación total anual que se registró entre 1945 y 2019 varió entre 653.2 y 4,216 mm, con un valor medio igual a 1486.4 ± 598.19 mm y una mediana de 1398.5




Figura 24. Serie de tiempo de la precipitación total anual.

El histograma de frecuencias y la función de densidad siguen una distribución sesgada a la derecha ($\text{media} > \text{mediana}$) lo que sugiere que los datos no siguen una distribución normal. El gráfico QQ reafirma dicha suposición. (Figura 25). Por lo cual, se utilizó la prueba de Jarque-Bera-Test y Shapiro Wilks para verificar que los datos siguen una distribución normal. La prueba de hipótesis fue la siguiente:

H_0 : La serie de tiempo tiene una distribución normal

H_1 : La serie de tiempo no tiene una distribución normal.

Se obtuvo un valor de significancia igual a 2.2×10^{-16} en la prueba de Jarque-Bera, mientras que la de Shapiro Wilks mostró un valor de significancia de 2.277×10^{-9} . Por lo que se rechaza la hipótesis de normalidad en la serie de tiempo analizada. La verificación del supuesto de normalidad sugiere que la metodología de Box y Jenkins no puede utilizarse a menos que se realice una transformación de la serie de tiempo.




Figura 25. Precipitación total anual: a) Histograma de frecuencias, b) Función de densidad y c) Gráfico QQ para normalidad.

R code:

```
rm(list=ls())
options(max.print = 10000)
setwd("C:/Users/.../Tarea 4")

#Librerias
library(ggfortify)
library(tseries)
library(car)
library(nortest)
library(forecast)
library(ggpubr)
library(strucchange)
library(fUnitRoots)
library(astsa)
library(lmtest)

### 1. Segundo conjunto de datos - Precipitación total anual
datos_PP<-read.csv("Precipitacion_SerieAnual.csv",header = FALSE)
View(datos_PP)
PP_serie<-ts(datos_PP,start = 1945,frequency = 1,names = "Precipitacion")
PP_serie
```

R code:

##1.1 Reconocimiento de la serie**#1.1.1. Estadística descriptiva de la serie**

```
autoplot(PP_serie,xlab = "Tiempo",ylab = "Precipitación (mm)")
summary(PP_serie)
Precipitacion
Min.   : 653.2
1st Qu.:1195.0
Median :1398.5
Mean   :1486.4
3rd Qu.:1692.0
Max.   :4216.0

var(PP_serie)
sd(PP_serie)
par(mfrow=c(1,3),cex=0.9)
hist(PP_serie,main = "a",xlab = "Precipitación total anual (mm)",ylab =
"Frecuencia")
plot(density(PP_serie), main = "b",ylab = "Densidad")
qqPlot(PP_serie,dist="norm",ylab = "Precipitación",main = "c")
dev.off() #800x320px
```

#1.1.2 Prueba de normalidad

```
jarque.bera.test(PP_serie) #La serie no sigue una distribución normal
Jarque Bera Test
```

```
data: PP_serie
X-squared = 265.77, df = 2, p-value < 2.2e-16
```

```
shapiro.test(PP_serie)
Shapiro-Wilk normality test
```

```
data: PP_serie
W = 0.77476, p-value = 2.277e-09
```

```
#Nota: No se puede aplicar la metodología de Box-Jenkins
#Se requiere de la transformación de los datos.
```

b) Transformación de la serie de tiempo

En virtud de que la serie no sigue una distribución normal y para poder utilizar la metodología de Box y Jenkins se evaluó si la transformación logarítmica o Boxcox permiten el cumplimiento de este supuesto.

- *Transformación logarítmica*

La transformación logarítmica no logro que los datos siguieran una distribución normal (Figura 26, Figura 27). Se ejecutaron las pruebas de normalidad de Jarque-Bera (función “*jarque.bera.test*” del paquete *tseries*), Lilliefors (Kolmogorov Smirnov) y Anderson-Darling (función “*lillie.test*” y “*ad.test*”, respectivamente, del paquete *nortest*). La prueba de hipótesis fue la siguiente:

H_0 : La serie de tiempo tiene una distribución normal

H_1 : La serie de tiempo no tiene una distribución normal

Las pruebas de Jarque-Bera y Anderson-Darling tuvieron un $pvalue < 0.05$, por lo que la hipótesis de normalidad se rechaza. La prueba de Lilliefors presento un $pvalue = 0.053$, lo que sugiere que los datos podrían considerarse normales.




Figura 26. Precipitación total anual con transformación logarítmica: a) Histograma de frecuencias, b) Función de densidad y c) Gráfico QQ para normalidad.




Figura 27. Precipitación total anual: a) serie original; b) serie con transformación logarítmica.

R code:

```
#1.1.3 Transformación de la serie
#Transformación logarítmica
PP_serie_log<-log(PP_serie)
par(mfrow=c(1,3),cex=0.9)
hist(PP_serie_log,main = "a",xlab = "Log Precipitación",ylab = "Frecuencia")
plot(density(PP_serie_log), main = "b",ylab = "Densidad")
qqPlot(PP_serie_log,main = "c",ylab = "Log Precipitación")
dev.off()
jarque.bera.test(PP_serie_log)
Jarque Bera Test

data: PP_serie_log
X-squared = 12.67, df = 2, p-value = 0.001773

lillie.test(PP_serie_log) #solo esta prueba sugiere normalidad
Lilliefors (Kolmogorov-Smirnov) normality test

data: PP_serie_log
D = 0.10164, p-value = 0.05306

ad.test(PP_serie_log)
Anderson-Darling normality test

data: PP_serie_log
A = 1.0494, p-value = 0.008749

serie_orig_Fig<-autoplot(PP_serie,xlab = "Tiempo",ylab = "Precipitación")
serie_log_Fig<-autoplot(PP_serie_log,xlab = "Tiempo",ylab = "Log
Precipitación")
ggarrange(serie_orig_Fig,serie_log_Fig,ncol = 1, nrow = 2,labels = c("A","B"))
```


- *Transformación BoxCox*

La transformación se realizó utilizando el paquete *forecast*. El valor de λ se obtuvo con la función “*BoxCox.lambda*” y fue igual a -0.2765. Este valor se incluyó en la transformación, la cual se realizó con la función “*BoxCox*”. Las pruebas de Jarque-Bera y Lilliefors tuvieron un *pvalue* > 0.05, por lo que la hipótesis de normalidad no se rechaza. La prueba de Anderson-Darling presentó un *pvalue* = 0.0148, por lo que fue la única prueba que sugiere que los datos no podrían considerarse normales.




Figura 28. Precipitación total anual con transformación BoxCox: a) Histograma de frecuencias, b) Función de densidad y c) Gráfico QQ para normalidad.




Figura 29. Precipitación total anual: a) serie original; b) serie con transformación BoxCox.

R code:

```

#Transformación BoxCox
lambda<-BoxCox.lambda(PP_serie)
lambda
1] -0.2765276

PP_serie_boxcox<-BoxCox(PP_serie, lambda = lambda)
PP_serie_boxcox
par(mfrow=c(1,3),cex=0.9)
hist(PP_serie_boxcox,main = "a"),xlab = "BoxCox - Precipitación",ylab =
"Frecuencia")
plot(density(PP_serie_boxcox), main = "b"),ylab = "Densidad")
qqPlot(PP_serie_boxcox,main = "c"),ylab = "BoxCox - Precipitación")
dev.off()

jarque.bera.test(PP_serie_boxcox) #Normalidad
Jarque Bera Test

data: PP_serie_boxcox
X-squared = 2.9817, df = 2, p-value = 0.2252

lillie.test(PP_serie_boxcox) #Normalidad
Lilliefors (Kolmogorov-Smirnov) normality test

data: PP_serie_boxcox
D = 0.096062, p-value = 0.08355

ad.test(PP_serie_boxcox) #Sin normalidad
Anderson-Darling normality test

data: PP_serie_boxcox
A = 0.95678, p-value = 0.01488

serie_bc_Fig<-autoplot(PP_serie_log,xlab = "Tiempo",ylab = "Log Precipitación")
ggarrange(serie_orig_Fig,serie_bc_Fig,ncol = 1, nrow = 2,labels = c("A","B"))
#Nota: la transformación Boxcox es la más adecuada para obtener normalidad
#en la serie de precipitación

```

c) Identificación de la señal y nivel de la serie.

La señal de la serie fue graficada utilizando la función de regresión local polinomial “*loess*” del paquete *stats*; en este caso, se utilizó un nivel de suavizamiento de 0.2 y fue obtenida tanto para los datos originales como para los transformados por BoxCox. Al igual que para la temperatura, la precipitación también muestra un periodo de disminución de la en los primeros 20 años y posteriormente se observa curvas de ascenso y descenso de esta (Figura 30). Para la estimación del nivel de la serie, se utilizó un modelo de regresión lineal.

El nivel de la serie fue significativo ($\alpha < 0.001$) y se encuentra en un valor de precipitación igual a 1486.41 mm (Figura 31).




Figura 30. Señal de la serie de tiempo de precipitación total anual.




Figura 31. Nivel de la serie de tiempo de precipitación total anual.

R code:

```
##1.2. Identificación de la señal de la serie
#Serie original
tt_pp <- 1:length(PP_serie)
fit_pp <- ts(loess(PP_serie ~ tt_pp, span = .2)$fitted, start = 1945, frequency
= 1)
plot.ts(fit_pp, type='l')
grid()
lines(PP_serie, col = "red")
```

R code:

```

#Serie transformada
tt_pp_bc <- 1:length(PP_serie_boxcox)
fit_pp_bc <- ts(loess(PP_serie_boxcox ~ tt_pp_bc, span = .2)$fitted, start =
1945, frequency = 1)
plot.ts(fit_pp_bc, type='l')
grid()
lines(PP_serie_boxcox, col = "red")

##1.3. Estimación del nivel de la serie (y=bo+e)
#serie original
fit_level_pp<-lm(PP_serie~1)
summary(fit_level_pp)
Call:
lm(formula = PP_serie ~ 1)

Residuals:
    Min       1Q   Median       3Q      Max
-833.21 -291.41  -87.91   205.59 2729.59

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1486.41      69.07    21.52  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 598.2 on 74 degrees of freedom
plot.ts(PP_serie, main="")
lines(ts(fitted(fit_level_pp), start=1945, frequency = 1), col = "red")
#Nota: el nivel de la serie se encuentra en un
#valor de precipitación igual a 1486.41 mm

#serie original transformada
fit_level_pp_bc<-lm(PP_serie_boxcox~1)
summary(fit_level_pp_bc)
Call:
lm(formula = PP_serie_boxcox ~ 1)

Residuals:
    Min       1Q   Median       3Q      Max
-0.11225 -0.01962  0.00209  0.02713  0.13042

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  3.126209   0.005169   604.8  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.04476 on 74 degrees of freedom
plot.ts(PP_serie_boxcox, main="")
lines(ts(fitted(fit_level_pp_bc), start=1945, frequency = 1), col = "red")

```

d) Identificación de cambios estructurales de nivel y tendencia.

- *Cambios estructurales de nivel.*

El número de puntos de corte óptimos para detectar cambios de nivel y de tendencia se obtuvo mediante la función “*breakpoints*” del paquete *strucchange*. Se utilizó un porcentaje de observaciones $h = 0.1$. Se espera que la suma de cuadrados para cada break sea lo menor posible. Para la detección de cambios de nivel de la serie original, en la Figura 32 se observa que el número óptimo de puntos de corte es igual a 2, con los valores de BIC más pequeños. Los años de corte son en 1951 y 1958 (Figura 35).




Figura 32. Suma de cuadrados residuales y criterio de información bayesiano (BIC) para cambios de nivel en la precipitación media anual.




Figura 33. Gráfica de segmentos ($breaks = 2$) para cambios de nivel en la serie de tiempo de precipitación media anual.

Comparando los cambios de nivel en la serie transformada, en la Figura 34 se observa que el número óptimo de puntos de corte es igual a 4, con los valores de BIC más pequeños. Los años de corte son en 1951, 1958, 1976 y 1997 (Figura 35). Lo anterior indica que la transformación permite detectar mucho mejor los cambios estructurales de nivel.




Figura 34. Suma de cuadrados residuales y criterio de información bayesiano (BIC) para cambios de nivel en la serie transformada de precipitación media anual.




Figura 35. Gráfica de segmentos ($breaks = 4$) para cambios de nivel en la serie transformada de precipitación media anual.

R code:

##1.4 Identificación de cambios estructurales de nivel

#1.4.1. Serie original

```
#Breakpoints
pp_brk <- breakpoints(PP_serie ~ 1, h = 0.1)
summary(pp_brk)
plot(pp_brk)
#Nota: De acuerdo con BIC, aproximadamente existen 2 cambios de nivel
breakdates(pp_brk, breaks = 2)
[1] 1951 1958

plot(PP_serie,col="dark gray")
lines(fitted(pp_brk, breaks = 2), col = 4)
lines(confint(pp_brk, breaks = 2))
coef(pp_brk, breaks = 2)
      (Intercept)
1945 - 1951      1275.714
1952 - 1958      2720.271
1959 - 2019      1368.997
```

#1.4.2. Serie transformada

```
#Breakpoints
pp_brk_bc <- breakpoints(PP_serie_boxcox ~ 1, h = 0.1)
summary(pp_brk_bc)
plot(pp_brk_bc)
#Nota: De acuerdo con BIC, aproximadamente existen 4 cambios de nivel
breakdates(pp_brk_bc, breaks = 4)
[1] 1951 1958 1976 1997

plot(PP_serie_boxcox,col="dark gray")
lines(fitted(pp_brk_bc, breaks = 4), col = 4)
lines(confint(pp_brk_bc, breaks = 4))
coef(pp_brk_bc, breaks = 4)
      (Intercept)
1945 - 1951      3.107888
1952 - 1958      3.198379
1959 - 1976      3.137641
1977 - 1997      3.092906
1998 - 2019      3.131510
```

- *Cambios estructurales de tendencia*

Para la detección de cambios de tendencia se ajustó nuevamente un modelo de regresión lineal. Para la serie original, la tendencia de la serie fue significativa ($\alpha < 0.01$). Se observó una tendencia ligeramente descendiente en la variable evaluada, por lo cual la serie de tiempo no es estacionaria en media (Figura 36). La obtención del número de puntos de

corte óptimos se determinó con la función “*breakpoints*” del paquete *strucchange*. De acuerdo con BIC, existen dos cambios estructurales de tendencia (Figura 37). Los años de corte son en 1955 y 1976 (Figura 38). Para la serie transformada, también se observó la misma tendencia descendente de la precipitación y dos cambios estructurales de tendencia en la serie en los mismos años.




Figura 36. Tendencia de la serie de tiempo de Precipitación total anual.




Figura 37. Suma de cuadrados residuales y criterio de información bayesiano (BIC) para cambios de tendencia en la precipitación media anual.




Figura 38. Gráfica de segmentos (*breaks* = 2) para cambios de tendencia en la serie de tiempo de precipitación media anual.

R code:

#1.5. Tendencias

#1.5.1. Serie original

#Ajuste del modelo de regresión lineal

```
tt_pp
```

```
trend_fit_pp <- lm(PP_serie ~ tt_pp)
```

```
summary(trend_fit_pp)
```

```
Call:
```

```
lm(formula = PP_serie ~ tt_pp)
```

```
Residuals:
```

Min	1Q	Median	3Q	Max
-1090.92	-350.01	-38.25	210.36	2520.63

```
Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1751.087	135.894	12.886	<2e-16 ***
tt_pp	-6.965	3.107	-2.242	0.028 *

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 582.6 on 73 degrees of freedom
```

```
Multiple R-squared:  0.0644,    Adjusted R-squared:  0.05158
```

```
F-statistic: 5.025 on 1 and 73 DF,  p-value: 0.02803
```

```
#Nota: hay presencia de tendencia significativa
```

```
plot(PP_serie)
```

```
lines(ts(fitted(trend_fit_pp), start=1945, frequency = 1), col = "red")
```

```
#La tendencia es descendente - la serie no es estacionaria en media.
```

#Obtención de breakpoints

```
pp_brk_trend <- breakpoints(PP_serie ~ tt_pp, h = 0.1)
```

```
summary(pp_brk_trend)
```

R code:

```

plot(pp_brk_trend)
#Nota: De acuerdo con BIC, existen 2 cambios estructurales de tendencia
breakdates(pp_brk_trend, breaks = 2)
[1] 1955 1976

coef(pp_brk_trend, breaks = 2)
              (Intercept)          tt_pp
1945 - 1955      227.8000  296.88182
1956 - 1976    1833.8505 -11.13130
1977 - 2019      683.0425   11.47359

plot(PP_serie,col="dark gray")
lines(fitted(pp_brk_trend, breaks = 2), col = 4)
lines(confint(pp_brk_trend, breaks = 2))

#1.5.1. Serie transformada

#Ajuste del modelo de regresión lineal
tt_pp_bc
trend_fit_pp_bc <- lm(PP_serie_boxcox ~ tt_pp_bc)
summary(trend_fit_pp_bc)
#Nota: hay presencia de tendencia significativa
plot(PP_serie_boxcox)
lines(ts(fitted(trend_fit_pp_bc), start=1945, frequency = 1), col = "red")
#La tendencia es descendente - la serie no es estacionaria en media.

#Obtención de breakpoints
pp_brk_trend_bc <- breakpoints(PP_serie_boxcox ~ tt_pp_bc, h = 0.1)
summary(pp_brk_trend_bc)
plot(pp_brk_trend_bc)
#Nota: De acuerdo con BIC, existen 2 cambios estructurales de tendencia
breakdates(pp_brk_trend_bc, breaks = 2)
coef(pp_brk_trend_bc, breaks = 2)
plot(PP_serie_boxcox,col="dark gray")
lines(fitted(pp_brk_trend_bc, breaks = 2), col = 4)
lines(confint(pp_brk_trend_bc, breaks = 2))

```

e) Identificación de un modelo ARIMA

- *Supuesto de estacionariedad*

Al utilizar la serie de tiempo transformada mediante BoxCox se cumple el supuesto de normalidad, por lo que ahora requiere evaluar si la serie cumple el supuesto de estacionariedad en media y varianza. Para ello, se utilizó la prueba de Dickey – Fuller aumentada con la función “*adf.test*” del paquete *tseries*. El contraste de hipótesis fue:

H_0 : La serie es no estacionaria: Tiene raíz unitaria

H_1 : La serie es estacionaria: No tiene raíz unitaria

Primero se contrastaron las hipótesis para la serie original. El valor del estadístico fue de 0.0275, con un valor de significancia *pvalue* menor a 0.05. Por lo que la hipótesis nula se rechaza, y por lo tanto, la serie original es estacionaria. Otra forma de realizar la prueba es mediante la función “*adfTest*” del paquete *fUnitRoots*. Esta función permite especificar el número de lags en la serie e incluir el tipo de regresión de raíz unitaria. En este caso, se seleccionó el tipo “ct” debido a la tendencia existente en la serie. La prueba de hipótesis reafirmo la estacionariedad en la serie de tiempo con un *pvalue* de 0.01. Para la serie transformada, también se cumple el supuesto de estacionariedad, con un *pvalue* = 0.01.

R code:

```
##1.6. Identificación de un modelo ARIMA

#1.6.1. Estacionariedad
#Serie original
adf.test(PP_serie) #La serie es estacionaria
      Augmented Dickey-Fuller Test

data:  PP_serie
Dickey-Fuller = -3.7367, Lag order = 4, p-value =
0.02756
alternative hypothesis: stationary

#Otra forma:
adfTest(PP_serie,lags=0,type=c("ct"))
Title:
  Augmented Dickey-Fuller Test

Test Results:
PARAMETER:
  Lag Order: 0
STATISTIC:
  Dickey-Fuller: -6.1594
P VALUE:
  0.01
#Nota: se selecciona el tipo ct debido a la tendencia existente
#Nota: La serie es estacionaria.

#Serie transformada
adfTest(PP_serie_boxcox,lags=0,type=c("ct")) #La serie es estacionaria
```

R code:

```
Title:
Augmented Dickey-Fuller Test

Test Results:
PARAMETER:
  Lag Order: 0
STATISTIC:
  Dickey-Fuller: -6.1983
P VALUE:
  0.01
#Nota: se selecciona el tipo ct debido a la tendencia existente
```

- *Funciones de autocorrelación acf – pcf*

De forma gráfica, estas dos funciones ayudan a identificar el número de coeficientes de auto regresión (AR) y promedios móviles (MA), valor p y q respectivamente, en un modelo ARIMA. La función “*acf2*” del paquete *astsa* permite obtener ambas gráficas de forma simultánea (Figura 39). Se observa que la serie estacionaria, de acuerdo con la función *acf*. Asimismo, se observan picos significativos en ambas funciones, por lo cual es adecuado ajustar un modelo ARIMA.




Figura 39. Función *acf* y *pacf* en la serie de tiempo transformada de precipitación total anual.

R code:

#1.6.2. Función acf y pacf

#Original

acf(PP_serie)

pacf(PP_serie)

acf2(PP_serie)

#Transformada

acf(PP_serie_boxcox)

pacf(PP_serie_boxcox)

acf2(PP_serie_boxcox)

- *Identificación de los valores (p, d, q)*

Al utilizar la función “*ndiffs*” con la serie transformada se indica que no se requiere de ninguna diferenciación. De acuerdo con la Figura 39, la función “*pacf*” muestra dos picos significativos autorregresivos ($p = 2$), mientras que la función “*acf*” presenta tres picos de promedios móviles por encima de los intervalos de confianza ($q = 3$), por lo que se plantean los siguientes modelos ARIMA:

- Arima1: ARIMA (2, 0, 3)
- Arima2: ARIMA (2, 0, 0)
- Arima3: ARIMA (0, 0, 3)

f) Ajuste de los modelos ARIMA

El ajuste de los modelos ARIMA se realizó mediante la función “*arima*” del paquete *stats*. Posterior al ajuste, se obtuvieron los valores de AIC y BIC respectivos. El modelo con valores menores en ambos criterios (AIC: -267.1093; BIC: -255.5219) fue el modelo *Arima3* de promedios móviles, con valores p, d, q , de 0, 0, 3 respectivamente. Adicionalmente, se utilizó la función “*autoarima*” del paquete *forecast* para obtener de forma automática los valores óptimos de estos parámetros, y de esta forma, comprobar la selección del mejor modelo ARIMA. El resultado obtenido coincide con los valores establecidos para el modelo *Arima3*.

R code:

```
##1.7. Ajuste de un modelo ARIMA
#Propuestas:

#Arima1: ARIMA (2,0,3)
#Arima2: ARIMA (2,0,0)
#Arima3: ARIMA (0,0,3)

Arima1<-arima(PP_serie_boxcox, c(2, 0, 3)) #ARMA
Arima2<-arima(PP_serie_boxcox, c(2, 0, 0)) #AR
Arima3<-arima(PP_serie_boxcox, c(0, 0, 3)) #MA

AIC(Arima1,Arima2,Arima3)
      df      AIC
Arima1  7 -265.4292
Arima2  4 -260.6583
Arima3  5 -267.1093

BIC(Arima1,Arima2,Arima3)
      df      BIC
Arima1  7 -249.2068
Arima2  4 -251.3884
Arima3  5 -255.5219

?auto.arima
auto.arima(PP_serie_boxcox, stepwise = FALSE, approximation = FALSE)
Series: PP_serie_boxcox
ARIMA(0,0,3) with non-zero mean

Coefficients:
      ma1      ma2      ma3      mean
    0.1547  0.3200  0.5474  3.1235
s.e.  0.0992  0.0962  0.1102  0.0087

sigma^2 estimated as 0.001511:  log likelihood=138.55
AIC=-267.11  AICc=-266.24  BIC=-255.52
```

g) Diagnóstico de los modelos ARIMA

El modelo con mejor ajuste fue *Arima3*: (0, 0, 3), este modelo únicamente incluye el componente de promedios móviles y no tiene componentes autorregresivos ni diferenciaciones. Por lo que se procedió a validarlo y a compararlo con los otros modelos con menor ajuste. Para ello, se utilizó la función “*ggtsdiag*” del paquete *ggfortify*.

En la Figura 40 se muestra el comportamiento de los residuales del modelo seleccionado *Arima3* (0, 0, 3). Se aprecia que los residuales representan ruido blanco, con media en cero y sin picos significativos en la función de autocorrelación y con *pvalues* superiores al valor de significancia que indican que los residuales son independientes. Lo anterior valida el modelo *Arima3*.




Figura 40. Diagnóstico de residuales del modelo ARIMA: Arima3 (0, 0, 3).




Figura 41. Diagnóstico de residuales del modelo ARIMA: Arima1 (2, 0, 3).




Figura 42. Diagnóstico de residuales del modelo ARIMA: Arima2 (2, 0, 0).

El modelo Arima1 (2, 0, 3) (Figura 41) también mostró residuales que son ruido blanco. Sin embargo, se optó por seleccionar el primer modelo en función de su menor complejidad. Mientras que el modelo Arima2 (2, 0, 0) (Figura 42) presento problemas en la prueba de independencia y mostro un pico significativo en la función *acf*. Por lo que no es un modelo adecuado.

Adicionalmente, se realizaron las pruebas de Box-Pierce y Ljung-Box para el modelo seleccionado *Arima3* para examinar la independencia de los residuales, el contraste de hipótesis fue:

$$H_0: \text{Los residuales son independientes}$$

$$H_1: \text{Los residuales no son independientes}$$

Se obtuvo un *pvalue* de 0.2486 y de 0.611 para la prueba de Box-Pierce y Ljung-Box, respectivamente, con un valor de significancia $\alpha > 0.05$. Por lo cual no se rechaza la hipótesis nula y se confirma la independencia de los residuales. Respecto a la normalidad en residuales, se realizaron las pruebas de Jarque-Bera y Shapiro-Wilks. El contraste de hipótesis fue:

H_0 : Los residuales tienen una distribución normal

H_1 : Los residuales no tiene una distribución normal.

No obstante, los residuales presentaron *pvalues* menores a $\alpha = 0.05$, por lo cual, se rechaza H_0 y se concluye que los residuales no tienen una distribución normal, pero si bastante cercana, tal como se muestra en la Figura 43.




Figura 43. Histograma de residuales y gráfico QQ para normalidad para el modelo *Arima3*.

R code:

```
##1.8. Diagnóstico de un modelo ARIMA
ggtsdiag(Arima3) #Modelo seleccionado
ggtsdiag(Arima1)
ggtsdiag(Arima2)

#Pruebas adicionales a los residuales
Box.test(Arima3$residuals) # Test de Box-Pierce #Independencia

Box-Pierce test

data: Arima3$residuals
X-squared = 0.24864, df = 1, p-value = 0.618

Box.test(Arima3$residuals, type="Ljung-Box") #Independencia
Box-Ljung test

data: Arima3$residuals
X-squared = 0.25872, df = 1, p-value = 0.611
```

R code:

```
jarque.bera.test(Arima3$residuals) #Normalidad
Jarque Bera Test

data: Arima3$residuals
X-squared = 13.808, df = 2, p-value = 0.001004

shapiro.test(Arima3$residuals) #Normalidad
Shapiro-Wilk normality test

data: Arima3$residuals
W = 0.95079, p-value = 0.005512

par(mfrow=c(1,2))
hist(Arima3$residuals, main="a",xlab = "Residuales",ylab = "Frecuencia")
qqPlot(Arima3$residuals,distribution = "norm",main = "b",ylab = "Residuales")
dev.off()
```

h) Predicción de la serie

Finalmente, la predicción de la serie se realizó con la función “*forecast*” del paquete *forecast* para el modelo *Arima3*. Mediante esta función se especifica el modelo que se utiliza para las predicciones, el nivel de confianza para los intervalos de predicción y la cantidad de años a predecir (*h*). El periodo de la serie es de 1945 a 2019, por lo que las predicciones se realizarán para 2025 y para 2030, con el objetivo de comparar la capacidad predictiva en diferentes plazos. Se estableció un intervalo de confianza del 95%.

Para 2025, el modelo *Arima3* predice un ligero aumento en la precipitación total anual (Figura 44). Sin embargo, para 2030, se muestra una estabilización en la predicción (Figura 45) y con intervalos de confianza mucho más amplios, lo cual, dado el comportamiento natural de esta variable, la predicción es bastante incierta.




Figura 44. Predicción del modelo Arima3 (0, 0, 3) para el año 2025.




Figura 45. Predicción del modelo Arima3 (0, 0, 3) para el año 2030.

R code:

```
##1.9. Predicción (con el mejor modelo: ARIMA3)
#2025
pp_pred_arima3<-forecast(Arima3,level = c(95), h = 6)
autoplot(pp_pred_arima3)

#2030
pp_pred2_arima3<-forecast(Arima3,level = c(95), h = 11)
autoplot(pp_pred2_arima3)

#Con los otros modelos tampoco se alcanza a predecir hasta 2030
#Arima1
#2025
pp_pred_arima1<-forecast(Arima1,level = c(95), h = 6)
autoplot(pp_pred_arima1)
#2030
pp_pred2_arima1<-forecast(Arima1,level = c(95), h = 11)
autoplot(pp_pred2_arima1)
#Arima2
#2025
pp_pred_arima2<-forecast(Arima2,level = c(95), h = 6)
autoplot(pp_pred_arima2)
#2030
pp_pred2_arima2<-forecast(Arima2,level = c(95), h = 11)
autoplot(pp_pred2_arima2)
```

III. Conclusiones

Las series de datos analizadas presentaron comportamientos completamente diferentes, a pesar de que, por su naturaleza, son variables que se encuentran relacionadas entre sí. En primer lugar, la temperatura mostro una tendencia ascendente, lo cual, es un escenario general bajo el contexto de cambio climático, el cual, también ha generado una disminución en la precipitación total anual, que se ve reflejada en el tipo de tendencia obtenida. La temperatura media anual requirió de una diferenciación $d = 1$ para poder ajustar un modelo ARIMA, mientras que precipitación esto no fue necesario, en su lugar, esta variable requirió de la transformación de los datos. El ajuste de los modelos fue bueno, sin embargo, las predicciones en ambas variables y los amplios intervalos de confianza obtenidos dan un indicio de que el ajuste de modelos ARIMA no necesariamente explican totalmente el comportamiento de la variable de forma univariada.

TAREA 4-B.

Pregunta 1.

¿Cuáles son las principales características de una serie de tiempo?

Una serie de tiempo es una secuencia de observaciones a través del tiempo. Se caracteriza por que las observaciones adyacentes presentan dependencia en el tiempo. Dicha dependencia es el principal objeto de interés del análisis de series de tiempo. Las series de tiempo pueden ser continuas o discretas, determinísticas (los valores se pueden determinar de forma exacta mediante funciones matemáticas) o estadísticas (los valores pueden ser descritos en términos de su función de probabilidad).

Pregunta 2.

¿Qué se necesita para obtener una buena predicción y cómo se puede expresar?

Para obtener una buena predicción se requiere especificar su precisión. Esta precisión puede ser expresada al calcular los límites de probabilidad de cada pronóstico. De tal forma que el valor realizado de la serie de tiempo, cuando eventualmente ocurra, debe incluirse dentro de estos límites con la probabilidad establecida. No obstante, debe tenerse siempre en cuenta que los métodos utilizados para realizar los pronósticos se desarrollan con base en el supuesto de que la serie de tiempo z_t sigue un modelo estocástico de forma conocida.

Pregunta 3.

¿Para qué se utiliza el análisis de series de tiempo multivariado?

Se utiliza para analizar relaciones dinámicas entre dos o más series de tiempo que comprenden el vector Z_t . El análisis multivariado busca explicar las relaciones dinámicas que existen entre esas series de tiempo a partir de diferentes métodos y modelos estadísticos. El análisis multivariado permite a su vez obtener un pronóstico mucho más adecuado de una serie de tiempo individual.

Pregunta 4.**¿Cuáles son los aspectos principales para modelar series de tiempo?**

La parsimonia es un aspecto importante que busca la menor selección de parámetros que obtengan el mejor ajuste y representación de su comportamiento. De igual modo, también se debe tener en cuenta las diferentes etapas iterativas del modelo, las cuales, en términos generales son: a) la postulación de clases generales de modelos, b) identificación de modelos apropiados, c) estimación de los parámetros del modelo aplicado, d) diagnóstico del modelo, e) uso del modelo para control y pronóstico. Este proceso se realiza de forma iterativa hasta obtener el modelo más adecuado.

Pregunta 5.**¿En que se basa el proceso estocástico de estacionariedad?**

Se basa en el supuesto de que el proceso se encuentra en un estado particular de equilibrio estadístico. Un proceso estocástico estrictamente estacionario es aquel si sus propiedades no son afectadas por un cambio en el tiempo de origen. Por lo cual, la distribución de probabilidad conjunta asociada a m observaciones $Z_{t_1}, Z_{t_2}, \dots, Z_{t_m}$, realizada en cualquier conjunto de tiempos $t_1, t_2, \dots, t_m$ es la misma que la asociada con m observaciones $Z_{t_1+k}, Z_{t_2+k}, \dots, Z_{t_m+k}$, realizada en los tiempos $t_1+k, t_2+k, \dots, t_m+k$. Entonces, en un proceso discreto estrictamente estacionario, la distribución conjunta de cualquier set de observaciones no debe ser afectada por el desplazamiento de todos los tiempos de observación hacia adelante o hacia atrás en cualquier valor entero de k .

• Referencias

Box, G. E. P., Jenkins, G. M., Reinsel, G. C., Ljung, G. M., 2016. Time series analysis : forecasting and control. Fifth edition, Wiley & Sons Inc. New Jersey, U. S. 1 – 18 pp.

Comisión Nacional del Agua (CONAGUA), 2019. Proyecto de bases de datos climatológicos de la estación Zacualtipán, Hidalgo. Disponible en: <https://smn.conagua.gob.mx/tools/RESOURCES/Mensuales/hgo/00013042.TXT>