



COLEGIO DE POSTGRADUADOS

COLEGIO DE POSTGRADUADOS
INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS
AGRÍCOLAS
CAMPUS MONTECILLO
PROGRAMA DE POSTGRADO EN CIENCIAS FORESTALES

TAREA 5.

MODELACIÓN DE UNA SERIE ESTACIONAL.

EST-624. Series de Tiempo

Dra. Martha Elva Ramírez Guzmán

Zaira Rosario Perez Vazquez

15 de febrero de 2021

Contenido

1. Introducción.....	1
2. Reconocimiento de la serie.....	2
3. Componentes de la serie de tiempo	3
4. Prueba de estacionariedad	4
5. Prueba de raíz unitaria	6
6. Identificación de un modelo ARIMA.....	9
7. Ajuste del modelo ARIMA	11
8. Diagnóstico de los modelos ARIMA.....	14
9. Predicción del modelo	18
10. Conclusiones.....	21

1. Introducción

Las series temporales son datos expresados como una secuencia de puntos a través del tiempo. El análisis de estas series permite definir modelos o describir tendencias para posteriormente predecir datos futuros que ayuden a una la toma de decisiones más efectiva y óptima. Los parámetros del modelo ARIMA se pueden usar como un modelo predictivo para hacer pronósticos de valores futuros de las series temporales, una vez que se selecciona el modelo más adecuado para los datos de la serie temporal. En general, se dice que una serie temporal Y_t admite una representación autoregresiva integrada y de medias móviles de órdenes p , d y q respectivamente, y se denota por $ARIMA(p, d, q)$.

Donde p denota el número de términos autoregresivos, d el número de veces que la serie debe ser diferenciada para hacerla estacionaria y q el número de términos de la media móvil invertible. La construcción de los modelos se lleva de manera iterativa mediante un proceso con cinco etapas: a) identificación y reconocimiento de la serie de datos, b) análisis y diferenciación de la serie temporal (conocer la estacionariedad, los diagramas *acf* y *pacf* y la elección del orden del modelo), c) ajuste del modelo ARIMA, d) diagnóstico del modelo y e) predicción.

2. Reconocimiento de la serie

Se utilizó una serie de datos mensual del periodo (2006-2017) sobre los registros de partículas suspendidas ($PM_{2.5}$) de la Ciudad de México. Los datos fueron obtenidos del siguiente enlace ([Vínculo](#)). En la Figura 1 se observa que la serie sigue una tendencia ascendente y un patrón estacional de incremento y disminución en cada año registrado, además se observa que los datos siguen una distribución posiblemente normal con dos picos máximos.




Figura 1. Gráficos descriptivos: a) Serie de tiempo, b) histograma de frecuencias, c) función de densidad y d) Gráfico QQ para normalidad.

Se utilizó la prueba de Jarque-Bera-Test para verificar que los datos siguen una distribución normal. La prueba de hipótesis fue la siguiente:

H_0 : La serie de tiempo tiene una distribución normal

H_1 : La serie de tiempo no tiene una distribución normal.

Se obtuvo un valor de significancia igual a 0.0638, por lo que se acepta la hipótesis de normalidad en la serie de tiempo analizada. La verificación de este supuesto sugiere que la metodología de Box y Jenkins puede utilizarse.

R code

```
rm(list=ls())
options(max.print = 10000)

Datos=scan('https://bit.ly/3afYHIK')
View(Datos)

### 1. Reconocimiento de la serie
Serie_PM = ts(Datos, start = c(2006,1), frequency = 12,names = "PM 2.5")
Serie_PM
autoplot(Serie_PM,xlab = "Tiempo",ylab = "Particulas suspendidas", main = "a")
summary(Serie_PM)
var(Serie_PM)
sd(Serie_PM)
par(mfrow=c(1,3),cex=0.9)
hist(Serie_PM,main = "b",xlab = "Partículas Suspendidas",ylab = "Frecuencia")
plot(density(Serie_PM), main = "c",ylab = "Densidad")
qqPlot(Serie_PM,dist="norm",ylab = "Partículas Suspendidas",main = "d")
dev.off() #800x320px

### 2. Prueba de normalidad
jarque.bera.test(Serie_PM) #La serie sigue una distribución normal
      Jarque Bera Test

data:  Serie_PM
X-squared = 5.5026, df = 2, p-value = 0.06384
```

3. Componentes de la serie de tiempo

Se obtuvieron los componentes de la serie de tiempo mediante la función “*decompose*” del paquete *stats*. En la Figura 2 se observan los datos originales, una tendencia general ascendente, así como un patrón mensual en los datos (estacionalidad) y finalmente, la parte inexplicable de los datos. Se puede asumir que los datos no son estacionarios.

R code

```
### 3. Componentes de la serie de tiempo
Componentes=decompose(Serie_PM)
plot(Componentes)
```




Figura 2. Descomposición aditiva de la serie de tiempo.

4. Prueba de estacionariedad

La serie de tiempo cumple el supuesto de normalidad, por lo que ahora requiere evaluar si la serie cumple el supuesto de estacionariedad en media y varianza. En la Figura 3 se observa que la función acf presenta un decaimiento lento a medida que avanzan los lags, lo que indica la falta de estacionariedad. Para confirmar se utilizó, en primer lugar, la prueba de Dickey – Fuller aumentada con la función “*adfTest*” del paquete *tseries*. El contraste de hipótesis fue:

H_0 : La serie es no estacionaria: Tiene raíz unitaria

H_1 : La serie es estacionaria: No tiene raíz unitaria

La prueba se realizó para los datos originales y para los datos transformados a logaritmo. El valor del estadístico fue de 0.7296 y 0.9315 respectivamente, con un valor de significancia

pvalue mayor a 0.05. Por lo que la hipótesis nula no se rechaza y por lo tanto, la serie original no es estacionaria.




Figura 3. Función *acf* y *pacf* de la serie de tiempo.

R code

```
### 4. Prueba de estacionariedad
adfTest(Serie_PM) #Serie no estacionaria, con raiz unitaria
Title:
Augmented Dickey-Fuller Test

Test Results:
PARAMETER:
  Lag Order: 1
STATISTIC:
  Dickey-Fuller: 0.3629
P VALUE:
  0.7296
adfTest(log(Serie_PM))
Title:
Augmented Dickey-Fuller Test

Test Results:
PARAMETER:
  Lag Order: 1
STATISTIC:
  Dickey-Fuller: 1.145
P VALUE:
  0.9315
acf2(Serie_PM) #Decaimiento lento
acf2(log(Serie_PM))
```

5. Prueba de raíz unitaria

Para determinar el número de raíces unitarias que tiene la serie, esta debe ser diferenciada con la función “*diff*” y utilizando los datos transformados a logaritmo. De igual modo, para conocer el orden de los picos significativos se debe ajustar un modelo autorregresivo. El orden obtenido fue igual a 12. Ahora con la función *adfTest*” del paquete *FUnitRoots* se realizó la prueba de Dickey – Fuller aumentada. Esta función, a diferencia de la anterior, permite especificar el tipo de regresión de raíz unitaria: a) la prueba de raíz unitaria, b) la prueba con deriva o constante $\neq 0$ y c) la prueba de raíz unitaria con deriva y tendencia temporal determinista. Se especificaron los 12 lags obtenidos, y de acuerdo con la Figura 4, no se observa tendencia, por lo cual la prueba se realizó con una deriva “c”. El contraste de hipótesis fue el mismo:

H_0 : La serie es no estacionaria: Tiene raíz unitaria

H_1 : La serie es estacionaria: No tiene raíz unitaria

El valor del estadístico fue de 0.01, con un valor de significancia *pvalue* menor a 0.05. Por lo que la hipótesis nula se rechaza, por lo tanto, la serie original con logaritmo no tiene raíz unitaria.




Figura 4. Serie de tiempo transformada a logaritmo y diferenciada.

R code

```

#Ajuste de un modelo AR a la serie diferenciada
?adfTest()

plot(diff(log(Serie_PM)))
#Nota: la serie diferenciada no presenta tendencia
acf2(diff(log(Serie_PM)))
mod1=ar(diff(log(Serie_PM)),method="mle")
mod1$order #Fue 12
[1] 12

#Prueba ADF ajustada a 12 lags
adfTest(log(Serie_PM),lags=12,type=c("c")) #serie estacionaria
Augmented Dickey-Fuller Test

Test Results:
PARAMETER:
  Lag Order: 12
STATISTIC:
  Dickey-Fuller: -4.4086
P VALUE:
  0.01

```

Para conocer si hay pendiente, así como el valor de la constante y su significancia, se ajustó un modelo de regresión lineal. De acuerdo con los resultados, ni el intercepto ni la pendiente son significativos ($\alpha < 0.05$). Por lo que la prueba se ajustó nuevamente.

R code

```

# ¿Hay pendiente? ¿Cuánto vale la constante?
t=seq(2:length(log(Serie_PM)))
mod2=lm(diff(log(Serie_PM))~t)
summary(mod2)
Call:
lm(formula = diff(log(Serie_PM)) ~ t)

Residuals:
    Min       1Q   Median       3Q      Max
-0.36117 -0.08563 -0.00158  0.08190  0.28479

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.772e-02  2.217e-02   0.799   0.426
t            -7.432e-05  2.747e-04  -0.271   0.787

```

R code

```
Residual standard error: 0.13 on 137 degrees of freedom
Multiple R-squared: 0.0005339, Adjusted R-squared: -0.006761
F-statistic: 0.07319 on 1 and 137 DF, p-value: 0.7872
#Nota: No es significativo el intercepto ni la pendiente
#entonces no hay deriva
```

#Prueba ADF ajustada sin constante

```
adfTest(log(Serie_PM),lags=12,type=c("nc"))
```

Title:

Augmented Dickey-Fuller Test

Test Results:

PARAMETER:

Lag Order: 12

STATISTIC:

Dickey-Fuller: 5.5827

P VALUE:

0.99

#Nota: la serie tiene raíz unitaria

#Requiere de una diferenciación

#Comprobación

```
ndiffs(Serie_PM)
```

```
[1] 1
```

```
ndiffs(log(Serie_PM))
```

```
[1] 1
```

#Prueba con unitrootTest

```
unitrootTest(log(Serie_PM),lags=1,type="nc")
```

Title:

Augmented Dickey-Fuller Test

Test Results:

PARAMETER:

Lag Order: 1

STATISTIC:

DF: 1.145

P VALUE:

t: 0.9345

n: 0.9323

Realizando el contraste de hipótesis, se concluye que la serie tiene raíz unitaria y por lo cual, requiere de una diferenciación para el ajuste de un modelo ARIMA. La prueba con la función *unitRootTest* también obtuvo la misma conclusión.

6. Identificación de un modelo ARIMA

Para ajustar un modelo ARIMA se debe de eliminar la no estacionariedad de la serie mediante una diferenciación. Como la serie de tiempo es estacionalidad, este componente también debe removerse. En la Figura 5ª se observa la serie de tiempo diferenciada ($d = 1$). Para eliminar la estacionalidad de los datos se resto el componente estacional de la serie original (Figura 5b) y posteriormente se diferenció para que sea estacionario (Figura 5c).




Figura 5. Ajuste de estacionariedad y estacionalidad: a) Serie original diferenciada ($d = 1$); b) Remoción del componente estacional a la serie original; c) Serie de tiempo diferenciada y sin estacionalidad.

R code

6. Identificación de un modelo ARIMA

#Eliminar no estacionariedad

```
Serie_PM_diferenciada<-diff(Serie_PM,differences=1)
Fig1<-autoplot(Serie_PM_diferenciada,xlab = "Tiempo",ylab = "Particulas
suspendidas", main = "a")
```

#Eliminar estacionalidad

```
Serie_PM_ajustada<-Serie_PM-Componentes$seasonal
Fig2<-autoplot(Serie_PM_ajustada,xlab = "Tiempo",ylab = "Particulas
suspendidas", main = "b")
```

```
Serie_PM_estacionaria<-diff(Serie_PM_ajustada,differences=1)
```

```
Fig3<-autoplot(Serie_PM_estacionaria,xlab = "Tiempo",ylab = "Particulas
suspendidas", main = "c")
```

```
ggarrange(Fig1,Fig2,Fig3,ncol = 1, nrow = 3)
```

Una vez que se cumplen todos los supuestos del modelo se requiere conocer los valores de p , d , q y que hacen referencia al orden de las partes medias autorregresivas, integradas y de promedios móviles, respectivamente. Para esto, nuevamente se grafican las funciones *acf* y *pacf*. Las gráficas se obtuvieron con la función “*acf2*” del paquete *astsa*.




Figura 6. Funciones *acf* y *pacf* de la serie de tiempo estacionaria.

R code

```
#Identificación de los valores p, d, q.
acf(Serie_PM_estacionaria)
pacf(Serie_PM_estacionaria)
acf2(Serie_PM_estacionaria)
frequency(Serie_PM)
[1] 12
```

Siguiendo la Figura 6, se propusieron los siguientes modelos:

- Arima1: ARIMA (1, 1, 1) (1, 0, 0) (12)
- Arima2: ARIMA (2, 0, 0) (0, 1, 2) (12)
- Arima3: ARIMA (2, 0, 1) (0, 1, 2) (12)
- Arima4: ARIMA (2, 0, 2) (1, 1, 2) (12)
- Arima5: ARIMA (2, 0, 2) (0, 1, 2) (12)
- Arima6: ARIMA (0, 0, 1) (0, 1, 1) (12)
- Arima7: ARIMA (0, 1, 1) (0, 1, 1) (12)
- Arima7: ARIMA (1, 1, 0) (1, 1, 0) (12)

7. Ajuste del modelo ARIMA

Para ajustar el modelo se deben de especificar tres aspectos: a) el orden, que es la parte estacional del modelo ARIMA (p, d, q), que se refiere al orden autorregresivo, el grado de diferencia y el orden de promedios móviles; b) la parte estacional del modelo ARIMA; c) el periodo, que por defecto es la frecuencia de la serie de tiempo, en este caso es igual a 12. El ajuste de los modelos ARIMA se realizó mediante la función “*arima*” del paquete *stats*. Posterior al ajuste, se obtuvieron los valores de AIC y BIC respectivos. El modelo con valores menores en ambos criterios (AIC: 5179.111; BIC: 5201.927) fue el modelo *Arima4* (2,0,2) (1,1,2) (12). Adicionalmente, se utilizó la función “*autoarima*” del paquete *forecast* para obtener de forma automática los valores óptimos de estos parámetros, y de esta forma, comprobar la selección del mejor modelo ARIMA. El resultado obtenido no coincide con los valores establecidos para el modelo *Arima4*, y en su lugar, sugiere el modelo *Arima2* (2, 0, 0) (0, 1, 2) (12).

R code

```
### 7. Ajuste del modelo ARIMA estacional
#Arima1: ARIMA (1, 1, 1) (1, 0, 0) (12)
#Arima2: ARIMA (2, 0, 0) (0, 1, 2) (12)
#Arima3: ARIMA (2, 0, 1) (0, 1, 2) (12)
```

R code

```
#Arima4: ARIMA (2, 0, 2) (1, 1, 2) (12)
#Arima5: ARIMA (2, 0, 2) (0, 1, 2) (12)
#Arima6: ARIMA (0, 0, 1) (0, 1, 1) (12)
#Arima7: ARIMA (0, 1, 1) (0, 1, 1) (12)
#Arima8: ARIMA (1, 1, 0) (1, 1, 0) (12)

Arima1<- arima(Serie_PM, order=c(1,1,1),seasonal = list(order = c(1,0,0), period
= 12),method="ML")
coeftest(Arima1)

Arima2<- arima(Serie_PM, order=c(2,0,0),seasonal = list(order = c(0,1,2), period
= 12),method="ML")
coeftest(Arima2) #Coeficientes significantes

z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ar1    0.341530   0.070158  4.8680 1.127e-06 ***
ar2    0.631881   0.069480  9.0945 < 2.2e-16 ***
sma1  -0.522009   0.089980 -5.8014 6.577e-09 ***
sma2    0.068062   0.101224  0.6724  0.5013
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Arima3<- arima(Serie_PM, order=c(2,0,1),seasonal = list(order = c(0,1,2), period
= 12),method="ML")
coeftest(Arima3)

Arima4<- arima(Serie_PM, order=c(2,0,2),seasonal = list(order = c(1,1,2), period
= 12),method="ML")
coeftest(Arima4)

z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ar1    0.1939527  0.1486805  1.3045  0.192065
ar2    0.7753913  0.1486062  5.2178 1.811e-07 ***
ma1   -0.0020066  0.1872422 -0.0107  0.991449
ma2   -0.3013725  0.1716678 -1.7556  0.079164 .
sar1    0.9938007  0.0161917 61.3773 < 2.2e-16 ***
sma1  -1.9465173  0.3731487 -5.2165 1.824e-07 ***
sma2    0.9838783  0.3722378  2.6431  0.008214 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Arima5<- arima(Serie_PM, order=c(2,0,2),seasonal = list(order = c(0,1,2), period
= 12),method="ML")
coeftest(Arima5)

Arima6<- arima(Serie_PM, order=c(0,0,1),seasonal = list(order = c(0,1,1), period
= 12),method="ML")
coeftest(Arima6)
```

R code

```

Arima7<- arima(Serie_PM, order=c(0,1,1),seasonal = list(order = c(0,1,1), period
= 12),method="ML")
coeftest(Arima7)

```

```

Arima8<- arima(Serie_PM, order=c(1,1,0),seasonal = list(order = c(1,1,0), period
= 12),method="ML")
coeftest(Arima8)

```

```

AIC(Arima1,Arima2,Arima3,Arima4,Arima5,Arima6,Arima7,Arima8) #Best: Arima4

```

	df	AIC
Arima1	4	5688.336
Arima2	5	5190.680
Arima3	6	5186.591
Arima4	8	5179.111
Arima5	7	5184.693
Arima6	3	5344.895
Arima7	3	5152.341
Arima8	3	5148.669

```

BIC(Arima1,Arima2,Arima3,Arima4,Arima5,Arima6) #Best: Arima4

```

	df	BIC
Arima1	4	5700.074
Arima2	5	5204.940
Arima3	6	5203.704
Arima4	8	5201.927
Arima5	7	5204.657
Arima6	3	5353.451
Arima7	3	5160.873
Arima8	3	5157.201

```

auto.arima(Serie_PM, stepwise = FALSE, approximation = FALSE)

```

```

Series: Serie_PM

```

```

ARIMA(2,0,0)(0,1,2)[12] with drift

```

```

Coefficients:

```

	ar1	ar2	sma1	sma2	drift
	0.1753	0.4751	-0.5748	0.2152	22803842
s.e.	0.0792	0.0792	0.0926	0.0957	1848336

```

sigma^2 estimated as 1.925e+16: log likelihood=-2581.19

```

```

AIC=5174.39 AICc=5175.08 BIC=5191.5

```

```

#Nota: Sugiere modelo Arima2

```

8. Diagnóstico de los modelos ARIMA

Los modelos con mejor ajuste fueron *Arima8* y *Arima2* (sugerido por la función *auto.arima*). Por lo que se validaron y compararon entre sí. Para ello, se utilizó la función “*ggtsdiag*” del paquete *ggfortify*. En la Figura 7 se muestra el comportamiento de los residuales del modelo seleccionado *Arima8* (1, 1, 0) (1, 1, 0) (12). Se aprecia que los residuales podrían representar ruido blanco, con media en cero, aunque al final del periodo se observa un cambio en las medias. No tiene picos significativos en la función de autocorrelación y con *pvalues* superiores al valor de significancia que indican que los residuales son independientes. Lo anterior valida el modelo *Arima8*.




Figura 7. Diagnóstico de residuales del modelo ARIMA: Arima8 (1, 1, 0) (1, 1, 0) (12).

En la Figura 8 se muestra el comportamiento de los residuales del modelo seleccionado *Arima2* (2, 0, 0) (0, 1, 2) (12). Se aprecia que los residuales son muy parecidos al modelo *Arima8*. No tiene picos significativos en la función de autocorrelación y con *pvalues* superiores al valor de significancia que indican que los residuales son independientes. Lo anterior valida el modelo *Arima2*.




Figura 8. Diagnóstico de residuales del modelo ARIMA: *Arima2* (2, 0, 0) (0, 1, 2) (12).

Adicionalmente, se realizaron las pruebas de Box-Pierce y Ljung-Box para el modelo seleccionado *Arima2* para examinar la independencia de los residuales, el contraste de hipótesis fue:

$$H_0: \text{Los residuales son independientes}$$

$$H_1: \text{Los residuales no son independientes}$$

Se obtuvo un *pvalue* de 0.3543 y de 0.3492 para la prueba de Box-Pierce y Ljung-Box, respectivamente, con un valor de significancia $\alpha > 0.05$. Por lo cual no se rechaza la hipótesis nula y se confirma la independencia de los residuales. Respecto a la normalidad en residuales, se realizó la prueba de Jarque-Bera. El contraste de hipótesis fue:

H_0 : Los residuales tienen una distribución normal

H_1 : Los residuales no tiene una distribución normal.

Los residuales presentaron *pvalues* menores a $\alpha = 0.05$, por lo cual, se rechaza H_0 y se concluye que los residuales no tienen una distribución normal, tal como se muestra en la Figura 9.




Figura 9. Histograma de residuales y gráfico QQ para normalidad para el modelo Arima2.

Para el modelo *Arima8* se obtuvo un *pvalue* de 0.3795 y de 0.3744 para la prueba de Box-Pierce y Ljung-Box, respectivamente, con un valor de significancia $\alpha > 0.05$. Por lo cual no se rechaza la hipótesis nula y se confirma la independencia de los residuales. Respecto a la normalidad en residuales, se obtuvo un *pvalue* menor a $\alpha = 0.05$, por lo cual, los residuales tampoco siguen una distribución normal (Figura 10).




Figura 10. Histograma de residuales y gráfico QQ para normalidad para el modelo Arima8.

R code

8. Diagnóstico de los modelos

```
ggtsdiag(Arima4)
ggtsdiag(Arima2) #Mejor desempeño
```

#Pruebas adicionales a los residuales del modelo Arima 2

```
Box.test(Arima2$residuals) # Test de Box-Pierce #Independencia
Box-Pierce test
```

```
data: Arima2$residuals
X-squared = 0.85802, df = 1, p-value = 0.3543
```

```
Box.test(Arima2$residuals, type="Ljung-Box") #Independencia
```

```
Box-Ljung test
```

```
data: Arima2$residuals
X-squared = 0.87654, df = 1, p-value = 0.3492
```

```
jarque.bera.test(Arima2$residuals) #Normalidad
Jarque Bera Test
```

```
data: Arima2$residuals
X-squared = 131.45, df = 2, p-value < 2.2e-16
```

```
par(mfrow=c(1,2),cex=0.7)
hist(Arima2$residuals, main="a"),xlab = "Residuales",ylab = "Frecuencia")
qqPlot(Arima2$residuals,distribution = "norm",main = "b"),ylab = "Residuales")
dev.off()
```

#Pruebas adicionales a los residuales del modelo Arima 2

```
Box.test(Arima8$residuals) # Test de Box-Pierce #Independencia
Box-Pierce test
```

R code

```
data: Arima8$residuals
X-squared = 0.77234, df = 1, p-value = 0.3795
Box.test(Arima8$residuals, type="Ljung-Box") #Independencia
Box-Ljung test

data: Arima8$residuals
X-squared = 0.78901, df = 1, p-value = 0.3744

jarque.bera.test(Arima8$residuals) #Normalidad
Jarque Bera Test

data: Arima8$residuals
X-squared = 112.07, df = 2, p-value < 2.2e-16
par(mfrow=c(1,2),cex=0.7)
hist(Arima8$residuals, main="a"),xlab = "Residuales",ylab = "Frecuencia")
qqPlot(Arima8$residuals,distribution = "norm",main = "b"),ylab = "Residuales")
dev.off()
```

9. Predicción del modelo

Finalmente, la predicción de la serie se realizó con la función “*forecast*” del paquete *forecast* para el modelo *Arima2* y *Arima8*. Mediante esta función se especifica el modelo que se utiliza para las predicciones, el nivel de confianza para los intervalos de predicción y la cantidad de años a predecir (*h*). El periodo de la serie es de 2006 a 2017, por lo que las predicciones se realizarán para 2018, 2019 y 2020, con el objetivo de comparar su capacidad predictiva. Se estableció un intervalo de confianza del 95%

En la Figura 11 se observa una buena predicción del modelo ajustado *Arima2*. La mejor representación fue a corto plazo, con intervalos de confianza más estrechos, aunque la predicción hasta 2020 presenta un patrón bastante similar al conjunto de datos original.




Figura 11. Predicción del modelo Arima2 para 2018, 2019 y 2020.

En la Figura 12 se observa una buena predicción del modelo ajustado *Arima8*. La mejor representación también fue a corto plazo, aunque aparentemente tiene intervalos de confianza ligeramente más amplios en comparación con el modelo *Arima8*.




Figura 12. Predicción del modelo Arima8 para 2018, 2019 y 2020.

R code

```
### 9. Prediccion del modelo
##Predicción (con el mejor modelo: ARIMA2)
forecast::forecast()
#Arima2
pred1_arima2<-forecast::forecast(Arima2,h=12, level=c(99.5))
Fig4<-autoplot(pred1_arima2, main = "2018")

pred2_arima2<-forecast::forecast(Arima2,h=24, level=c(99.5))
Fig5<-autoplot(pred2_arima2, main = "2019")

pred3_arima2<-forecast::forecast(Arima2,h=36, level=c(99.5))
Fig6<-autoplot(pred3_arima2, main = "2020")

ggarrange(Fig4, Fig5, Fig6, ncol = 1, nrow = 3)
```

R code

```
#Arima8
pred4_arima8<-forecast::forecast(Arima8,h=12, level=c(99.5))
Fig4<-autoplot(pred4_arima8, main = "2018")

pred5_arima8<-forecast::forecast(Arima8,h=24, level=c(99.5))
Fig5<-autoplot(pred5_arima8, main = "2019")

pred6_arima8<-forecast::forecast(Arima8,h=36, level=c(99.5))
Fig6<-autoplot(pred6_arima8, main = "2020")

ggarrange(Fig4, Fig5, Fig6, ncol = 1, nrow = 3)
```

10. Conclusiones

La serie de tiempo analizada presenta una tendencia positiva y una estacionalidad bastante definida y de acuerdo con la naturaleza de los datos, este comportamiento es acertado debido al aumento de la contaminación de la Ciudad de México. Debido a la falta de estacionariedad de la serie, al trazar su diferenciación se observó un patrón oscilante alrededor de 0, sin una tendencia fuerte visible que indicó que la diferenciación de los términos del orden 1 fue suficiente para incluir en el modelo, así como la inclusión de parámetros de estacionalidad. Estos procedimientos permitieron obtener el modelo Arima2, que presenta un ajuste bastante cercano al comportamiento natural de los datos.