



COLEGIO DE POSTGRADUADOS
INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS
AGRÍCOLAS
CAMPUS MONTECILLO
PROGRAMA DE POSTGRADO EN CIENCIAS FORESTALES

TAREA 6

MODELO ARIMA DE SERIE ESTACIONAL

EST-624. Series de Tiempo

Dra. Martha Elva Ramírez Guzmán

Zaira Rosario Perez Vazquez

22 de febrero de 2020

TAREA 6 A

1. Introducción

Box y Jenkins han desarrollado modelos estadísticos para series temporales que tienen en cuenta la dependencia existente entre los datos, esto es, cada observación en un momento dado es modelada en función de los valores anteriores. Los análisis se basan en un modelo explícito y se conocen como ARIMA (Autorregresive Integrated Moving Average).

En un modelo ARIMA estacional, los términos AR y MA predicen x_t utilizando valores de datos y errores en momentos con rezagos que son múltiplos de S . Con datos mensuales y con una tendencia anual ($S=12$), un modelo autorregresivo de primer orden estacional utilizaría x_{t-12} para predecir de x_t . La estacionalidad generalmente provoca que la serie de tiempo no sea estacionaria y consecuentemente requiere utilizar la diferenciación estacional, la cual se define como una diferencia entre un valor y otro con un *lag* o retraso que es múltiplo de S .

La diferenciación estacional elimina una tendencia estacional y también puede eliminar una caminata aleatoria estacional (*seasonal random walk*), que es otro tipo de no estacionariedad. No obstante, si existe una tendencia general en los datos, es posible que también se requiera de una diferenciación no estacional. Frecuentemente una primera diferencia reduce la tendencia de los datos.

Una vez que la serie es estacionaria se procede a estimar los parámetros del modelo por máxima verosimilitud y se obtienen sus errores estándar y los residuos del modelo. El diagnóstico del modelo permite verificar que los residuos no muestren una estructura de dependencia y siguen un proceso de ruido blanco. La cuarta fase es la predicción y validación de las predicciones con el modelo más adecuado.

2. Reconocimiento de la serie

Se utilizó un conjunto de datos de temperatura media anual que proviene del Servicio Meteorológico Nacional. Los datos constituyen una serie mensual con registros para el periodo 1985-2019 de la Estación Meteorológica de Zacualtipán. La temperatura mínima fue de 8.056°C y la máxima de 22.24°C, una media en $15.21 \pm 2.68^\circ\text{C}$. En la Figura 1 se observa

que la serie de tiempo parece ser estacionaria en media y varianza con una marcada estacionalidad entre cada año, además la serie de tiempo no sigue una distribución normal.




Figura 1. Gráficos descriptivos: a) Serie de tiempo, b) histograma de frecuencias, c) función de densidad y d) Gráfico QQ para normalidad.

Se utilizó la prueba de Jarque-Bera-Test para verificar que los datos siguen una distribución normal. La prueba de hipótesis fue la siguiente:

H_0 : La serie de tiempo tiene una distribución normal

H_1 : La serie de tiempo no tiene una distribución normal.

Se obtuvo un valor de significancia menor a 0.05, por lo que se rechaza la hipótesis de normalidad en la serie de tiempo analizada.

Rcode

```
rm(list=ls())
options(max.print = 10000)
setwd("C:/Users/zaira/... /Tarea 6")

#Librerias
library(forecast)
library(tseries)
library(ggfortify)
library(car)
library(nortest)
library(fUnitRoots)
library(astsa)
library(ggpubr)
library(lmtest)
library(TSPred)

### 1. Conjunto de datos
#Datos de temperatura
#01/1985 a 12/2019
datos_tma<-read.csv("Temperatura_Serie.csv",header=FALSE)
datos_tma
tma_serie<-ts(datos_tma,frequency = 12,start = c(1985,1),names =
"Temperatura")
tma_serie

### 2. Reconocimiento de la serie
summary(tma_serie)
sd(tma_serie)
autoplot(tma_serie,xlab = "Tiempo",ylab = "Temperatura media (°C)", main =
"a)")
par(mfrow=c(1,3),cex=0.9)
hist(tma_serie,main = "b)",xlab = "Temperatura media (°C)",ylab =
"Frecuencia")
plot(density(tma_serie), main = "c)",ylab = "Densidad")
qqPlot(tma_serie,dist="norm",ylab = "Temperatura media (°C)",main = "d)")
dev.off()

### 3. Prueba de normalidad
jarque.bera.test(tma_serie) #La serie no sigue una distribución normal
Jarque Bera Test

data:  tma_serie
X-squared = 9.0312, df = 2, p-value = 0.01094
```

3. Prueba de estacionariedad

La función de autocorrelación *acf* muestra un decaimiento rápido que sugiere la estacionariedad de los datos. La función *pacf* ayuda a identificar el número de coeficientes *p* de autorregresión (AR) en un modelo ARIMA (Figura 2).




Figura 2. Función acf y pacf de la serie de tiempo.

Confirmando con la prueba Dickey-Fuller y la prueba de raíz unitaria de Phillips-Perron, con la siguiente prueba de hipótesis:

H_0 : La serie de tiempo es no estacionaria: tiene raíz unitaria

H_1 : La serie de tiempo es estacionaria: no tiene raíz unitaria

El *pvalue* obtenido fue de 0.01, por lo que se rechaza la hipótesis nula y se confirma la estacionariedad de los datos.

Rcode

```
### 4. Prueba de estacionariedad y raíz unitaria.
acf2(tma_serie) #Serie estacionaria
adf.test(tma_serie) #Se rechaza Ho, con un pvalue=0.01
  Augmented Dickey-Fuller Test

data:  tma_serie
Dickey-Fuller = -6.4129, Lag order = 7, p-value = 0.01
alternative hypothesis: stationary

pp.test(tma_serie)
```

Rcode

Phillips-Perron Unit Root Test

```
data: tma_serie  
Dickey-Fuller Z(alpha) = -119.67, Truncation lag parameter = 5, p-value =  
0.01  
alternative hypothesis: stationary
```

4. Componentes de la serie de tiempo: estacionalidad

La función “*decompose*” permite observar los componentes de la serie temporal: observaciones, tendencia, estacionalidad y aleatoriedad (Figura 3). La temperatura tiene un comportamiento estacional muy marcado y una tendencia con cambios estructurales notables. Debido a la naturaleza de la variable, las menores temperaturas se registran en los primeros y últimos meses del año, mientras que las mayores temperaturas fueron registradas entre abril y agosto, con excepción de algunos años atípicos (Figura 4).

Rcode

```
### 4. Componentes de la serie de tiempo  
Componentes=decompose(tma_serie)  
plot(Componentes, cex=0.9)  
seasonplot(tma_serie, col=rainbow(12), year.labels=TRUE, cex=0.5)  
  
#Grafica polar  
ggseasonplot(tma_serie, polar=TRUE, main="Temperatura" )
```




Figura 3. Descomposición aditiva de una serie de tiempo




Figura 4. Comportamiento estacional de la temperatura.

5. Identificación de un modelo ARIMA

Para el ajuste de un modelo ARIMA se requiere eliminar la no estacionariedad y la estacionalidad de la serie. En este caso la serie ya estacionaria pero aún tiene el componente estacional, por lo que se debe realizar eliminar este componente, ajustar la serie y aplicar una diferencia estacional para tener una serie que cumpla con los supuestos del modelo ARIMA. En la Figura 5 se observa que la serie ajustada y diferenciada se estabiliza en torno a un valor medio. Una vez que se cumplen todos los supuestos del modelo se requiere conocer los valores (p, d, q) (P, D, Q) y que hacen referencia al orden de las partes medias autorregresivas, integradas y de promedios móviles, respectivamente con el componente estacional. Para esto, nuevamente se grafican las funciones *acf* y *pacf* (Figura 6).




Figura 5. Ajuste de estacionalidad y primera diferenciación ($d=1$).




Figura 6. Funciones acf y pacf de la serie de tiempo ajustada.

Se propusieron los siguientes modelos ARIMA, acorde con el principio de parsimonia:

Arima1: ARIMA (1,0,0) (1,1,0) (12)

Arima8: ARIMA (1,0,1) (0,1,1) (12)

Arima2: ARIMA (1,0,0) (0,1,1) (12)

Arima9: ARIMA (1,0,1) (1,1,1) (12)

Arima3: ARIMA (1,0,0) (1,1,1) (12)

Arima10: ARIMA (2,0,2) (1,1,1) (12)

Arima4: ARIMA (0,0,1) (1,1,0) (12)

Arima11: ARIMA (1,0,2) (2,1,2) (12)

Arima5: ARIMA (0,0,1) (0,1,1) (12)

Arima12: ARIMA (0,0,3) (2,1,2) (12)

Arima6: ARIMA (0,0,1) (1,1,1) (12)

Arima13: ARIMA (3,0,0) (1,1,1) (12)

Arima7: ARIMA (1,0,1) (1,1,0) (12)

Arima14: ARIMA (3,0,0) (2,1,2) (12)

Rcode

```
### 5. Identificación de un modelo ARIMA
```

```
#Eliminar estacionalidad
```

```
Serie_tma_ajustada<-tma_serie-Componentes$seasonal
```

```
Fig1<-autoplot(Serie_tma_ajustada,xlab = "",ylab = "(°C)", main = "Tma-season")
```

```
#Aplicando la primera diferencia
```

```
Serie_tma_estacionaria<-diff(Serie_tma_ajustada,differences=1)
```

Rcode

```
Fig2<-autoplot(Serie_tma_estacionaria,xlab = "Tiempo",ylab = "(°C)", main =
"d=1")
ggarrange(Fig1,Fig2,ncol = 1, nrow = 2)
```

#Identificación de parámetros

```
acf(Serie_tma_estacionaria)
pacf(Serie_tma_estacionaria)
adf.test(Serie_tma_estacionaria) #función del paquete tseries
Augmented Dickey-Fuller Test
```

```
data: Serie_tma_estacionaria
Dickey-Fuller = -11.48, Lag order = 7, p-value = 0.01
alternative hypothesis: stationary
acf2(Serie_tma_estacionaria)
```

6. Ajuste de un modelo ARIMA

Previamente, la serie de tiempo fue dividida para su ajuste (80%) y validación (20%). Para ajustar cada modelo se deben de especificar tres aspectos: a) el orden, que es la parte estacional del modelo ARIMA (p, d, q), que se refiere al orden autorregresivo, el grado de diferencia y el orden de promedios móviles; b) la parte estacional del modelo ARIMA; c) el periodo, que por defecto es la frecuencia de la serie de tiempo, en este caso es igual a 12. El ajuste de los modelos ARIMA se realizó mediante la función “*arima*” del paquete *stats*. Posterior al ajuste, se obtuvieron los valores de AIC y BIC respectivos. El modelo *Arima11* (1,0,2) (2,1,2) (12) obtuvo el menor AIC, con un valor de 987.2690, sin embargo, el modelo *Arima8* (1,0,1) (0,1,1) (12) obtuvo el menor valor de BIC (1017.515). Por lo cual, se realizó el diagnostico de ambos modelos.

Rcode

6. Ajuste del modelo

#Partición de datos

```
tma_train = window(tma_serie, start = c(1985,1), end = c(2012,12))
plot(tma_train)
dim(as.matrix(tma_train))
tma_test = window(tma_serie, start = c(2013,1))
plot(tma_test)
dim(as.matrix(tma_test))
```

#Ajuste de los modelos

```
frequency(tma_train)
Arima1<- arima(tma_train, order=c(1,0,0),seasonal = list(order = c(1,1,0),
period = 12),method="ML")
Arima2<- arima(tma_train, order=c(1,0,0),seasonal = list(order = c(0,1,1),
period = 12),method="ML")
```

Rcode

```

Arima3<- arima(tma_train, order=c(1,0,0),seasonal = list(order = c(1,1,1),
period = 12),method="ML")
Arima4<- arima(tma_train, order=c(0,0,1),seasonal = list(order = c(1,1,0),
period = 12),method="ML")
Arima5<- arima(tma_train, order=c(0,0,1),seasonal = list(order = c(0,1,1),
period = 12),method="ML")
Arima6<- arima(tma_train, order=c(0,0,1),seasonal = list(order = c(1,1,1),
period = 12),method="ML")
Arima7<- arima(tma_train, order=c(1,0,1),seasonal = list(order = c(1,1,0),
period = 12),method="ML")
Arima8<- arima(tma_train, order=c(1,0,1),seasonal = list(order = c(0,1,1),
period = 12),method="ML")
Arima9<- arima(tma_train, order=c(1,0,1),seasonal = list(order = c(1,1,1),
period = 12),method="ML")
Arima10<- arima(tma_train, order=c(2,0,2),seasonal = list(order = c(1,1,1),
period = 12),method="ML")
Arima11<- arima(tma_train, order=c(1,0,2),seasonal = list(order = c(2,1,2),
period = 12),method="ML")
Arima12<- arima(tma_train, order=c(0,0,3),seasonal = list(order = c(2,1,2),
period = 12),method="ML")
Arima13<- arima(tma_train, order=c(2,0,0),seasonal = list(order = c(2,1,1),
period = 12),method="ML")
Arima14<- arima(tma_serie, order=c(3,0,0),seasonal = list(order = c(2,1,2),
period = 12),method="ML")

AIC(Arima1,Arima2,Arima3,Arima4,Arima5,Arima6,Arima7,Arima8,Arima9,Arima10,Ari
ma11,Arima12,Arima13,Arima14)
#<AIC=Arima11
      df      AIC
Arima1   3 1110.3131
Arima2   3 1036.8173
Arima3   4 1037.9666
Arima4   3 1123.5438
Arima5   3 1068.5764
Arima6   4 1069.9479
Arima7   4 1101.1189
Arima8   4  991.0370
Arima9   5  992.8416
Arima10  7  995.0768
Arima11  8  987.2690
Arima12  8 1038.3692
Arima13  6 1018.9865
Arima14  8 1311.9576

BIC(Arima1,Arima2,Arima3,Arima4,Arima5,Arima6,Arima7,Arima8,Arima9,Arima10,Ari
ma11,Arima12,Arima13,Arima14)
#<BIC=Arima8
      df      BIC
Arima1   3 1121.655
Arima2   3 1048.160
Arima3   4 1053.090
Arima4   3 1134.886
Arima5   3 1079.919

```

Rcode

```

Arima6  4 1085.071
Arima7  4 1116.242
Arima8  4 1006.160
Arima9  5 1011.745
Arima10 7 1021.542
Arima11 8 1017.515
Arima12 8 1068.615
Arima13 6 1041.671
Arima14 8 1344.048

```

```
coeftest(Arima8)
```

```
z test of coefficients:
```

	Estimate	Std. Error	z value	Pr(> z)
ar1	0.978254	0.017124	57.1262	< 2.2e-16 ***
ma1	-0.777259	0.046789	-16.6119	< 2.2e-16 ***
sma1	-0.999990	0.103492	-9.6625	< 2.2e-16 ***

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
coeftest(Arima11)
```

```
z test of coefficients:
```

	Estimate	Std. Error	z value	Pr(> z)
ar1	0.987978	0.012938	76.3654	< 2.2e-16 ***
ma1	-0.698244	0.054278	-12.8642	< 2.2e-16 ***
ma2	-0.111440	0.051077	-2.1818	0.029123 *
sar1	-0.632800	0.235065	-2.6920	0.007102 **
sar2	-0.147988	0.066738	-2.2174	0.026593 *
sma1	-0.358951	0.237738	-1.5099	0.131081
sma2	-0.573330	0.243410	-2.3554	0.018502 *

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
confint(Arima8)
```

	2.5 %	97.5 %
ar1	0.9446908	1.0118174
ma1	-0.8689643	-0.6855533
sma1	-1.2028307	-0.7971494

```
coeftest(Arima11)
```

```
z test of coefficients:
```

	Estimate	Std. Error	z value	Pr(> z)
ar1	0.987978	0.012938	76.3654	< 2.2e-16 ***
ma1	-0.698244	0.054278	-12.8642	< 2.2e-16 ***
ma2	-0.111440	0.051077	-2.1818	0.029123 *
sar1	-0.632800	0.235065	-2.6920	0.007102 **
sar2	-0.147988	0.066738	-2.2174	0.026593 *
sma1	-0.358951	0.237738	-1.5099	0.131081
sma2	-0.573330	0.243410	-2.3554	0.018502 *

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

7. Diagnóstico de los modelos ARIMA

Para el diagnóstico se utilizó la función “*ggsdiag*” del paquete *ggfortify*. En la Figura 7 se muestra el comportamiento de los residuales del modelo seleccionado *Arima8* (1,0,1) (0,1,1) (12). Se aprecia que los residuales podrían representar ruido blanco, con media en cero, aunque presenta algunos picos importantes de mayor magnitud. La función *acf* no tiene picos significativos pero los *pvalues* son inferiores al valor de significancia, por lo que los residuales no son independientes. Lo anterior invalida el modelo *Arima8* por el incumplimiento de independencia en residuales.




Figura 7. Diagnóstico de residuales del modelo ARIMA: *Arima8* (1,0,1) (0,1,1) (12).

En la Figura 8 se muestra el comportamiento de los residuales del modelo *Arima11* (1,0,2) (2,1,2) (12). Se aprecia que los residuales son muy parecidos al modelo *Arima8*. No tiene picos

significativos en la función de autocorrelación y con *pvalues* superiores al valor de significancia que indican que los residuales son independientes. Lo anterior valida el modelo *Arima11*.




Figura 8. Diagnóstico de residuales del modelo ARIMA: Arima11 (1,0,2) (2,1,2) (12).

Adicionalmente, se realizaron las pruebas de Box-Pierce y Ljung-Box para el modelo seleccionado *Arima2* para examinar la independencia de los residuales, el contraste de hipótesis fue:

H_0 : Los residuales son independientes

H_1 : Los residuales no son independientes

Se obtuvo un *pvalue* de 9513 y de 0.9511 para la prueba de Box-Pierce y Ljung-Box, respectivamente, con un valor de significancia $\alpha > 0.05$. Por lo cual no se rechaza la hipótesis nula y se confirma la independencia de los residuales. Respecto a la normalidad en residuales, se realizó la prueba de Jarque-Bera. El contraste de hipótesis fue:

H₀: Los residuales tienen una distribución normal

H₁: Los residuales no tiene una distribución normal.

Los residuales presentaron un *pvalue* = 0.4382, como es mayor a $\alpha = 0.05$ no se rechaza *H₀* y se concluye que los residuales siguen una distribución normal, tal como se muestra en la Figura 9.




Figura 9. Histograma de residuales y gráfico QQ para normalidad para el modelo *Arima11*.

Rcode

```
### 7. Diagnóstico del modelo
#Arima8
ggtsdiag(Arima8)
Box.test(Arima8$residuals) # Test de Box-Pierce #Independencia
Box-Pierce test

data: Arima8$residuals
X-squared = 3.4566, df = 1, p-value = 0.063
Box.test(Arima8$residuals, type="Ljung-Box") #Independencia
Box-Ljung test

data: Arima8$residuals
X-squared = 3.4876, df = 1, p-value = 0.06183

jarque.bera.test(Arima8$residuals) #Normalidad
```

Rcode

```
Jarque Bera Test

data: Arima8$residuals
X-squared = 2.5209, df = 2, p-value = 0.2835
par(mfrow=c(1,2),cex=0.7)
hist(Arima8$residuals, main="a"),xlab = "Residuales",ylab = "Frecuencia")
qqPlot(Arima8$residuals,distribution = "norm",main = "b"),ylab = "Residuales")
dev.off()

#Arima11
ggtsdiag(Arima11)
Box.test(Arima11$residuals) # Test de Box-Pierce #Independencia
      Box-Pierce test

data: Arima11$residuals
X-squared = 0.003727, df = 1, p-value = 0.9513

Box.test(Arima11$residuals, type="Ljung-Box") #Independencia
      Box-Ljung test

data: Arima11$residuals
X-squared = 0.0037604, df = 1, p-value = 0.9511

jarque.bera.test(Arima11$residuals) #Normalidad
Jarque Bera Test

data: Arima11$residuals
X-squared = 1.6502, df = 2, p-value = 0.4382

par(mfrow=c(1,2),cex=0.7)
hist(Arima11$residuals, main="a"),xlab = "Residuales",ylab = "Frecuencia")
qqPlot(Arima11$residuals,distribution = "norm",main = "b"),ylab =
"Residuales")
dev.off()
```

8. Predicción del modelo y validación.

Finalmente, la predicción de la serie se realizó con la función “*forecast*” del paquete *forecast* para el modelo *Arima11*. Mediante esta función se especifica el modelo que se utiliza para las predicciones, el nivel de confianza para los intervalos de predicción y la cantidad de periodos a predecir (h). El periodo de la serie es de 1985 a 2012, por lo que las predicciones se realizarán para tres periodos futuros, con el objetivo de comparar su capacidad predictiva. Se estableció un intervalo de confianza del 95%.

En la Figura 10 se observa una buena predicción del modelo ajustado *Arima11*. La mejor representación fue a corto plazo, con intervalos de confianza más estrechos, aunque la

predicción hasta tres periodos presenta un patrón bastante similar al conjunto de datos original.




Figura 10. Predicción del modelo *Arima11* para tres periodos.

Para validar cada una de las predicciones por periodos se obtuvieron los valores del error medio (ME), error cuadrático medio (RMSE) y error medio absoluto (MAE). En la Tabla 1 se observa que la predicción a corto plazo fue la que mostró los valores más pequeños de error y como es de esperarse, a medida que aumenta el tiempo la capacidad predictiva del modelo va disminuyendo.

Tabla 1. Error de las predicciones del modelo Arima 11.

Periodo de Predicción	Datos	ME	RMSE	MAE
1 año	Ajuste del modelo	0.0001	1.0155	0.7777
	Validación del modelo	0.7398	1.8912	1.3657

2 años	Ajuste del modelo	0.0001	1.0155	0.7777
	Validación del modelo	1.8881	2.6650	2.2010
3 años	Ajuste del modelo	0.0001	1.0155	0.7777
	Validación del modelo	2.3869	3.0115	2.5955

ME: error medio; RMSE: error cuadrático medio y MAE: error medio absoluto.

Forecasts from ARIMA(1,0,2)(2,1,2)[12]




Figura 11. Predicción del modelo *Arima 11* con el conjunto de validación de 2013 a 2019.

Rcode

```
### 8. Predicción del modelo
##Predicción (con el mejor modelo: ARIMA11)
#Tres periodos
#forecast::forecast()

pred1_arima11<-forecast::forecast(Arima11,h=12, level=c(99.5))
Fig3<-autoplot(pred1_arima11, main = "1 año")

pred2_arima11<-forecast::forecast(Arima11,h=24, level=c(99.5))
Fig4<-autoplot(pred2_arima11, main = "2 años")

pred3_arima11<-forecast::forecast(Arima11,h=36, level=c(99.5))
Fig5<-autoplot(pred3_arima11, main = "3 años")

ggarrange(Fig3, Fig4, Fig5, ncol = 1, nrow = 3)
```

Rcode

9. Validación de la predicción

```
forecast::accuracy(pred1_arma11, tma_test)
```

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.0009866346	1.015533	0.7777794	-0.4634285	5.686091	0.6580117
Test set	0.7398005477	1.891245	1.3657245	4.7827555	9.609332	1.1554211

	ACF1	Theil's U
Training set	0.003330512	NA
Test set	0.198141438	0.7996485

```
forecast::accuracy(pred2_arma11, tma_test)
```

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.0009866346	1.015533	0.7777794	-0.4634285	5.686091	0.6580117
Test set	1.8881224845	2.665048	2.2010844	11.5439035	13.957192	1.8621467

	ACF1	Theil's U
Training set	0.003330512	NA
Test set	0.429850961	1.078075

```
forecast::accuracy(pred3_arma11, tma_test)
```

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.0009866346	1.015533	0.7777794	-0.4634285	5.686091	0.6580117
Test set	2.3869175406	3.011532	2.5955588	14.3211852	15.930044	2.1958773

	ACF1	Theil's U
Training set	0.003330512	NA
Test set	0.530570393	1.244467

```
plotarimapred(tma_test, Arima11, xlim=c(2013, 2019), range.percent = 0.05)
```

Conclusiones

TAREA 6 – B

Pregunta 1.

¿Cuándo una serie es estacional?

Se dice que una serie es estacionaria cuando porque exhibe un comportamiento periódico en un periodo s , y esas similitudes en las series ocurren después de s intervalos de tiempo.

Pregunta 2

¿De qué depende la aplicación práctica de las predicciones?

Depende de los modelos invertibles ajustados a datos reales, los cuales suelen producir previsiones que dependen apreciablemente sólo de valores recientes de la serie.

Los pronósticos son insensibles a pequeños cambios en los valores de los parámetros, como los introducidos por errores de estimación.

Pregunta 3

¿Cuál es la forma más práctica de estimar los pronósticos?

En la práctica, el procedimiento de ecuación en diferencias es, con mucho, la forma más sencilla y conveniente de calcular y actualizar los pronósticos. Sin embargo, las ecuaciones de diferencias en sí no revelan mucho sobre la naturaleza de los pronósticos y su actualización.

Pregunta 4.

¿Cómo se verifica la idoneidad de un modelo ajustado?

Se realiza mediante la verificación de la autocorrelación y la verificación del periodograma

Pregunta 5.

¿Cuál es la estrategia para relacionar modelos multiplicativos o no multiplicativos con los datos?

Puede realizarse mediante la función de autocorrelación como guía:

- La serie se diferencia con respecto a ∇ y / o ∇^s , para producir estacionariedad.
- Mediante inspección de la función de autocorrelación de la serie adecuadamente diferenciada y la selección de un modelo tentativo.

- A partir de los valores de las autocorrelaciones apropiadas de las series diferenciadas, se obtienen estimaciones preliminares de los parámetros. Estos se pueden utilizar como valores iniciales en la búsqueda de estimaciones de mínimos cuadrados o de máxima verosimilitud.
- Después del ajuste, el proceso de verificación de diagnóstico aplicado a los residuos puede llevar a la aceptación del modelo provisional o, alternativamente, puede sugerir formas en las que se puede mejorar, lo que lleva al reacondicionamiento y la repetición de las verificaciones de diagnóstico.