



COLEGIO DE POSTGRADUADOS
INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS
AGRÍCOLAS
CAMPUS MONTECILLO
PROGRAMA DE POSTGRADO EN CIENCIAS FORESTALES

TAREA 7

MODELOS DE INTERVENCIÓN DE BOX-TIAO

EST-624

Dra. Martha Elva Ramírez Guzmán

Zaira Rosario Perez Vazquez

02 de marzo de 2021

Introducción

En algunas ocasiones, las series de tiempo pueden presentar momentos con movimientos bruscos importantes que no son posibles de detectar con una dependencia de su pasado, ya que dichos movimientos pueden tener su origen en intervenciones incontroladas o inesperadas, lo cual da origen a una observación atípica que no guarda relación con el patrón de comportamiento de la serie. Tal movimiento no se explica con un modelo ARIMA clásico. Según Box y Tiao, las observaciones atípicas deben analizarse hasta conocer que los origino y poder tratarlos, considerando sus efectos.

En caso de que una serie presente movimientos bruscos de importancia, estos movimientos pueden tratarse mediante un análisis de intervenciones. Para aplicar esta técnica, se deben identificar dos características de los modelos de intervención, estas características son:

- a) El periodo de comienzo de dichos sucesos externos (intervenciones)
- b) La forma general del impacto de dichas intervenciones

En este caso, se utilizó un conjunto de datos que contiene la información de nacimientos de hombres y mujeres en Londres desde 1629 hasta 1710. La variable de interés es una métrica que representa el exceso fraccional de nacimientos de niños frente a niñas que se define como (chicas – chicos)/chicas. La información fue obtenida en este [enlace](#).

Análisis exploratorio

En primer lugar, se graficaron las series de tiempo: nacimientos (*boys & girls*), los nacimientos totales (obtenida al sumar los nacimientos de ambos géneros) y la serie de métricas de excesos de nacimientos de niños (Figura 1). La variable de interés es la métrica de excesos, aparentemente muestra una estacionariedad en media, pero en varianza posiblemente no. Las dos primeras series muestran cambios estructurales a simple vista y muestran que los chicos tienen una mayor proporción de nacimientos. La serie tiene una media de 0.07 y una desviación estándar de 0.03. La serie presenta una distribución aparentemente normal. El siguiente contraste de hipótesis en la prueba Jarque Bera:

H_0 : la serie de tiempo tiene una distribución normal

H_1 : la serie de tiempo no tiene una distribución normal

Indica que la serie no tiene distribución normal, con un $pvalue = 0.03$ se rechaza H_0 .




Figura 1. Series de tiempo de nacimientos por género, nacimientos totales y exceso de nacimientos de niños.




Figura 2. Histograma de frecuencias, función de densidad y gráfico QQ para la variable de excesos de nacimientos de niños.

R code:

#TAREA 7

#Presenta: Zaira Rosario Pérez Vázquez

#Librerías

```
library(ggplot2)
library(forecast)
library(astsa)
library(fUnitRoots)
library(lmtest)
library(strucchange)
library(reshape)
library(fBasics)
library(FitARMA)
library(Rmisc)
library(tidyverse)
library(magrittr)
library(ggfortify)
library(TSA)
library(dygraphs)
library(dplyr)
library(car)
library(tseries)
```

```
rm(list=ls())
options(max.print = 10000)
setwd("C:/Users/zaira/Documents/Doctorado PCF/3. Cursos/2. Primavera 2021/3.
Series de tiempo/3. Tareas/Tarea 7")
```

```
nacimientos <- read.csv("londres.csv", header=TRUE)
View(nacimientos)
```

####1. Exploración de la serie de tiempo

```
nacimientos_tot_ts<-ts(nacimientos$boys + nacimientos$girls, frequency = 1 ,
                      start = 1629)
exceso_boys<-ts(nacimientos$excess,frequency = 1 ,
               start = 1629)
```

#a) Nacimientos por género

```
nacimientos_rs <- melt(nacimientos[1:3], id = c("year"))
F1<-ggplot(data = nacimientos_rs, aes(x = year)) + geom_line(aes(y = value,
  colour = variable)) +
  scale_colour_manual(values = c("blue", "red"))
```

#b) Nacimientos totales (boys + girls)

```
F2<-autoplot(nacimientos_tot_ts,xlab = "",ylab = "births")
```

#c) Exceso de nacimientos masculinos

```
F3<-autoplot(exceso_boys,xlab = "year",ylab = "excess boys")
multiplot(F1,F2,F3)
```

```
basicStats(exceso_boys)
```

```
      exceso_boys
nobs      82.000000
NAs        0.000000
```

R code:

```

Minimum      0.010673
Maximum      0.156075
1. Quartile  0.048469
3. Quartile  0.087510
Mean         0.070748
Median       0.064704
Sum          5.801343
SE Mean      0.003451
LCL Mean     0.063881
UCL Mean     0.077615
Variance     0.000977
Stdev        0.031254
Skewness     0.680042
Kurtosis     0.073620

```

```

par(mfrow=c(1,3),cex=0.9)
hist(exceso_boys,main = "a"),xlab = "Nacimientos",ylab = "Frecuencia")
plot(density(exceso_boys), main = "b"),ylab = "Densidad")
qqPlot(exceso_boys,dist="norm",ylab = "Nacimientos",main = "c")
dev.off()
jarque.bera.test(exceso_boys)
      Jarque Bera Test

```

```

data:  exceso_boys
X-squared = 6.6341, df = 2, p-value = 0.03626

```

🚩 Detección de outliers

Para identificar datos atípicos se utilizó la función “tso” del paquete *tsoutliers*. Esta función considera cinco tipos de outliers: outliers aditivos (AO), cambios de nivel (LS), cambios temporales (TC), outliers innovadores (IO) y cambios de nivel estacional (SLS). En la Figura 3 se muestra el outlier detectado de tipo TC en el año 1659.




Figura 3. Detección de outliers en la serie de tiempo de excesos de nacimientos de niños.

Dado que la serie de tiempo original no es estacionaria en varianza, también se utilizó esta función con la serie transformada a logaritmo. En esta ocasión, se detectan dos outliers, el primero de tipo TC en 1659, previamente identificado, y el segundo de tipo AO en 1703 (Figura 4).




Figura 4. Detección de outliers en la serie de tiempo de excesos de nacimientos de niños transformada a logaritmo.

R code:

```
### 2. Analisis de datos atípicos
bp<-boxplot(exceso_boys)
bp$out

library(tsoutliers)
?tso
(outliers_excesoboys<-tso(exceso_boys))
Series: exceso_boys
Regression with ARIMA(0,0,0) errors

Coefficients:
    intercept    TC31
      0.0665    0.1049
s.e.      0.0031    0.0199

sigma^2 estimated as 0.0007378:  log likelihood=180.34
AIC=-354.69  AICc=-354.38  BIC=-347.47

Outliers:
  type ind time coefhat tstat
1  TC  31 1659  0.1049 5.283
plot(outliers_excesoboys)
```

R code:

```
#¿Es igual con la serie transformada a logaritmo?
exceso_boys_log<-log(exceso_boys)
autoplot(exceso_boys_log)
(outliers_excesoboy_log<-tso(exceso_boys_log))
Series: exceso_boys_log
Regression with ARIMA(0,0,0) errors

Coefficients:
      intercept      TC31      A075
      -2.7769    1.1429   -1.7631
s.e.      0.0458    0.2941    0.3998

sigma^2 estimated as 0.1637:  log likelihood=-40.63
AIC=89.26   AICc=89.78   BIC=98.88

Outliers:
  type ind time coefhat  tstat
1   TC  31 1659   1.143   3.886
2   AO  75 1703  -1.763  -4.410

plot(outliers_excesoboy_log)
```

Cambios estructurales de nivel

La señal de la serie fue graficada utilizando la función de regresión local polinomial “*loess*” del paquete *stats*; en este caso, se utilizó un nivel de suavizamiento de 0.2. Se observa un incremento en la cantidad de nacimientos de niños a partir de 1650 hasta 1670. Para la estimación del nivel de la serie, se utilizó un modelo de regresión lineal. El nivel de la serie fue significativo ($\alpha < 0.001$) y se encuentra en un valor de 0.07 (Figura 5). El número de puntos de corte óptimos para detectar cambios de nivel y de tendencia se obtuvo mediante la función “*breakpoints*” del paquete *strucchange*. Se utilizó un porcentaje de observaciones $h = 0.1$. Se espera que la suma de cuadrados para cada break sea lo menor posible. Para la detección de cambios de nivel, en la se observa que solo hay un punto óptimo de corte con el valores de BIC más pequeño. El año de corte fue en 1670, aproximadamente a la mitad del periodo evaluado y bastante cercano al outlier detectado en 1659 (Figura 6). No se detectaron cambios estructurales en tendencia significativos.




Figura 5. Señal y nivel de la serie de tiempo de excesos de nacimientos de niños.

La proporción de nacimientos de niños y niñas al nacer cambió de 0.08 a 0.05. Se realizó una prueba de t con la función $t.test$ para verificar si la diferencia en la media es significativa en las dos ventanas de tiempo identificadas por la fecha del punto de corte, año 1670. Para realizar esta prueba, se consideró este año como un evento de intervención. Se definieron dos ventanas de tiempo mediante la función *window* del paquete *timeSeries*, una para el tiempo previo a este año y otra para el tiempo posterior. El contraste de hipótesis para la prueba de t es el siguiente:

H_0 : la diferencia entre medias de las series es igual a cero

H_1 : la diferencia entre medias de las series es diferente de cero

El $pvalue$ obtenido fue menor a $\alpha = 0.05$, por lo que se rechaza H_0 . Se asume que existe una diferencia significativa entre las medias de ambos periodos.

Una vez que la intervención fue detectada, es importante conocer que influencio o causo ese cambio estructural. En este caso, el periodo de guerra de esa época pudo ejercer algún efecto

que este relacionado con esta intervención. La serie de tiempo cubre el periodo de guerra civil inglesa que sucedió entre 1642 y 1651. Contrastando con la serie de la Figura 1, se observa una fuerte caída en los nacimientos de ambos géneros que coincide con el periodo de guerra, escasez de recursos y hambruna, por lo que se puede inferir que fue causa de la guerra civil.




Figura 6. Suma de cuadrados residuales y criterio de información bayesiano (BIC), gráfica de segmentos (breaks = 1) para cambios de nivel en la serie de tiempo de excesos en nacimientos de niños.

```
### 3. Cambios estructurales
# a) Identificación de la señal de la serie
tt_exceso <- 1:length(exceso_boys)
```

R code:

R code:

```

fit_exceso <- ts(loess(exceso_boys ~ tt_exceso, span = .2)$fitted, start =
1629, frequency = 1)

plot.ts(fit_exceso, type='l',ylab="values")
grid()
lines(exceso_boys, col = "red")

# b) Estimación del nivel de la serie (y=bo+e)
fit_level_exceso<-lm(exceso_boys~1)
summary(fit_level_exceso)
Call:
lm(formula = exceso_boys ~ 1)

Residuals:
    Min       1Q   Median       3Q      Max
-0.060075 -0.022279 -0.006044  0.016762  0.085327

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.070748    0.003451   20.5   <2e-16 ***
---
Signif. codes:
  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.03125 on 81 degrees of freedom
plot.ts(exceso_boys, main="",ylab="values")
grid()
lines(ts(fitted(fit_level_exceso), start=1629, frequency = 1), col = "red")

# c) Cambios estructurales de tendencia
excesos_brk_trend <- breakpoints(exceso_boys ~ tt_exceso, h = 0.1)
summary(excesos_brk_trend)
plot(excesos_brk_trend)
#Nota: De acuerdo con BIC, no existen cambios estructurales de tendencia

# d) Identificación de cambios estructurales de nivel
#Breakpoints
excesos_brk <- breakpoints(exceso_boys ~ 1, h = 0.1)
summary(excesos_brk)
plot(excesos_brk)
#Nota: De acuerdo con BIC, aproximadamente existe 1 cambios de nivel
breakdates(excesos_brk, breaks = 1)
plot(exceso_boys,col="dark gray",ylab="values")
lines(fitted(excesos_brk, breaks = 1), col = 4)
lines(confint(excesos_brk, breaks = 1))
coef(excesos_brk, breaks = 1)

# e) Tasa del cambio de nivel
fitted(excesos_brk)[1]
fitted(excesos_brk)[length(exceso_boys)]
#La tasa de cambio fue de 0.08 a 0.05

# f) Significancia en las medias

```

R code:

```
(break_date<-breakdates(excesos_brk))
[1] 1670
pre_interv<-window(exceso_boys,end=break_date)
post_interv<-window(exceso_boys,start=break_date+1)
t.test(pre_interv,post_interv)

Welch Two Sample t-test

data: pre_interv and post_interv
t = 3.5773, df = 70.961, p-value = 0.0006305
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 0.01012671 0.03563322
sample estimates:
 mean of x mean of y
0.08190905 0.05902908
```

🚦 Prueba de raíz unitaria

Para determinar si la serie transformada a logaritmo tiene raíz unitaria se ajustó un modelo autorregresivo. El orden obtenido fue igual a 1. Ahora con la función *adfTest* del paquete *FUnitRoots* se realizó la prueba de Dickey – Fuller aumentada. Esta función permite especificar el tipo de regresión de raíz unitaria: a) la prueba de raíz unitaria, b) la prueba con deriva o constante $\neq 0$ y c) la prueba de raíz unitaria con deriva y tendencia temporal determinista. Para conocer si hay pendiente, así como el valor de la constante y su significancia, se ajustó un modelo de regresión lineal. El contraste de hipótesis de la prueba *adfTest* fue:

H_0 : la serie de tiempo tiene raíz unitaria

H_1 : la serie de tiempo no tiene una raíz unitaria

Se obtuvo un valor de significancia *pvalue* = 0.01, por lo que se asume que la serie no tiene raíz unitaria.

R code:

```
### 4. Prueba de raíz unitaria
autoplot(exceso_boys)
autoplot(exceso_boys_log)
acf(exceso_boys)
acf(exceso_boys_log) #Son estacionarias, no se necesita diferenciar

mod1=ar(exceso_boys_log,method="mle")
mod1$order
[1] 1
```

R code:

```
# ¿Hay pendiente? ¿Cuánto vale la constante?
t_exceso=seq(1:length(exceso_boys_log))
mod2=lm((exceso_boys_log)~t_exceso)
summary(mod2) #La constante es significativa
Call:
lm(formula = (exceso_boys_log) ~ t_exceso)

Residuals:
    Min       1Q   Median       3Q      Max
-1.64530 -0.30880  0.04457  0.34857  0.85829

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -2.575035    0.104896  -24.549  <2e-16 ***
t_exceso     -0.004263    0.002196   -1.942   0.0557 .
---
Signif. codes:
  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4706 on 80 degrees of freedom
Multiple R-squared:  0.045,    Adjusted R-squared:  0.03306
F-statistic:  3.77 on 1 and 80 DF,  p-value: 0.05572

adfTest(exceso_boys_log,lags=1,type=c("c")) #serie estacionaria
Title:
Augmented Dickey-Fuller Test

Test Results:
PARAMETER:
  Lag Order: 1
STATISTIC:
  Dickey-Fuller: -5.5301
P VALUE:
  0.01

ndiffs(exceso_boys_log)
[1] 0
```

🚦 Funciones de autocorrelación acf y pacf

La función de autocorrelación presenta dos picos significativos que sugieren la presencia de un componente estacional con un periodo (S) igual a 10. La función de autocorrelación parcial presenta dos picos significativos (Figura 7).




Figura 7. Función de autocorrelación acf y pacf para la serie de excesos de nacimientos de niños transformada a logaritmo.

5. Funciones acf y pacf

```
acf(exceso_boys_log)
pacf(exceso_boys_log)
```

```
acf2(exceso_boys_log)
#S=10
```

R code:

🚦 Modelo ARIMA sin intervención

Se definieron tres modelos ARIMA (p, d, q) (P, D, Q) (S) para toda la serie de tiempo transformada a logaritmo, sin considerar el evento de intervención. El primer modelo incorporo un parámetro autorregresivo: ARIMA (1, 0, 0) (1, 0, 0) (10). El segundo modelo incorporó un parámetro de promedios móviles: ARIMA (0, 0, 1) (0, 0, 1) (10). El tercer modelo incorporo ambos parámetros: ARMA (1, 0, 1) (1, 0, 1) (10). De acuerdo con los valores obtenidos de AIC y BIC, el mejor modelo es el del componente autorregresivo *Arima1*, con valores de 116.95 y 107.33, respectivamente.

R code:

```
### 6. Modelo ARIMA sin intervencion
#Modelo ARIMA (p,d,q)(P,D,Q)(S) #S=10

#a) ARIMA1(1, 0, 0) (1, 0, 0) (10).
ARIMA1 <- Arima(exceso_boys_log, order = c(1,0,0),
                seasonal = list(order = c(1,0,0),
                                period = 10),include.mean = TRUE)

summary(ARIMA1)
coeftest(model_1)
z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ar1      0.2636602  0.1069472  2.4653  0.013689 *
sar1      0.3185397  0.1027903  3.0989  0.001942 **
intercept 0.0704636  0.0058313 12.0836 < 2.2e-16 ***
---
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

# b) ARIMA2(0, 0, 1) (0, 0, 1) (10).
ARIMA2 <- Arima(exceso_boys_log, order = c(0,0,1),
                seasonal = list(order = c(0,0,1),
                                period = 10),include.mean = TRUE)

summary(ARIMA2)
coeftest(model_2)
z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
sma1      0.3437109  0.1135387  3.0273  0.002468 **
intercept 0.0817445  0.0052825 15.4745 < 2.2e-16 ***
xreg      -0.0225294  0.0072468 -3.1089  0.001878 **
---
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

# c) ARIMA3(1, 0, 1) (1, 0, 1) (10).
ARIMA3 <- Arima(exceso_boys_log, order = c(1,0,1),
                seasonal = list(order = c(1,0,1),
                                period = 10),include.mean = TRUE)

summary(ARIMA3)
coeftest(ARIMA3)
z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ar1      -0.230650  0.428383 -0.5384  0.5903
ma1       0.471936  0.386571  1.2208  0.2222
sar1      0.357892  0.415233  0.8619  0.3887
sma1     -0.046277  0.443936 -0.1042  0.9170
intercept -2.756003  0.081534 -33.8017 <2e-16 ***
---
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

R code:

```
AIC(ARIMA1,ARIMA2,ARIMA3)
```

```
ARIMA1  4 107.3308
```

```
ARIMA2  4 107.4857
```

```
ARIMA3  6 110.6740
```

```
BIC(ARIMA1,ARIMA2,ARIMA3)
```

```
          df      BIC
```

```
ARIMA1  4 116.9576
```

```
ARIMA2  4 117.1126
```

```
ARIMA3  6 125.1143
```

```
#Mejor: ARIMA1
```

🚦 Modelo ARIMA con intervención

Se definieron los mismos modelos ARIMA pero ahora consideran el cambio de nivel resaltado por el análisis estructural y su componente estacional. Para representar el cambio estructural como cambio de nivel se definió una variable regresora denominada “*nivel*”, la cual fue igual a cero para los registros precedentes a 1670 y se le asignó el valor de 1 a los registros posteriores a ese año (Figura 8). Este procedimiento se realizó también de forma manual en el archivo Excel adjunto. De esta forma, se representa el cambio de nivel permanente de forma escalonada. Esta variable se incorpora en la función “*arima*” como argumento *xreg*.




Figura 8. Variable regresora de cambio de nivel en el año 1670.

El modelo de componentes autorregresivos *Arima4*: ARIMA (1, 0, 0) (1, 0, 0) (10) con la inclusión de la intervención, fue el modelo con los valores más inferiores de AIC y BIC, con valores de 103.45 y 115.48, respectivamente.

R code:

```
### 7. Creación de variable regresora de intervencion
nivel <- c(rep(0, excesos_brk$breakpoints),
           rep(1, length(exceso_boys_log) - excesos_brk$breakpoints))

plot(data.frame(nacimientos$year,nivel),pch=20,ylim=c(0,1),ylab="Value",xlab="
Year")

### 8. Modelo ARIMA con intervención
#ARIMA4 (1, 0, 0) (1, 0, 0) (10).
ARIMA4 <- Arima(exceso_boys_log, order = c(1,0,0),
                seasonal = list(order = c(1,0,0), period = 10),
                xreg = nivel, include.mean = TRUE)

summary(ARIMA4)
coeftest(ARIMA4)
z test of coefficients:

            Estimate Std. Error  z value Pr(>|z|)
ar1         0.153574   0.108878   1.4105  0.15839
sar1        0.281487   0.114315   2.4624  0.01380 *
intercept -2.589476   0.097793 -26.4792 < 2e-16 ***
xreg        -0.336547   0.131665  -2.5561  0.01059 *
---
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

#ARIMA5 (0, 0, 1) (0, 0, 1) (10).
ARIMA5 <- Arima(exceso_boys_log, order = c(0,0,1),
                seasonal = list(order = c(0,0,1), period = 10),
                xreg = nivel, include.mean = TRUE)

summary(ARIMA5)
coeftest(ARIMA5)
z test of coefficients:

            Estimate Std. Error  z value Pr(>|z|)
ma1         0.177584   0.121666   1.4596  0.14440
sma1        0.263987   0.108633   2.4301  0.01510 *
intercept -2.591312   0.092337 -28.0638 < 2e-16 ***
xreg        -0.326871   0.127476  -2.5642  0.01034 *
---
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

#ARIMA6 (1, 0, 1) (1, 0, 1) (10).
ARIMA6 <- Arima(exceso_boys_log, order = c(1,0,1),
                seasonal = list(order = c(1,0,1), period = 10),
                xreg = nivel, include.mean = TRUE)

summary(ARIMA6)
```


R code:

```

coeftest(ARIMA6)
z test of coefficients:

      Estimate Std. Error  z value Pr(>|z|)
ar1      -0.404280   0.348968  -1.1585  0.24666
ma1       0.593274   0.302445   1.9616  0.04981 *
sar1      0.407174   0.440007   0.9254  0.35477
sma1     -0.115455   0.468865  -0.2462  0.80549
intercept -2.589540   0.096663 -26.7893 < 2e-16 ***
xreg      -0.342275   0.128372  -2.6663  0.00767 **
---
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

AIC(ARIMA4,ARIMA5,ARIMA6)
      df      AIC
ARIMA4  5 103.4559
ARIMA5  5 103.4649
ARIMA6  7 106.0639
BIC(ARIMA4,ARIMA5,ARIMA6)
      df      BIC
ARIMA4  5 115.4895
ARIMA5  5 115.4985
ARIMA6  7 122.9109
#Mejor: ARIMA4

```

Diagnóstico del modelo

Al comparar todos los modelos ARIMA con y sin intervención se observó que los valores de AIC y BIC disminuyeron al incorporar la variable regresora. El modelo con menor AIC y BIC fue el modelo *Arima4*. Para verificar que los residuales sean ruido blanco se utilizó la función “*checkresiduals*” del paquete *ggfortify*. Los residuales presentan un comportamiento estable alrededor de la media, no presentan picos significativos en su función de autocorrelación y son independientes, por lo cual se asume que son ruido blanco y se valida el modelo *Arima4*. Respecto a la normalidad en residuales, el contraste de hipótesis en la prueba de Jarque Bera confirman la normalidad en residuales, con un *pvalue* = 0.07.




Figura 9. Diagnóstico del modelo Arima4: ARIMA (1, 0, 0) (1, 0, 0) (10) con intervención en 1670.




Figura 10. Histograma de residuales y gráfico QQ para normalidad para el modelo Arima4: ARIMA (1, 0, 0) (1, 0, 0) (10) con intervención en 1670.

R code:

```

### 9. Diagnóstico del modelo
#¿Comparando todos?
AIC(ARIMA1,ARIMA2,ARIMA3,ARIMA4,ARIMA5,ARIMA6)
      df      AIC
ARIMA1  4 107.3308
ARIMA2  4 107.4857
ARIMA3  6 110.6740
ARIMA4  5 103.4559
ARIMA5  5 103.4649
ARIMA6  7 106.0639
BIC(ARIMA1,ARIMA2,ARIMA3,ARIMA4,ARIMA5,ARIMA6)
      df      BIC
ARIMA1  4 116.9576
ARIMA2  4 117.1126
ARIMA3  6 125.1143
ARIMA4  5 115.4895
ARIMA5  5 115.4985
ARIMA6  7 122.9109

#Mejor: ARIMA4
#Nota. Los valores de AIC y BIC disminuyeron al incorporar
#... la variable regresora de intervención

ggtsdiag(ARIMA4)
Box.test(ARIMA4$residuals) # Test de Box-Pierce #Independencia
Box-Pierce test

data: ARIMA4$residuals
X-squared = 0.020915, df = 1, p-value = 0.885
Box.test(ARIMA4$residuals, type="Ljung-Box") #Independencia
Box-Ljung test

data: ARIMA4$residuals
X-squared = 0.021689, df = 1, p-value = 0.8829
jarque.bera.test(ARIMA4$residuals) #Normalidad
Jarque Bera Test

data: ARIMA4$residuals
X-squared = 5.1284, df = 2, p-value = 0.07698
par(mfrow=c(1,2),cex=0.7)

hist(ARIMA4$residuals, main="a"),xlab = "Residuales",ylab = "Frecuencia")
qqPlot(ARIMA4$residuals,distribution = "norm",main = "b"),ylab =
"Residuales")
dev.off()

```

🔗 Predicción de los modelos

Finalmente, la predicción de la serie se realizó con la función “*forecast*” del paquete forecast para el modelo Arima11. Mediante esta función se especifica el modelo que se utiliza para las

predicciones, el nivel de confianza para los intervalos de predicción y la cantidad de periodos a predecir (h). Se seleccionaron tres periodos futuros (5, 10 y 20 años). Como es de esperar, la serie predice mejor en los primeros cinco años.




Figura 11. Predicción del modelo Arima4. Predicciones en logaritmo de la serie de exceso de nacimientos de niños.

10. Predicción del modelo

```
pred1<-forecast(ARIMA4, h = 5, xreg = rep(1, 5))
F1<-autoplot(pred1,main="a)")

pred2<-forecast(ARIMA4, h = 10, xreg = rep(1, 10))
F2<-autoplot(pred2,main="b)")

pred3<-forecast(ARIMA4, h = 20, xreg = rep(1, 20))
F3<-autoplot(pred3,main="c)",xlab="Year")

multiplot(F1,F2,F3)
```

R code:

Conclusiones

El análisis de cambios estructurales permitió incorporar definir modelos con mejor métrica AIC y BIC al introducir una variable regresora de escalón que identificara ese cambio en el nivel. Estos modelos de intervención basados en Arima permitieron evaluar el impacto que tuvo la guerra civil sobre la tasa de nacimientos de niños y de esta forma, mejorar las predicciones en las estimaciones de la variable de interés.