



COLEGIO DE POSTGRADUADOS
INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS
AGRÍCOLAS
CAMPUS MONTECILLO
PROGRAMA DE POSTGRADO EN CIENCIAS FORESTALES

TAREA 8, 9

MODELOS DE INTERVENCIÓN Y TRANSFERENCIA

EST-624. Series de Tiempo

Dra. Marta Elva Ramírez Guzmán

Zaira Rosario Perez Vazquez

15 de marzo de 2021

Introducción

Cuando un modelo de regresión dinámica incluye una variable exógena X que predice la variable de respuesta Y , se utilizará algún tipo de estimación de parámetro para determinar cuál es el efecto de X en Y . Esta estructura de parámetro se llama función de transferencia. Entonces este parámetro puede tomar varias formas:

- i. Un coeficiente en la forma βX_t . Esta es una forma más intuitiva de modelo de función de transferencia y lee el coeficiente beta como un simple coeficiente beta de regresión lineal. Esto significa que un valor actual de X predice un valor actual de Y . Por lo tanto, la parte de la serie temporal pasa al término de error. Por tanto, este modelo es una regresión con errores ARIMA. La regresión con errores ARIMA es un caso especial de modelo de función de transferencia. En pocas palabras, ARIMAX = Regresión con errores ARIMA < Modelos de función de transferencia.
- ii. Un poco más complejo que la opción anterior es tener una estructura autorregresiva (AR) para explicar la variable Y . Eso podría escribirse como:

$$\phi(L)y_t = \delta + \theta_0 x_t + u_t$$

Comparado con la fórmula anterior, la única diferencia es que ahora el coeficiente theta para X_t se ha convertido en un polinomio. La serie X ahora también tiene en cuenta los efectos retardados de los valores pasados de X . Comúnmente, theta (L) se define como un polinomio de orden q y phi (L) es un polinomio de orden- p . phi (L) es la parte AR, porque proviene del proceso autorregresivo de la serie Y ; theta (L) es la parte DL, porque muestra los efectos retardados distribuidos de la serie X . Juntos, estos modelos se denominan modelos de retardo distribuido autorregresivo.

En este caso, se analizaron los precios mensuales de la gasolina en Turquía entre 2013 y 2020 (84 observaciones). Los datos fueron obtenidos del siguiente vinculo ([enlace](#)). Una de las variables que posiblemente influye sobre los precios de la gasolina de este país es el precio del crudo Brent, que es el petróleo de referencia en el mercado europeo y una de las tres principales referencias para los inversores en petróleo.

Análisis exploratorio

Se definió al precio de la gasolina mensual como la variable dependiente (Y_t) y al precio del petróleo Brent (X_t) como la variable independiente. En la Tabla 1 se muestran los estadísticos clásicos para describir cada una de las variables. Los valores fueron obtenidos mediante la función “*basicStats*” del paquete *fBasics*.

Tabla 1. Estadística descriptiva de las variables.

Variable	Mínimo	Máximo	Media	Mediana	Varianza	Desviación estándar	Asimetría	Curtosis
Gasolina (Y)	4.10	7.00	5.26	5.05	0.72	0.85	0.75	-0.72
Precio de Brent (X_1)	34.74	115.55	71.18	64.83	550.50	23.46	0.60	-0.99

Rcode

```
rm(list=ls())
options(max.print = 10000)
setwd("C:/Users/zaira/Documents/Doctorado PCF/3. Cursos/2. Primavera 2021/3.
Series de tiempo/3. Tareas/Tarea 8")
getwd()

### 1. Leer datos.
library(readr)
datos_petroleo <- read_csv("datos_petroleo.csv")
View(datos_petroleo)

#Librerías
library(tseries)
library(ggfortify)
library(fBasics)
library(car)
library(tidyverse)
library(ggplot2)
library(Rmisc)
library(forecast)
library(nortest)
library(strucchange)
library(tsoutliers)

library(fUnitRoots)
library(astsa)
library(dplyr)
library(lmtest)
library(aTSA)
library(TSA)

#Definir variables
gasolinaY_ts <- ts(datos_petroleo$gasolina,start = c(2013,01),frequency = 12)
```

Rcode

```
brentX_ts <- ts(datos_petroleo$brent,start = c(2013,01),frequency = 12)

### 1. Análisis exploratorio de Yt y Xt
basicStats(gasolinaY_ts)
basicStats(brentX_ts)
```

a) Variable dependiente

En la Figura 1 se muestra que la serie de tiempo “precio de gasolina” no es estacionaria en media y varianza, además no se observa una estacionalidad marcada. Aparentemente, el precio de la gasolina no tiene una distribución normal de acuerdo con los histogramas de frecuencia, su función de densidad y el gráfico QQ. Se utilizó la prueba Jarque Bera para probar normalidad en la serie de tiempo. La prueba de hipótesis fue la siguiente:

H_0 : la serie de tiempo tiene una distribución normal

H_1 : la serie de tiempo tiene una distribución normal

Se obtuvo un valor de significancia igual a 0.00721, por lo que se rechaza H_0 y, por lo tanto, la serie de tiempo no tiene una distribución normal.

Rcode

```
## a) Análisis exploratorio de Y
autoplot(gasolinaY_ts,xlab = "Tiempo",ylab = "Gasolina (US$)",main = "a")
par(mfrow=c(1,3),mar=c(5,4,3,1),cex=0.6)
hist(gasolinaY_ts,main = "b",xlab = "Gasolina (US$)",ylab = "Frecuencia")
plot(density(gasolinaY_ts), main = "c",ylab = "Densidad")
qqPlot(gasolinaY_ts,dist="norm",ylab = "Gasolina (US$)",main = "d")
dev.off()
jarque.bera.test(gasolinaY_ts)
      Jarque Bera Test
data:  gasolinaY_ts
X-squared = 9.8644, df = 2, p-value = 0.00721
```




Figura 1. Gráficos descriptivos de la serie de tiempo “Precio de gasolina”: a) Serie de tiempo, b) Histograma de frecuencias, c) Función de densidad y d) Gráfico QQ para normalidad.

Para poder utilizar la metodología de Box y Jenkins se evaluó si la transformación logarítmica o Boxcox permiten el cumplimiento de este supuesto. La transformación logarítmica obtuvo un $pvalue = 0.025$ en la prueba de Jarque Bera, mientras que la transformación BoxCox obtuvo un $pvalue = 0.0404$ en el mismo test, acercando bastante los datos a una distribución normal con un valor $\lambda = -0.4164$ (Figura 2). El procedimiento se realizó con las funciones “*BoxCox.lambda*” y “*BoxCox*” del paquete *forecast*.

Rcode

```
## b) Transformación de Yt
#Transformación logarítmica
jarque.bera.test(log(gasolinaY_ts))
Jarque Bera Test

data: log(gasolinaY_ts)
X-squared = 7.3201, df = 2, p-value = 0.02573
```

#Transformación BoxCox

```
(lambdaY<-BoxCox.lambda(gasolinaY_ts))
[1] -0.4164669
gasolinaY_BC<-BoxCox(gasolinaY_ts,lambda = lambdaY)
jarque.bera.test(gasolinaY_BC)
Jarque Bera Test
```

```
data: gasolinaY_BC
X-squared = 6.4138, df = 2, p-value = 0.04048
```

#Comparación entre transformaciones

```
par(mfrow=c(2,3),mar=c(5,4,3,1),cex=0.6)
hist(gasolinaY_ts,main = "Original",xlab = "Gasolina (US$)",ylab = "Frecuencia")
hist(log(gasolinaY_ts),main = "Logarítmica",xlab = "Gasolina (US$)",ylab = "Frecuencia")
hist(gasolinaY_BC,main = expression(paste("BoxCox (", lambda, " = -",
0.4164)")),xlab = "Gasolina (BoxCox)",ylab = "Frecuencia")
qqPlot(gasolinaY_ts,dist="norm",ylab = "Gasolina (US$)",main = "")
qqPlot(log(gasolinaY_ts),dist="norm",ylab = "Gasolina (US$)",main = "")
qqPlot(gasolinaY_BC,dist="norm",ylab = "Gasolina (US$)",main = "")
dev.off()
```




Figura 2. Histogramas de frecuencia y gráficos QQ para evaluar normalidad en la serie de tiempo “precio de gasolina”: serie original, serie con transformación logarítmica y serie con transformación BoxCox.

b) Variables independientes

En la Figura 3 se observa que la serie de tiempo “precio del petróleo Brent” tuvo una disminución notable a mediados del año 2015 y un ligero incremento a mediados del año 2017, este desplome en el precio del Brent aparentemente está relacionado con una crisis económica de los países europeos ([enlace](#)). No se observa la presencia de estacionalidad y tanto el histograma como el gráfico QQ muestran que la serie no tiene un comportamiento normal. En la prueba de Jarque Bera se obtuvo un $pvalue = 0.014$ por lo que se rechazó H_0 , lo que indica que la serie no tiene una distribución normal. Se aplicó una transformación BoxCox con un valor $\lambda = -0.047$, la prueba de Jarque Bera ($pvalue = 0.1965$) indicó que con esta transformación la serie ya seguía una distribución normal.




Figura 3. Gráficos descriptivos de la serie de tiempo “Precio de Brent”: a) Serie de tiempo, b) Histograma de frecuencias, c) Función de densidad y d) Gráfico QQ para normalidad.

```
## c) Análisis exploratorio de X1
autoplot(brentX_ts,xlab = "Tiempo",ylab = "Brent (US$)",main = "a")
par(mfrow=c(1,3),mar=c(5,4,3,1),cex=0.6)
hist(brentX_ts,main = "b",xlab = "Brent (US$)",ylab = "Frecuencia")
plot(density(brentX_ts), main = "c",ylab = "Densidad")
qqPlot(brentX_ts,dist="norm",ylab = "Gasolina (US$)",main = "d")
dev.off()
jarque.bera.test(brentX_ts)
Jarque Bera Test

data:  brentX1_ts
X-squared = 8.4456, df = 2, p-value = 0.01466

## d) Transformación BoxCox de Xt
(lambdaX1<-BoxCox.lambda(brentX_ts))
brentX1_BC<-BoxCox(brentX_ts,lambda = lambdaX1)
hist(brentX1_BC,main = "",xlab = "Brent (BC)",ylab = "Frecuencia")
qqPlot(brentX1_BC,dist="norm",ylab = "Brent (BC)",main = "")
jarque.bera.test(brentX1_BC)
Jarque Bera Test

data:  brentX1_BC
X-squared = 3.2539, df = 2, p-value = 0.1965
```

Identificación y señal de la serie dependiente

La señal de la serie fue graficada utilizando la función de regresión local polinomial “*loess*” del paquete *stats*; en este caso, se utilizó un nivel de suavizamiento de 0.2. Se observa que el precio de la gasolina ha sido bastante cambiante a lo largo del periodo evaluado. Para estimar el nivel de la serie se utilizó un modelo de regresión lineal. El nivel de la serie de los precios de la gasolina fue muy significativo ($\alpha = 0.001$) con un valor de 1.19 (Figura 4).

```
### 2. Identificación de la señal y nivel de la serie Y
## a) Señal de la serie
par(mfrow=c(2,1),cex=0.9,mar=c(5,4,3,1),cex=0.6)
tt_gas<-1:length(gasolinaY_BC)
fit_gas<-ts(loess(gasolinaY_BC~tt_gas,span      =      0.2)$fitted,start      =
2013,frequency=12)
plot.ts(fit_gas,type="l",main="a",ylab=expression(paste("Gasolina (", lambda,
" = -0.4164)")))
grid()
lines(gasolinaY_BC,col="Red")
```



```
## b) Nivel de la serie
fitlevel_gas<-lm(gasolinaY_BC~1)
summary(fitlevel_gas)
plot.ts(gasolinaY_BC,main="b"),ylab=expression(paste("Gasolina (", lambda, " = 
-0.4164)"))
lines(ts(fitted(fitlevel_gas),start = 2013,frequency = 12),col="red")
dev.off()
```




Figura 4. a) Señal de la serie. b) Nivel de la serie "precios de gasolina de Turquía".

🚦 Identificación de cambios estructurales en la serie dependiente.

a) Cambios de nivel

Para identificar los cambios estructurales en la serie dependiente “precios de gasolina” se utilizó un porcentaje de observaciones $h = 0.1$. En la Figura 5 se observa que el valor más bajo de BIC fue con seis puntos de corte óptimos, los cuales corresponden a noviembre 2013, octubre 2014, septiembre 2016, agosto 2017, abril 2018, febrero 2019 y diciembre 2019 (Figura 6).




Figura 5. Suma de cuadrados residuales y criterio de información bayesiano (BIC) para cambios de nivel en el precio de la gasolina de Turquía.




Figura 6. Gráfica de segmentos ($breaks = 6$) para cambios de nivel en los precios de gasolina de Turquía.

b) Cambios de tendencia

Para la detección de cambios estructurales de tendencia se ajustó nuevamente un modelo de regresión lineal a la serie transformada. La tendencia de la serie fue significativa ($\alpha < 0.01$) y marcadamente ascendente (Figura 7), por lo cual la serie no es estacionaria en media. De acuerdo con los valores de BIC, el número de puntos de corte óptimos fue igual a seis (Figura

8), que corresponden a marzo 2014, noviembre 2014, julio 2015, marzo 2016, abril 2017, octubre 2018 y diciembre 2020 (Figura 9).




Figura 7. Tendencia de la serie "precios de gasolina en Turquía".




Figura 8. Suma de cuadrados residuales y criterio de información bayesiano para cambios de tendencia en los precios de gasolina de Turquía.




Figura 9. Gráfico de segmentos (*breaks* = 6) para cambios de tendencia en la serie de tiempo de precios de gasolina en Turquía.

Rcode

```
### 3. Cambios estructurales Y
## a) Cambios de nivel
gasBC_brk<-breakpoints(gasolinaY_BC~1,h=0.1)
summary(gasBC_brk)
par(mfrow=c(1,1),cex=0.9,mar=c(5,4,3,1))
plot(gasBC_brk) #BIC=6 brk
breakdates(gasBC_brk,breaks = 6)
plot(gasolinaY_BC,col="dark gray",ylab=expression(paste("Gasolina (", lambda, "
= -0.4164)")),xlab="Tiempo")
lines(fitted(gasBC_brk,breaks = 6),col=4)
lines(confint(gasBC_brk,breaks = 6))
coef(gasBC_brk,breaks = 6)
      (Intercept)
2013(1) - 2013(11)    1.148234
2013(12) - 2014(10)   1.173336
2014(11) - 2016(9)    1.108472
2016(10) - 2017(8)    1.182883
2017(9) - 2018(4)     1.228082
2018(5) - 2019(2)     1.291299
2019(3) - 2019(12)    1.321466

## b) Cambios de tendencia
trend_fit_gas<-lm(gasolinaY_BC~tt_gas)
summary(trend_fit_gas)
Call:
lm(formula = gasolinaY_BC ~ tt_gas)
```

```

Residuals:
    Min       1Q   Median       3Q      Max
-0.112676 -0.040390  0.006963  0.044099  0.072400

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.0885624   0.0109576   99.34  <2e-16 ***
tt_gas       0.0023969   0.0002239   10.70  <2e-16 ***
---
Signif. codes:
  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.04977 on 82 degrees of freedom
Multiple R-squared:  0.5828,    Adjusted R-squared:  0.5777
F-statistic: 114.6 on 1 and 82 DF,  p-value: < 2.2e-16

plot(gasolinaY_BC,ylab=expression(paste("Gasolina  (", lambda, " = -
0.4164)")),xlab="Tiempo")
lines(ts(fitted(trend_fit_gas),start = 2013,frequency = 12),col="red")
gasBC_brk_trend<-breakpoints(gasolinaY_BC~tt_gas,h=0.1)
summary(gasBC_brk_trend)
plot(gasBC_brk_trend) #6 Brk
breakdates(gasBC_brk_trend,breaks = 6)
coef(gasBC_brk_trend,breaks = 6)
              (Intercept)      tt_gas
2013(1) - 2014(3)      1.1327752  0.002807740
2014(4) - 2014(11)     1.2954866 -0.006582965
2014(12) - 2015(7)     0.8326114  0.010285474
2015(8) - 2016(3)      1.3325124 -0.006632441
2016(4) - 2017(4)      0.6973499  0.009828054
2017(5) - 2018(10)     0.6882838  0.009007428
2018(11) - 2019(12)    1.0279040  0.003628344

```

Prueba de raíz unitaria

En la Figura 10 se observa la función de autocorrelación para la variable “precio de gasolina” transformada a BoxCox y una vez que fue diferenciada. En la primera se observa una lenta disminución en la función *acf* a medida que avanzan los lags. Para determinar el número de raíces unitarias que tiene la serie se diferenció una vez, posteriormente se ajustó un modelo autorregresivo y se determinó la significancia de la constante. El orden obtenido para la serie dependiente “precio de la gasolina” fue igual a 3. Mediante la función “*adfTest*” del paquete *fUnitRoots* se realizó la prueba de Dickey y Fuller aumentada. El contraste de hipótesis fue:

$$H_0: \text{La serie tiene raíz unitaria}$$

H_1 : La serie no tiene raíz unitaria

La serie sin diferenciar no rechaza H_0 , lo que indica la presencia de raíz unitaria con un $pvalue = 0.9517$. Sin embargo, al diferenciar una sola vez se observa que la serie ya no tiene raíz unitaria y por lo tanto es estacionaria, con un $pvalue < 0.01$.




Figura 10. Función de autocorrelación de la serie "precios de gasolina en Turquía": a) transformada a BoxCox y b) transformada a BoxCox y diferenciada ($d = 1$).




Figura 11. Series de tiempo “precio de gasolina” y “precio de Brent” transformadas a BoxCox y diferenciadas (d=1).

Rcode

```
### 4. Raiz unitaria de las series Yt, Xt
##Serie Y
par(mfrow=c(1,1),cex=0.9,mar=c(5,4,3,1))
acf(gasolinaY_BC,main="a")
F1<-autoplot(gasolinaY_BC,ylab = "Gasolina",main="Y: BoxCox")
F2<-autoplot(diff(gasolinaY_BC),ylab = "Gasolina",main="Y: BoxCox + d=1")
acf(diff(gasolinaY_BC),main="b")
mod1<-ar(diff(gasolinaY_BC),method = "mle")
mod1$order #Fue = 3
[1] 3
#Hay constante? es significativa?
```

```

t_Y=seq(2:length(gasolinaY_BC))
mod2<-lm(diff(gasolinaY_BC)~t_Y)
summary(mod2) #No es significativa
Call:
lm(formula = diff(gasolinaY_BC) ~ t_Y)

Residuals:
    Min       1Q   Median       3Q      Max
-0.041156 -0.008733 -0.000761  0.011308  0.033288

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -6.932e-04  3.316e-03  -0.209   0.835
t_Y          6.959e-05  6.858e-05   1.015   0.313

Residual standard error: 0.01497 on 81 degrees of freedom
Multiple R-squared:  0.01255,    Adjusted R-squared:  0.0003618
F-statistic:  1.03 on 1 and 81 DF,  p-value: 0.3133

#Ajustar a 3 lags
adfTest(gasolinaY_BC,lags = 3,type = "nc")
Title:
Augmented Dickey-Fuller Test

Test Results:
PARAMETER:
  Lag Order: 3
STATISTIC:
  Dickey-Fuller: 1.3205
P VALUE:
  0.9517
adfTest(diff(gasolinaY_BC),lags = 3,type = "nc")
Title:
Augmented Dickey-Fuller Test

Test Results:
PARAMETER:
  Lag Order: 3
STATISTIC:
  Dickey-Fuller: -4.5582
P VALUE:
  0.01
#La serie transformada tiene raiz unitaria y por lo tanto necesita diferenciarse
dev.off()

```

En la Figura 11 se muestran las dos series de tiempo transformadas a BoxCox y su cambio una vez diferenciadas ($d = 1$). El procedimiento se repitió para la variable independiente. El ajuste del modelo autorregresivo mostró un valor de lag = 1 para la variable “precio del

petróleo Brent”. La constante no fue significativa y una vez ajustada la prueba de Dickey y Fuller aumentada, se concluyó que la serie tenía raíz unitaria y al diferenciarlas una vez ya se cumplía el supuesto de estacionariedad (Figura 12).




Figura 12. Función de autocorrelación de la serie "precios de Brent en Turquía": a) transformada a BoxCox y b) transformada a BoxCox y diferenciada ($d = 1$).

Rcode

```
##Serie X1
par(mfrow=c(1,1),cex=0.9,mar=c(5,4,3,1))
acf(brentX1_BC,main="a")
F3<-autoplot(brentX1_BC,ylab = "Brent",main="X1: BoxCox")
F4<-autoplot(diff(brentX1_BC),ylab = "Brent",main="X1: BoxCox + d=1")
acf(diff(brentX1_BC),main="b")
mod3<-ar(diff(brentX1_BC),method = "mle")
mod3$order #Fue = 1
[1] 1
```

```

#Hay constante? es significativa?
t_X1=seq(2:length(brentX1_BC))
mod4<-lm(diff(brentX1_BC)~t_X1)
summary(mod4) #No es significativa
Call:
lm(formula = diff(brentX1_BC) ~ t_X1)

Residuals:
    Min       1Q   Median       3Q      Max
-0.21099 -0.03857  0.01038  0.03826  0.16991

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.0209594  0.0156394   -1.34   0.184
t_X1         0.0003688  0.0003234    1.14   0.258

Residual standard error: 0.0706 on 81 degrees of freedom
Multiple R-squared:  0.0158,    Adjusted R-squared:  0.00365
F-statistic:  1.3 on 1 and 81 DF,  p-value: 0.2575
#Ajustar a 1 lag
adfTest(brentX1_BC,lags = 1,type = "nc")
Title:
Augmented Dickey-Fuller Test

Test Results:
PARAMETER:
Lag Order: 1
STATISTIC:
Dickey-Fuller: -0.6573
P VALUE:
0.4032
adfTest(diff(brentX1_BC),lags = 1,type = "nc")
Title:
Augmented Dickey-Fuller Test

Test Results:
PARAMETER:
Lag Order: 1
STATISTIC:
Dickey-Fuller: -5.3756
P VALUE:
0.01
dev.off()
#La serie transformada tiene raiz unitaria y por lo tanto necesita diferenciarse

```

Correlación entre variables

La relación entre dos series de tiempo puede estar dada por retrasos en la serie x. La correlación entre variables se obtuvo a partir de la correlación cruzada y mediante la función

“*ccf*” del paquete *stats*. Esta función permite identificar esos lags que son útiles para predecir y . En esta función se definen un conjunto de correlaciones muestrales entre x_{t+h} y y_t para $h = 0, \pm 1, \pm 2, \pm 3$. Un valor negativo para h es una correlación entre la variable x un momento antes de t y la variable y al tiempo t . Para generar los gráficos se utilizaron las variables diferenciadas para evitar obtener una regresión espuria. Aunque X_t y Y_t son series no estacionarias, sus primeras diferencias si lo son. En la Figura 13 se observa que el precio de Brent y el precio de la gasolina se encuentran fuertemente relacionados en el lag 0 (x_{t-0}) y en el lag -1 (x_{t-1}). Lo anterior también implica que posiblemente x conduce a y .




Figura 13. Correlación cruzada entre series de tiempo diferenciadas ($d=1$).

Rcode

```
### 5. Correlación entre pares de variables
#La correlación debe ser entre variables estacionarias
par(mfrow=c(1,1),cex=0.9,mar=c(5,4,3,1))
ccf(diff(brentX1_BC),diff(gasolinaY_BC),ylab="Cross correlation",main="Precio
Brent & Precio Gasolina",type = "correlation")
dev.off()
```

Adicionalmente, se realizó la prueba de Granger para causalidad entre variables. Esta prueba es útil para conocer si una serie de tiempo univariante es útil para predecir otra. La prueba se realizó con la función “*grangertest*” del paquete *lmtest*. Las variables se incorporaron a la

función con la primera diferencia para asegurar el requisito de estacionariedad. La prueba de hipótesis fue la siguiente:

H_0 : La serie de tiempo X_t no causa a la serie de tiempo Y_t

H_1 : La serie de tiempo X_t si es causal de Y_t

El *pvalue* obtenido para la variable X_1 (precio del petróleo Brent) fue menor a 0.001, por lo que se rechaza H_0 , por lo tanto, esta variable si es causal del comportamiento de la serie Y_t (precio de la gasolina).

Rcode

```
### 6. Test de causalidad Granger -- Ho: X no causa a Y
grangertest(diff(brentX1_BC),diff(gasolinaY_BC),order = 3)
Granger causality test

Model 1: diff(gasolinaY_BC) ~ Lags(diff(gasolinaY_BC), 1:3) +
Lags(diff(brentX1_BC), 1:3)
Model 2: diff(gasolinaY_BC) ~ Lags(diff(gasolinaY_BC), 1:3)
Res.Df Df F Pr(>F)
1 73
2 76 -3 12.608 9.944e-07 ***
---
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

#¿Existe una relación inversa?
grangertest(diff(gasolinaY_BC),diff(brentX1_BC))
Granger causality test

Model 1: diff(brentX1_BC) ~ Lags(diff(brentX1_BC), 1:1) +
Lags(diff(gasolinaY_BC), 1:1)
Model 2: diff(brentX1_BC) ~ Lags(diff(brentX1_BC), 1:1)
Res.Df Df F Pr(>F)
1 79
2 80 -1 0.0045 0.9465
```

Pre branqueamiento para la variable independiente

a) Ajuste de un modelo ARIMA

Para el preblanqueamiento de la serie X_t se ajustó un modelo ARIMA a dicha variable. En primer lugar, se definieron los parámetros AR y MA a partir de la Figura 14. En ninguna de

las funciones se observan picos significativos, por lo que se crearon cinco modelos, dos modelos estacionales y tres no estacionales.




Figura 14. Función acf y pacf para la variable X: precio del petróleo Brent.

Los modelos planteados fueron ARIMA1: (0,1,0) (1,0,0) (12), ARIMA2: (0,1,0) (0,0,1) (12), ARIMA3: (0,1,0), ARIMA4: (1,1,0), ARIMA5: (0,1,1). De acuerdo con el criterio de información bayesiano, el mejor modelo fue ARIMA5: (0,1,1), con un parámetro MA estimado en 0.34, significativo ($pvalue < 0.001$) y con un valor BIC igual a -492.0947.

El diagnóstico del modelo seleccionado fue bueno, mostró ruido blanco en los residuales y una distribución normal. Los residuales fueron independientes de acuerdo con la prueba de Ljung-Box, en el que el contraste de hipótesis fue el siguiente:

H_0 : los residuales son independientes

H_1 : Los residuales no son independientes

Se obtuvo un $pvalue = 0.87$, por lo que se cumple este supuesto en residuales. En la prueba de Jarque Bera se obtuvo un $pvalue = 0.7332$.




Figura 15. Diagnóstico del modelo Arima 5 (0,1,1) para la variable X ("Precio del Brent).

Rcode

```
### 7. Preblanqueamiento (Método 1)
acf(diff(brentX1_BC))
pacf(diff(brentX1_BC))
acf2(diff(brentX1_BC),main = "Serie: Brent (d=1)")

## a) Modelos arima propuestos
Arima1_x<-Arima(brentX1_BC,order = c(0,1,0),seasonal = list(order =
c(1,0,0),period = 12),method = "ML",lambda = lambdaX1)
coeftest(Arima1_x)
```

Rcode

```
Arima2_x<-Arima(brentX1_BC,order = c(0,1,0),seasonal = list(order =
c(0,0,1),period = 12),method = "ML",lambda = lambdaX1)
coeftest(Arima2_x)
#Modelo sin estacionalidad
Arima3_x<-Arima(gasolinaY_BC,order = c(0,1,0),method = "ML",lambda = lambdaX1)
Arima4_x<-Arima(gasolinaY_BC,order = c(1,1,0),method = "ML",lambda = lambdaX1)
coeftest(Arima4_x)
Arima5_x<-Arima(gasolinaY_BC,order = c(0,1,1),method = "ML",lambda = lambdaX1)
coeftest(Arima5_x)
z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ma1 0.346094    0.091849  3.7681 0.0001645 ***
---
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

BIC(Arima1_x,Arima2_x,Arima3_x,Arima4_x,Arima5_x)
      df      BIC
Arima1_x  2 -424.0907
Arima2_x  1 -427.4555
Arima3_x  1 -485.5039
Arima4_x  2 -491.8161
Arima5_x  2 -492.0947

AIC(Arima1_x,Arima2_x,Arima3_x,Arima4_x,Arima5_x)
      df      AIC
Arima1_x  2 -428.9283
Arima2_x  1 -429.8743
Arima3_x  1 -487.9227
Arima4_x  2 -496.6537
Arima5_x  2 -496.9324

## b) Diagnostico del modelo
ggtsdiag(Arima5_x)
Box.test(Arima5_x$residuals) # Test de Box-Pierce #Independencia
Box-Pierce test

data: Arima5_x$residuals
X-squared = 0.025452, df = 1, p-value = 0.8732
Box.test(Arima5_x$residuals, type="Ljung-Box") #Independencia
Box-Ljung test

data: Arima5_x$residuals
X-squared = 0.026372, df = 1, p-value = 0.871
jarque.bera.test(Arima5_x$residuals) #Normalidad
Jarque Bera Test

data: Arima5_x$residuals
X-squared = 0.62076, df = 2, p-value = 0.7332

par(mfrow=c(1,2),cex=0.9,mar=c(5,4,3,1))
hist(Arima5_x$residuals, main="a",xlab = "Residuales",ylab = "Frecuencia")
```

```

Rcode
qqPlot(Arima5_x$residuals,distribution = "norm",main = "b"),ylab =
"Residuales")

## c) Una forma de preblanqueamiento
prewhiten(x=diff(brentX1_BC),y=diff(gasolinaY_BC))
#Nota: la gráfica es la misma que la obtenida en el paso 5.

```

b) Detección de outliers

La detección de outliers se realizó con la función “*tso*” y “*locate.outliers*” del paquete *TSA*. La primera función permite detectar el tipo de outlier tanto en la variable original como en los residuales, mientras que la segunda función solo puede utilizarse con residuales. Para la variable X_t , se detectó un outlier en el registro 71 para la serie original, que corresponde a la fecha noviembre 2018. Mientras tanto, para los residuales del modelo seleccionado, no se identificaron outliers con ninguna función. Lo anterior sugiere que es necesario ajustar nuevamente un modelo Arima incorporando esta intervención dentro de su estructura.




Figura 16. Detección de outliers de la variable transformada "precio de Brent".


```
## d) Identificación de outliers
tso(br9entX1_BC)
Series: brentX1_BC
Regression with ARIMA(0,1,0) errors

Coefficients:
      LS71
    -0.2061
s.e.    0.0668

sigma^2 estimated as 0.004515:  log likelihood=106.85
AIC=-209.7  AICc=-209.55  BIC=-204.86

Outliers:
  type ind    time coefhat  tstat
1  LS   71 2018:11 -0.2061 -3.087
plot(tso(brentX1_BC))
#Se identifico un outlier LS (cambio de nivel),
#¿y en residuales?
res_Arima5_x<-residuals(Arima5_x)
polin_X<-coefs2poly(Arima5_x)
(outliersX1<-locate.outliers(res_Arima5_x,polin_X))
[1] type    ind      coefhat tstat
<0 rows> (or 0-length row.names)
#Nota. esta función solo se utiliza con residuales
plot(tso(res_Arima5_x))
'x' does not contain outliers to display
NULL
```

c) Ajuste de un modelo arima con intervención

En primer lugar, se creó el vector binario 0, 1 de intervención por cambio de nivel. Los registros previos a noviembre 2018 se les asignó un valor de 0 y 1 a los registros posteriores. Una vez que el vector estaba creado, se ajustó un nuevo modelo ARIMA, con los mismos parámetros que el modelo previamente seleccionado: ARIMA5: (0,1,1), pero incorporando el vector creado de cambio de nivel y también incorporando el efecto de la intervención. Se observa que el valor omega (-0.199) fue el único significativo con un *pvalue* < 0.001.

```
## e) Incorporar intervención al modelo de X1
#Crear vector binario
length(brentX1_BC)
LS_X1<-outliers("LS",71)
(LSef_X1<-outliers.effects(LS_X1,length(brentX1_BC)))
```

```

library(TSA)
#Omega
Arima_xLS<-arimax(brentX1_BC,order = c(0,1,1),method = "ML",
                  xreg = LSef_X1)
coeftest(Arima_xLS)

#Omega y delta
Arima2_xLS<-arimax(brentX1_BC,order = c(0,1,1),method = "ML",
                  xtrans=LSef_X1,transfer = list(c(1,0)))
coeftest(Arima2_xLS)
z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ma1      0.089375   0.092958   0.9615 0.336325
LS71-AR1  0.177929   0.209382   0.8498 0.395447
LS71-MA0 -0.199123   0.067039  -2.9702 0.002976 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#vALOR Delta no significativo.

```

El diagnóstico del modelo fue bueno, los residuales son ruido blanco y la prueba de Ljung Box indicó que los residuales son independientes. Se utilizó la función *tso* para detectar posibles outliers (se espera que no se detecten, pues ya están incorporados al modelo). La función indicó que ya no existían outliers en los residuales. Por lo que este modelo tuvo un buen ajuste para la variable independiente. Los residuales de este modelo serán utilizados posteriormente para generar nuevamente el gráfico de autocorrelación cruzada.

```

## f) Diagnostico del modelo
ggtsdiag(Arima2_xLS)
Box.test(Arima2_xLS$residuals) # Test de Box-Pierce #Independencia
Box.test(Arima2_xLS$residuals, type="Ljung-Box") #Independencia
hist(Arima2_xLS$residuals, main="a",xlab = "Residuales",ylab = "Frecuencia")
qqPlot(Arima2_xLS$residuals,distribution = "norm",main = "b",ylab =
"Residuales")
dev.off()
plot(tso(Arima_x3_LS2$residuals))

```




Figura 17. Diagnóstico del modelo Arima (0,1,1) con intervención incorporada.

📊 Preblanqueamiento de la variable dependiente

📊 Modelo ARIMA univariado para Y_t

Para el pre blanqueamiento de la serie Y_t , también se ajustó un modelo ARIMA a dicha variable. El modelo utilizado fue el mismo que el seleccionado para la variable independiente ARIMA1: (0,1,1).




Figura 18. Función acf y pacf para la variable Y: precio de la gasolina.

Rcode

```
### 8. Preblanqueamiento Yt
## a) Modelo arima univariado

acf(diff(gasolinaY_BC))
pacf(diff(gasolinaY_BC))
acf2(diff(gasolinaY_BC))

#Propuestas
Arima1_y<-Arima(gasolinaY_BC,order = c(0,1,1),method = "ML",lambda = lambdaY)
coeftest(Arima1_y) #Mismo modelo que el seleccionado por X
z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ma1 0.348573   0.092156   3.7824 0.0001553 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
BIC(Arima1_y)
[1] -501.9053
AIC(Arima1_y,Arima2_y,Arima3_y)
[1] -506.7429
```

De acuerdo con el criterio de información bayesiano, con un parámetro MA estimado en 0.3485, significativo ($pvalue < 0.001$) y con un valor BIC igual a -501.9056. El diagnóstico del modelo seleccionado fue bueno (Figura 19), mostró ruido blanco en los residuales y una distribución normal. Los residuales fueron independientes de acuerdo con la prueba de Ljung-Box, en el que el contraste de hipótesis fue el siguiente:

H_0 : los residuales son independientes

H_1 : Los residuales no son independientes

Se obtuvo un $pvalue = 0.884$, por lo que se cumple este supuesto en residuales. En la prueba de Jarque Bera se obtuvo un $pvalue = 0.6923$ (Figura 20).

```
## b) Diagnostico
ggtsdiag(Arima1_y)
Box.test(Arima1_y$residuals) # Test de Box-Pierce #Independencia
Box-Pierce test

data: Arima3_y$residuals
X-squared = 0.022185, df = 1, p-value = 0.8419
Box.test(Arima1_y$residuals, type="Ljung-Box")
Box-Ljung test

data: Arima1_y$residuals
X-squared = 0.099401, df = 1, p-value = 0.8819
#Independencia
jarque.bera.test(Arima1_y$residuals) #Normalidad
Jarque Bera Test

data: Arima1_y$residuals
X-squared = 73559, df = 2, p-value = 0.6923

par(mfrow=c(1,2),cex=0.9,mar=c(5,4,3,1))
hist(Arima1_y$residuals, main="a",xlab = "Residuales",ylab = "Frecuencia")
qqPlot(Arima1_y$residuals,distribution = "norm",main = "b",ylab =
"Residuales")
dev.off()
```




Figura 19. Diagnóstico del modelo Arima (1,1) para la variable Y_t . “precio de gasolina”.




Figura 20. Histograma de residuales y gráfico QQ para normalidad en residuales.

Identificación de outliers

La detección de outliers se realizó con la función “*tso*” y “*locate.outliers*” del paquete *TSA*. La primera función permite detectar el tipo de outlier tanto en la variable original como en residuales, mientras que la segunda función solo puede utilizarse con residuales. En esta serie, a diferencia de la serie X_t , no se detectaron outliers ni en la serie transformada a boxcox, ni en los residuales del modelo ajustados.

Rcode

```
## c) Identificación de outliers en Yt
tso(gasolinaY_BC)
Series:
ARIMA(0,1,1)

Coefficients:
      ar1
    0.351
s.e. 0.103

sigma^2 estimated as 0.0002009:  log likelihood=235.95
AIC=-467.91  AICc=-467.76  BIC=-463.07

No outliers were detected.

plot(tso(gasolinaY_BC))

#No se identificaron outliers, ¿y en residuales?
resid_Arima1_y<-residuals(Arima3_y)
polin_y<-coefs2poly(Arima1_y)
(outliersY1<-locate.outliers(resid_Arima1_y,polin_y))
[1] type      ind      coefhat tstat
<0 rows> (or 0-length row.names)
plot(tso(resid_Arima1_y))
'x' does not contain outliers to display
NULL
```

Correlación cruzada entre residuales

La correlación cruzada entre residuales de ambos modelos X y Y (Figura 21) fue igual a la que se muestra en la Figura 13. Esto enfatiza la importancia de realizar la correlación entre series estacionarias o preblanqueadas para mostrar correctamente la relación entre variables.




Figura 21. Correlación cruzada entre series de tiempo.

Rcode

```
### 9. Correlación cruzada entre series preblanqueadas
## Se utilizaron residuales de modelos X y Y
#Correlación cruzada entre series preblanqueadas
par(mfrow=c(1,1),cex=0.9,mar=c(5,4,3,1))
ccf(Arima2_xLS$residuals,Arima3_y$residuals,ylab="Cross
correlation",main="Precio Brent & Precio Gasolina",type =
"correlation",na.action = na.omit)
dev.off()
```

🔗 Función de transferencia en modelo bivariado

Se generaron tres modelos arima con ambas variables. El primer modelo solo se incorporó a la variable independiente “precio de Brent” y fue ARIMA1: (1,1,0). El segundo modelo fue el modelo bivariado con la incorporación de la variable binaria como otra variable regresora y con los mismos parámetros. El tercer modelo incorporó tanto la variable de intervención como el efecto por cambio de nivel.

En el primer modelo, se obtuvo una alta significancia en la variable regresora, con un *pvalue* < 0.001. El valor de BIC fue de -474.6216. En la se observa que los residuales son ruido blanco, al no presentar picos significativos en su función acf y ser independientes. Tampoco se detectaron outliers en los residuales.




Figura 22. Diagnóstico del modelo arima bivariado sin intervención.

Rcode

10. Función de transferencia

a). Modelo bivariado sin intervención

```
Arima1_xy_si<-arimax(gasolinaY_BC,order = c(1,1,0),xreg = brentX1_BC)
```

Call:

```
arimax(x = gasolinaY_BC, order = c(0, 1, 1), xreg = brentX1_BC)
```

Coefficients:

	ma1	xreg
	0.0699	0.1037
s.e.	0.1346	0.0254

sigma^2 estimated as 0.000164: log likelihood = 243.93, aic = -483.86

Rcode

```

coeftest(Arima1_xy_si)
z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ma1  0.069863   0.134554  0.5192   0.6036
xreg 0.103731   0.025396  4.0846 4.415e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
BIC(Arima1_xy_si)
[1] -474.6009

ggtsdiag(Arima1_xy_si)
checkresiduals(Arima1_xy_si)
plot(rstandard(Arima1_xy_si))
resid_Arima1_xy<-residuals(Arima1_xy_si)
polin1_XY<-coefs2poly(Arima1_xy_si)
(outliersX1<-locate.outliers(resid_Arima1_xy,polin1_XY))
[1] type      ind      coefhat tstat
<0 rows> (or 0-length row.names)

tso(residuals(Arima1_xy_si))
Series:

No outliers were detected.

```

Con respecto al segundo modelo, la variable de intervención se incorporó como otra variable regresora, mediante el argumento *xreg*. El valor de BIC fue menos negativo que el del modelo anterior, con un valor de -470.2124. El valor MA estimado fue de 0.07091, el coeficiente de la variable de regresión fue significativo con un valor de 0.1024 y un $\alpha < 0.001$.

Rcode

```

### b) Modelo bivariado con intervención
Arima2_xy_ci<-arimax(gasolinaY_BC,order = c(0,1,1), xreg = data.frame
(brentX1_BC,LSeF_X1))
Call:
arimax(x = gasolinaY_BC, order = c(0, 1, 1), xreg = data.frame(brentX1_BC,
LSeF_X1))

Coefficients:
      ma1  brentX1_BC      LS71
      0.0709      0.1025 -0.0023
s.e.  0.1347      0.0263  0.0134

sigma^2 estimated as 0.0001639:  log likelihood = 243.94,  aic = -481.89

BIC(Arima2_xy_ci)

```

```
[1] -470.2124
```

```
coeftest(Arima2_xy_ci)
z test of coefficients:
```

	Estimate	Std. Error	z value	Pr(> z)
ma1	0.0709116	0.1346889	0.5265	0.5986
brentX1_BC	0.1024788	0.0263361	3.8912	9.975e-05 ***
LS71	-0.0023394	0.0134311	-0.1742	0.8617

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
ggtsdiag(Arima2_xy_ci)
checkresiduals(Arima2_xy_ci)
plot(rstandard(Arima2_xy_ci))
resid_Arima2_xy<-residuals(Arima2_xy_ci)
polin2_XY<-coefs2poly(Arima2_xy_ci)
(outliersX2<-locate.outliers(resid_Arima2_xy,polin2_XY))
```

```
[1] type      ind      coefhat tstat
<0 rows> (or 0-length row.names)
```

```
tso(residuals(Arima2_xy_ci))
```

```
Series:
```

```
ARIMA(0,0,0) with zero mean
```

```
sigma^2 estimated as 0.0001619:  log likelihood=247.4
AIC=-492.79  AICc=-492.75  BIC=-490.36
```

```
No outliers were detected.
```




Figura 23. Diagnóstico del modelo ARIMA bivariado con intervención.

Para el tercer modelo, aunque el valor de BIC no se pudo determinar, el valor de AIC fue ligeramente menor al de los otros modelos. El coeficiente estimado para la variable regresora “precio de brent” fue igual a 0.096 y significativo ($pvalue < 0.001$). El valor estimado de ω fue de -0.01450 pero no fue significativo, en cambio el efecto δ fue significativo ($pvalue < 0.05$) e igual a 0.5319, lo que indica que su efecto se encuentra en un punto medio entre un cambio abrupto y gradual. Los residuales fueron ruido blanco con una variabilidad mucho estable y cercana a cero. Los residuales siguen una distribución normal y son independientes.




Figura 24. Diagnóstico del modelo ARIMA bivariado con intervención y efecto.

c). Modelo bivariado con intervención y efecto

```

Arima3_xy_ci<-arimax(gasolinaY_BC,order      =      c(1,1,0),xreg      =
brentX1_BC,xtrans=LSeF_X1,transfer = list(c(0,1)))
arimax(x = gasolinaY_BC, order = c(0, 1, 1), xreg = data.frame(brentX1_BC),
      xtransf = LSeF_X1, transfer = list(c(1, 0)))

Coefficients:
      ma1  brentX1_BC  LS71-AR1  LS71-MA0
      0.0716      0.0968      0.5319     -0.0140
s.e.  0.1314      0.0256      0.2433      0.0118

sigma^2 estimated as 0.0001611:  log likelihood = 244.67,  aic = -481.34
coeftest(Arima3_xy_ci)

```

Rcode

```
z test of coefficients:
```

	Estimate	Std. Error	z value	Pr(> z)	
ma1	0.071624	0.131406	0.5451	0.5857151	
brentX1_BC	0.096764	0.025564	3.7851	0.0001536	***
LS71-AR1	0.531923	0.243310	2.1862	0.0288016	*
LS71-MA0	-0.014013	0.011846	-1.1829	0.2368399	

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
gtsdiag(Arima3_xy_ci)
```

```
checkresiduals(Arima3_xy_ci)
```

```
plot(rstandard(Arima3_xy_ci))
```

```
resid_Arima3_xy<-residuals(Arima3_xy_ci)
```

```
polin3_XY<-coefs2poly(Arima3_xy_ci)
```

```
(outliersX3<-locate.outliers(resid_Arima3_xy,polin3_XY))
```

```
tso(residuals(Arima3_xy_ci))
```

Conclusiones

En este trabajo se mostró la relación entre dos series de tiempo, la gasolina y el precio del petróleo Brent. De acuerdo con la función de correlación cruzada, el precio de Brent dirige de forma inmediata el comportamiento temporal del precio de gasolina. Además, se observó una intervención en noviembre 2018 con un efecto en cambio de nivel en la serie X. Consultando algunas noticias de esa fecha, esta perturbación podría ser efecto de una recesión económica en Turquía, así como presiones de inflación en el precio de la gasolina ([Noticia](#)). Con la creación del modelo de transferencia, este efecto se incorporó de manera adecuada al modelo de Yt.