



COLEGIO DE POSTGRADUADOS
INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS
AGRÍCOLAS
CAMPUS MONTECILLO
PROGRAMA DE POSTGRADO EN CIENCIAS FORESTALES

TAREA 11

REGRESIÓN CON ERRORES AUTOREGRESIVOS

EST-624. Series de tiempo
Dra. Martha Elva Ramírez Guzmán

Zaira Rosario Pérez Vázquez
05 de abril de 2021

Introducción

La autocorrelación, también conocida como correlación en serie, es la correlación de una señal con una copia retrasada de sí misma en función del retraso. En otras palabras, es la similitud entre observaciones en función del desfase temporal entre ellas. Esta propiedad hace que la prueba Durbin Watson sea útil para datos de series de tiempo donde el estado actual del sistema depende en gran medida de datos anteriores.

Cuando se utilizan datos de series de tiempo en el análisis de regresión, a menudo no se incluye el término de error dependiente a través del tiempo. En cambio, los errores están correlacionados en serie o auto correlacionados, y por lo tanto, las estimaciones de parámetros se ven afectadas negativamente y las estimaciones de error estándar están sesgadas.

El análisis de regresión ordinario supone que la varianza del error es la misma para todas las observaciones. Cuando la varianza del error no es constante, se dice que los datos son heterocedásticos y las estimaciones de mínimos cuadrados ordinarios son ineficientes. La heterocedasticidad también afecta la precisión de los límites de confianza del pronóstico. Los modelos que tienen en cuenta la heterocedasticidad pueden hacer un uso más eficiente de los datos y estimaciones de errores de predicción más precisas.

El modelo de error autorregresivo se utiliza para corregir la autocorrelación, y el modelo de heterocedasticidad condicional autorregresiva generalizada (GARCH) y sus variantes se utilizan para modelar y corregir la heterocedasticidad.

Detección de autocorrelación y regresión entre residuales

Para diagnosticar la autocorrelación, el procedimiento AUTOREG produce estadísticas de Durbin-Watson (DW) generalizadas y sus probabilidades marginales. En R, esta prueba se realiza utilizando la función “*durbinWatsonTest*” del paquete *car* o mediante la función “*dwtest*” del paquete *lmtest*.

La prueba se realizó a partir de los residuales de un modelo arimax con la incorporación de una variable de intervención y función de transferencia. Este modelo relaciona dos series de tiempo: la producción forestal maderable (Y_t) y el número de árboles infestados por muérdago enano. El modelo ajustado fue $ARIMA(1,1,0)(1,1,0)(12)$. En la Figura 1 se observa

que los residuales son independientes y normales pero presenta dos picos significativos en su función acf..




Figura 1. Diagnóstico del modelo ARIMA (1,1,0) (1,1,0) (12) para la producción forestal maderable.

El estadístico de Durbin-Watson es aproximadamente igual a 2, siendo los valores cercanos a 2 los indicativos de ausencia de autocorrelación de primer orden. El contraste de hipótesis es:

$H_0 = \text{No existe autocorrelación}$

$H_a = \text{Lo contrario}$

Una vez que los residuales fueron convertidos a vector, se obtuvo un valor DW = 1.85.

Rcode

```
#####  
#### Autocorrelación en residuales  
#Residuales  
  
#Modelo ajustado en la linea 338.  
ggtsdiag(Arima3_xy_model_ci)  
checkresiduals(Arima3_xy_model_ci)  
  
residxy<-residuals(Arima3_xy_model_ci)  
acf2(residxy) #Hay presencia de algunos picos en acf y pacf a 2 lags  
  
library(car)  
library(lmtest)  
  
residxy<-as.vector(residxy)  
durbinWatsonTest(residxy)  
1.85287  
  
#El valor cercano a 2 es indicativo de ausencia de autocorrelación de primer  
orden  
shapiro.test(residxy) #Son normales  
Shapiro-Wilk normality test  
  
data: residxy  
W = 0.97436, p-value = 0.09174  
  
Box.test(residxy, type="Ljung-Box") #son independientes  
Box-Ljung test  
  
data: residxy  
X-squared = 0.4193, df = 1, p-value = 0.5173
```

Por lo cual se ajustó un modelo de regresión lineal residuales ~ tiempo. De acuerdo con el resumen del modelo, el tiempo no fue significativo.

Rcode

```
#Definir tiempo  
trend=time(residxy)  
  
reg_model<-lm(residxy~trend)  
summary(reg_model)  
  
Call:  
lm(formula = residxy ~ trend)  
  
Residuals:  
      Min       1Q   Median       3Q      Max  
-0.0069927 -0.0012267  0.0003217  0.0014623  0.0043160
```

```

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -1.763e-01  2.532e-01  -0.696   0.488
trend        8.738e-05  1.255e-04   0.696   0.488

Residual standard error: 0.002324 on 82 degrees of freedom
Multiple R-squared:  0.005876,    Adjusted R-squared:  -0.006247
F-statistic: 0.4847 on 1 and 82 DF,  p-value: 0.4883

acf2(residuals(reg_model))

#Ho: no hay autocorrelacion
dwtest(residxy~trend)
      Durbin-Watson test

data:  residxy ~ trend
DW = 1.8639, p-value = 0.2297
alternative hypothesis: true autocorrelation is greater than 0

```

Posteriormente, se graficaron las funciones acf y pacf para verificar que los residuales fueran ruido blanco, sin embargo, aún se observa un pico significativo en la función acf (Figura 2). La prueba DW a los residuales de este modelo obtuvo un valor 1.86 con un pvalue = 0.2297, por lo que no hay presencia de autocorrelación.




Figura 2. Función acf y pacf para residuales del modelo de regresión lineal ajustado.

Finalmente, para afinar un poco más el modelo, se creó otro modelo sarima iterativo con los residuales de este modelo, con el objetivo de eliminar los picos significativos. El modelo ajustado fue el siguiente:

```
Rcode

##Afinar el modelo
adjreg = sarima (residuals(reg_model), 0,0,1, xreg=trend) # This is the
adjustment regression with MA(1) residuals
adjreg2 = sarima (residuals(reg_model), 2,0,3, xreg=trend) # This is the
adjustment regression with ARMA residuals
##Este modelo es más cercano a ruido blanco

acf2(resid(adjreg$fit))
acf2(resid(adjreg2$fit))

resid_adjreg2<-resid(adjreg2$fit)
resid_adjreg2<-as.vector(resid_adjreg2)

durbinWatsonTest(resid_adjreg2)
[1] 2.0146

shapiro.test(resid_adjreg2) #son normales
Shapiro-Wilk normality test

data:  resid_adjreg2
W = 0.97513, p-value = 0.1033

Box.test(resid_adjreg2, type="Ljung-Box") #Son independientes
Box-Ljung test

data:  resid_adjreg2
X-squared = 0.011928, df = 1, p-value = 0.913
```

En las Figuras 3 y 4 se muestra el diagnóstico de este modelo, así como sus funciones acf y pacf, respectivamente. Con el ajuste de este nuevo modelo ya no se observan picos significativos en sus residuales, la prueba DW obtuvo un valor de 2.014, lo que indicó la ausencia de autocorrelación. Asimismo, los residuales fueron normales, con la prueba Shapiro-Wilk e independientes, con la prueba Box-Ljung.




Figura 3. Diagnóstico del modelo con corrección por autoregresión




Figura 4. Funciones acf y pacf del modelo con corrección por autoregresión