



COLEGIO DE POSTGRADUADOS

COLEGIO DE POSTGRADUADOS

INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS
AGRÍCOLAS

CAMPUS MONTECILLO

PROGRAMA DE POSTGRADO EN CIENCIAS FORESTALES

TAREA 12-13

Modelos ARCH - GARCH

EST-624. Series de tiempo

Dra. Martha Elva Ramírez Guzmán

Zaira Rosario Pérez Vázquez

12 de abril de 2021

Introducción

El estudio del componente de varianza constante es un fenómeno menos extendido en los modelos de Box y Jenkins. La omisión de una posible heterocedasticidad en residuales puede suponer diversos problemas estadísticos en la estimación de modelos (problemas ligados con la eficiencia de los parámetros estimados y su fuerte volatilidad el amplio intervalo de confianza en el que se mueven).

Por lo tanto, para determinar un patrón estadístico para la varianza, se encuentran los modelos ARCH (Modelos autorregresivos condicionales heterocedásticos). Para justificar el desarrollo de estos modelos, Eagle (1982) cita dos situaciones para exponer por qué estos modelos fueron propuestos para explicar ciertas propiedades que no pueden ser explicados por los modelos ARIMA y que aparecen con frecuencia en series estacionarias de datos financieros y ambientales de alta frecuencia:

- a) La experiencia empírica permite contrastar períodos de amplia varianza de error seguidos de otros de varianza más pequeña. Es decir, el valor de la dispersión del error respecto a su media cambia en el pasado, por lo que es lógico pensar que un modelo que atiende en la predicción a los valores de dicha varianza en el pasado servirá para realizar estimaciones más precisas.
- b) Estos modelos son válidos para determinar los criterios de mantenimiento o venta de activos financieros. Los agentes económicos deciden esta cuestión en función de la información proveniente del pasado respecto al valor medio de su rentabilidad y la volatilidad que esta ha tenido. Con los modelos ARCH se tienen en cuenta estas dos condicionantes.

Estas series tienen poca estructura en la media y siguen caminatas aleatorias o procesos AR de orden bajo y coeficiente pequeño. Además, puede ocurrir que, aunque los residuales parezcan ruido blanco, su distribución no sea normal y muestre colas pesadas y alta curtosis, que los datos estén casi sin autocorrelación, pero al calcular las auto correlaciones entre los residuales al cuadrado se observa una fuerte estructura de dependencia. En los residuales podrían observarse rachas de mayor variabilidad seguida de rachas de menor variabilidad. Por eso se plantean este tipo de modelos, que serán modelados con varianza marginal constante y varianza condicionada a los valores del pasado de la serie no constante, ya que depende de sus valores previos.

El modelo ARCH supone que la varianza condicional depende del pasado con estructura autorregresiva. Los modelos GARCH incorporan a esta dependencia términos de media móvil. Proporcionan buenos ajustes con p y q pequeños (la mayoría de las series temporales financieras pueden modelarse con un GARCH (1,1)). Otra clase de modelos más flexibles son los modelos de volatilidades estocásticas (SV) que reproducen algunas propiedades típicas de las series financieras, como exceso de curtosis, agrupamiento de los periodos de volatilidad, correlación en los cuadrados de la serie, etc. Difiere de los anteriores en que la volatilidad es un componente no observable cuyo logaritmo suele

modelizarse mediante un proceso lineal autorregresivo. Al considerar la volatilidad como un proceso estocástico se busca ajustar un modelo que permita describir y analizar su comportamiento presente y a partir de este, su comportamiento futuro.

Detección de heterocedasticidad en residuales

Se continuó el análisis de residuales de un modelo arimax con la incorporación de una variable de intervención y función de transferencia. Este modelo relaciona dos series de tiempo: la producción forestal maderable Y_t y el número de árboles infestados por muérdago enano. El modelo ajustado fue ARIMA (1,1,0) (1, 1, 0) (12). Los residuales de este modelo fueron sometidos a una regresión lineal (residuales ~ tiempo) donde se detectó que el tiempo no fue significativo y de acuerdo con el test Durbin Watson, los residuales no están auto correlacionados de forma significativa.

Para verificar homogeneidad de varianzas se realizó el test de Breusch-Pagan. En R esta prueba se realizó con la función “*bptest*” del paquete *lmtest*. El contraste de hipótesis fue el siguiente:

H_0 : Los residuales son homocedásticos

H_a : Los residuales son heterocedásticos

Se obtuvo un pvalue de 0.3517, por lo que se acepta la hipótesis nula de residuales homocedásticos. Sin embargo, la función de densidad muestra una distribución ligeramente sesgada a la derecha, aunque la prueba de Shapiro-Wilk tuvo un pvalue = 0.05281, que indica una distribución normal.

e

Rcode

```
#Nota. A partir de la línea 397 del código en R.
```

```
##### Tarea 12
```

```
#Heterocedasticidad ##### TAREA 12
```

```
bptest(reg_model)
```

```
studentized Breusch-Pagan  
test
```

```
data: reg_model  
BP = 0.86735, df = 1,  
p-value = 0.3517
```

```
# Ho: Los residuales son homocedasticos  
# No se rechaza Ho  
hist(reg_model$residuals)
```

```
plot(density(reg_model$residuals))
shapiro.test(reg_model$residuals)
```

Shapiro-Wilk normality
test

```
data: reg_model$residuals
W = 0.97077, p-value =
0.05281
```

Para afinar el modelo, se creó previamente un modelo sarima iterativo con los residuales del modelo anterior, con el objetivo de obtener residuales sin picos significativos en sus funciones acf y pacf. El modelo ajustado a estos residuales fue ARMA (2, 0, 3). La Fig. 1 muestra el diagnóstico de este modelo. Los residuales no están autocorrelacionados, son independientes y siguen una distribución normal.




Fig. 1. Diagnóstico del modelo ajustado ARMA (2,1) para residuales autocorrelacionados.

Para probar la homocedasticidad en los residuales de este modelo, se utilizó la función “*arch.test*” del paquete *aTSA*. Esta función utiliza pruebas de multiplicador de Lagrange para la hipótesis nula de que los residuos de un modelo ARIMA son homocedásticos. En la Figura 2 se observa que en los residuales al cuadrado solo se observa un punto con un pvalue menor a 0.05.




Fig. 2. Prueba de homocedasticidad ($pvalue > 0.05$) para el modelo ajustado ARMA (2,1).

Adicionalmente se obtuvieron los residuales al cuadrado y se graficó su función *acf* y *pacf* (Fig. 3). Se observa que tienen un comportamiento similar al ruido blanco. Por lo que se concluye que los residuales son aptos y no es necesario el ajuste a un modelo ARCH.




Fig. 3. Función *acf* y *pacf* para los residuales elevados al cuadrado del modelo ajustado ARMA (2,1).

```

#Poner el modelo sarima en objeto arima
adjreg22 = arima(residuals(reg_model), order=c(2,0,3), xreg=trend) # This is the
adjustment regression with MA(1) residuals
checkresiduals(adjreg22)
ggtsdiag(adjreg22)
arch.test(adjreg22) #probar homocedasticidad , h0 es homocedast..
ARCH heteroscedasticity test for residuals
alternative: heteroscedastic

Portmanteau-Q test:
      order    PQ p.value
[1,]      4  1.91  0.752
[2,]      8  3.64  0.888
[3,]     12  7.72  0.807
[4,]     16  8.74  0.924
[5,]     20 10.57  0.957
[6,]     24 11.71  0.983

Lagrange-Multiplier test:
      order    LM p.value
[1,]      4 15.5342 0.00141
[2,]      8  5.6074 0.58627
[3,]     12  2.3350 0.99693
[4,]     16  0.5503 1.00000
[5,]     20 -0.0339 1.00000
[6,]     24 -0.2328 1.00000

res2=residuals(adjreg22)^2
plot(res2,type="l")
acf2(res2,ci.type="ma")

```

Modelo ARCH

El modelo ARCH asume que la media condicional del término de error en un modelo de series de tiempo es constante (cero), a diferencia de las series no estacionarias, pero su varianza condicional no lo es. Dicho modelo se puede describir como en las ecuaciones 1, 2 y 3.

$$y_t = \phi + \epsilon_t \quad (1)$$

$$\epsilon_t | I_{t-1} \sim N(0, h_t) \quad (2)$$

$$h_t = \alpha_0 + \alpha_1 \epsilon_{t-1}^2, \quad \alpha_0 > 0, \quad 0 \leq \alpha_1 < 1 \quad (3)$$

El modelo de prueba y las hipótesis para probar los efectos ARCH en una serie de tiempo se representan por las ecuaciones 4 y 5, donde los residuales ϵ_t provienen de la regresión de la variable y_t en una constante, como 1, o en una constante más otros regresores; la prueba que

se muestra en la Ecuación 4 puede incluir varios términos de retardo, en cuyo caso la hipótesis nula sería que todos ellos son conjuntamente insignificantes.

$$\hat{e}_t^2 = \gamma_0 + \gamma_1 \hat{e}_{t-1}^2 + \cdots + \gamma_q \hat{e}_{t-q}^2 + v_t \quad (4)$$

$$H_0: \gamma_1 = \cdots = \gamma_q = 0, \quad H_a: \gamma_q \neq 0 \quad (5)$$

En este caso, no se rechaza la hipótesis nula, que indica que no hay efecto ARCH

EJEMPLO RENDIMIENTOS DE LAS ACCIONES DE HOME DEPOT

El siguiente ejemplo utiliza las acciones el conjunto de datos OFD que contiene 500 observaciones generadas sobre los rendimientos de las acciones de Home Depot. En la Figura 4 se muestra el comportamiento de los residuales y en la Figura 5 se observa que tanto los residuales simples como elevados al cuadrado presentan picos significativos que sugieren la falta de homocedasticidad.




Fig. 4. Serie de los rendimientos de las acciones de Home Depot e histograma




Fig. 5. Funciones acf y pacf de los residuales simples y elevados al cuadrado

El modelo de la Ecuación 4 se realizó con el siguiente código en R:

Rcode

```
#Modelo ARCH
```

```
setwd("C:/Users/zaira/Documents/Doctorado PCF/3. Cursos/2. Primavera 2021/3.
Series de tiempo/3. Tareas/Tarea 13")
rm(list=ls())
options(max.print = 10000)
```

```
rendHD<- read.csv("rend_HD.csv",header = TRUE)
View(rendHD)
resHD<-rendHD$r_HOME_DEPOT
```

```
par(mfrow=c(1,2),mar=c(5,4,3,1),cex=0.6)
plot.ts(resHD)
hist(resHD, main="", breaks=20, freq=FALSE, col="grey")
```

```
library("dynlm")
resHD_mean<-dynlm(resHD~1)
summary(resHD_mean)
```

```
Time series regression with "numeric" data:
Start = 1, End = 500
```

```
Call:
dynlm(formula = resHD ~ 1)
```

```
Residuals:
      Min       1Q   Median       3Q      Max
-3.8469 -0.7228 -0.0490  0.6691  5.9306
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    1.078      0.053   20.35  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 1.185 on 499 degrees of freedom
```

```
ehat2<-ts(resid(resHD_mean)^2)
HD_arch<-dynlm(ehat2~L(ehat2))
summary(HD_arch)
```

```
Time series regression with "ts" data:
Start = 2, End = 500
```

```
Call:
dynlm(formula = ehat2 ~ L(ehat2))
```

```
Residuals:
      Min       1Q   Median       3Q      Max
-10.8023  -0.9496  -0.7055   0.3204  31.3468
```

```
Coefficients:
```



```

              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.90826    0.12440   7.301 1.14e-12 ***
L(ehat2)     0.35307    0.04198   8.410 4.39e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.45 on 497 degrees of freedom
Multiple R-squared:  0.1246,    Adjusted R-squared:  0.1228
F-statistic: 70.72 on 1 and 497 DF,  p-value: 4.387e-16

##Estimación de parametros
library(broom)
T <- 500
q <- length(coef(HD_arch))-1
Rsqr <- glance(HD_arch)[[1]]
[1] 0.1245681

LM <- (T-q)*Rsqr
[1] 62.1595

alpha <- 0.05

Chicr <- qchisq(1-alpha, q)
[1] 3.841459

```

En este caso, el valor de $LM = 62.1595$ y al compararse con el valor crítico de chi-cuadrado ($\alpha = 0.05$, $q = 1$ (grados de libertad)). Este valor fue igual a $\chi^2_{(0.95,1)} = 3.84$, lo que indica que la hipótesis nula se rechaza y por lo tanto, hay efectos ARCH. Este procedimiento es similar al obtenido con la función *ArchTest* del paquete *FinTS*.

Rcode

```

(HD_archtest<-ArchTest(resHD,lags = 1,demean = T))

      ARCH LM-test; Null hypothesis: no ARCH effects

data:  resHD
Chi-squared = 62.16, df = 1, p-value = 3.167e-1

```

Se utilizó la función *garch* del paquete *tseries* convierte un modelo ARCH con un orden (0,1) y permite estimar h_t definido en la Ecuación 3. En la figura 6 se muestra el comportamiento de $\hat{h}_t$.




Fig. 6. Varianza estimada de ARCH (1) de los rendimientos de las acciones de Home Depot.

Rcode

```
#ARCH (0,1)
library(tseries)
HD.arch_m2 <- garch(resHD,c(0,1))
```

***** ESTIMATION WITH ANALYTICAL GRADIENT *****

I	INITIAL X(I)	D(I)
1	1.334069e+00	1.000e+00
2	5.000000e-02	1.000e+00

IT	NF	F	RELDF	PRELDF	RELDX	STPPAR	D*STEP	NPRELDF
0	1	5.255e+02						
1	2	5.087e+02	3.20e-02	7.13e-01	3.1e-01	3.8e+02	1.0e+00	1.34e+02
2	3	5.004e+02	1.62e-02	1.78e-02	1.2e-01	1.9e+00	5.0e-01	2.11e-01
3	5	4.803e+02	4.03e-02	4.07e-02	1.2e-01	2.1e+00	5.0e-01	1.42e-01
4	7	4.795e+02	1.60e-03	1.99e-03	1.3e-02	9.7e+00	5.0e-02	1.36e-02
5	8	4.793e+02	4.86e-04	6.54e-04	1.2e-02	2.3e+00	5.0e-02	2.31e-03
6	9	4.791e+02	4.16e-04	4.93e-04	1.2e-02	1.7e+00	5.0e-02	1.39e-03
7	10	4.789e+02	3.80e-04	4.95e-04	2.3e-02	4.6e-01	1.0e-01	5.36e-04
8	11	4.789e+02	6.55e-06	6.73e-06	9.0e-04	0.0e+00	5.1e-03	6.73e-06
9	12	4.789e+02	4.13e-08	3.97e-08	2.2e-04	0.0e+00	9.8e-04	3.97e-08
10	13	4.789e+02	6.67e-11	6.67e-11	9.3e-06	0.0e+00	4.2e-05	6.67e-11

***** RELATIVE FUNCTION CONVERGENCE *****

FUNCTION	4.788831e+02	RELDX	9.327e-06
FUNC. EVALS	13	GRAD. EVALS	11
PRELDF	6.671e-11	NPRELDF	6.671e-11

I	FINAL X(I)	D(I)	G(I)
1	2.152304e+00	1.000e+00	-2.370e-06
2	1.592050e-01	1.000e+00	-7.896e-06

```
summary(HD.arch_m2)
```

```
Call:
garch(x = resHD, order = c(0, 1))
```

```

Model:
GARCH(0,1)

Residuals:
      Min       1Q   Median       3Q      Max
-1.4591  0.2200  0.6683  1.0790  4.2928

Coefficient(s):
      Estimate Std. Error  t value Pr(>|t|)
a0    2.15230    0.18570   11.590  <2e-16 ***
a1    0.15920    0.06738    2.363   0.0181 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Diagnostic Tests:
      Jarque Bera Test

data:  Residuals
X-squared = 48.565, df = 2, p-value = 2.846e-11

      Box-Ljung test

data:  Squared.Residuals
X-squared = 0.12243, df = 1, p-value = 0.7264

hhat <- ts(2*HD.arch_m2$fitted.values[-1,1]^2)
plot.ts(hhat)

```

Adicionalmente, se utilizó el paquete “rugarch” para ajustar un modelo GARCH ordinario (1,1) (Figura 7). Un modelo GARCH (m, s) sigue la siguiente fórmula:

$$\sigma_t^2 = \omega + \sum_{i=1}^m \alpha_i \epsilon_{t-i}^2 + \sum_{j=1}^s \beta_j \sigma_{t-j}^2 \quad (7)$$

Donde

$$\{\epsilon_t^2\}_{t=1}^m \quad \epsilon_t^2 \sim WN(0, \sigma_\epsilon^2) \quad (8)$$

Y utilizando un operador de retardo:

$$\sigma_t^2 = \omega + \alpha(B)\epsilon_t^2 + \beta(B)\sigma_t^2 \quad (9)$$

$$\sigma_t^2 = 0.3967 + 0.4951\epsilon_{t-1}^2 + 0.2407\sigma_{t-1}^2 \quad (7)$$




Fig. 7. Varianza estimada de GARCH (1,1) de los rendimientos de las acciones de Home Depot.

Rcode

```
##Modelo GARCH
library(rugarch)
garch_Spec <- ugarchspec(variance.model=list(model="sGARCH",
                                             garchOrder=c(1,1)), mean.model=list(armaOrder=c(0,0)),
                        distribution.model="std")
garchFit <- ugarchfit(spec=garch_Spec, data=resHD)
(coef(garchFit))

      mu      omega    alpha1    beta1    shape
1.0492727 0.3967002 0.4951085 0.2407466 99.9930417

rhat <- garchFit@fit$fitted.values

par(mfrow=c(1,2),mar=c(5,4,3,1),cex=0.6)
plot.ts(rhat)
hhat2 <- ts(garchFit@fit$sigma^2)
plot.ts(hhat2)
```